Reporte tecnico explicativo del notebook de analitica y aprendizaje automatico

Campanas de phishing simulado: construccion del dataset, ingenieria de variables, modelado, visualizacion y proyecciones

Este documento explica detalladamente la logica del cuaderno `test.ipynb`. Incluye la descripcion del flujo de datos, las transformaciones, los modelos empleados, los calculos matematicos y estadisticos, asi como la interpretacion de tablas y graficos para una presentacion academica.

Proposito	Documentar tecnicamente el notebook y convertirlo en un guion de defensa / presentacion.
Paradigma principal	Analitica descriptiva + aprendizaje supervisado + reglas semanticas + proyeccion temporal exploratoria.
Fuentes de datos	Tablas MySQL de GoPhish, plantillas textuales y tabla de clasificacion semantica.
Resultado final	Modelo de clasificacion de interacciones, dashboard analitico y predicciones a seis meses por nivel de riesgo.

1. Arquitectura general del notebook

El notebook sigue un flujo en ocho etapas: inspeccion de tablas, construccion del dataset maestro, carga de un diccionario semantico de clasificacion textual, normalizacion y enriquecimiento NLP, modelado supervisado, evaluacion, dashboard descriptivo y, finalmente, analisis de riesgo y proyecciones.

El diseño es hibrido. Por un lado, utiliza tecnicas clasicas de ciencia de datos tabular. Por otro lado, incorpora procesamiento de lenguaje natural para transformar texto libre de plantillas de correo en variables explicativas. El cuaderno combina paradigmas descriptivos, predictivos y heuristico-semanticos.

2. Tablas base y validacion estructural

Antes de modelar, el notebook verifica que la estructura de las tablas sea coherente. Esto evita errores de integridad y ayuda a definir las uniones SQL necesarias.

2.1. Tabla templates

La tabla `templates` almacena el contenido de las campañas. Sus columnas principales son el identificador, el asunto, el cuerpo en texto, el HTML y la fecha de modificacion. Esta tabla es la fuente textual principal para el analisis de lenguaje.

```
   id  user_id            name                                     subject  \
0   1        1   Template P1-1   Actualizacion de cuenta corporativa P1-1
1   2        1   Template P1-2              Revision de acceso a VPN P1-2
2   3        3   Template P1-3        Confirmacion de nomina interna P1-3
3   4        2   Template P1-4    Verificacion de correo empresarial P1-4
4   5        2   Template P1-5           Politica nueva de seguridad P1-5
5   6        2   Template P1-6       Portal de vacaciones y permisos P1-6
6   7        1   Template P1-7  Actualizacion de beneficios internos P1-7
7   8        1   Template P1-8         Revision de firma electronica P1-8
8   9        4   Template P1-9         Confirmacion de acceso remoto P1-9
9  10        1  Template P1-10     Validacion de directorio interno P1-10
                                                  text  \
0  Actualizacion de cuenta corporativa P1-1. Se s...
1  Revision de acceso a VPN P1-2. Se solicita val...
2  Confirmacion de nomina interna P1-3. Se solici...
3  Verificacion de correo empresarial P1-4. Se so...
4  Politica nueva de seguridad P1-5. Se solicita ...
5  Portal de vacaciones y permisos P1-6. Se solic...
6  Actualizacion de beneficios internos P1-7. Se ...
7  Revision de firma electronica P1-8. Se solicit...
8  Confirmacion de acceso remoto P1-9. Se solicit...
9  Validacion de directorio interno P1-10. Se sol...
                                                  html       modified_date  \
0  <html><body><h2>Actualizacion de cuenta corpor... 2021-02-07 08:00:00
1  <html><body><h2>Revision de acceso a VPN P1-2<... 2021-02-14 08:00:00
2  <html><body><h2>Confirmacion de nomina interna... 2021-02-21 08:00:00
3  <html><body><h2>Verificacion de correo empresa... 2021-02-28 08:00:00
4  <html><body><h2>Politica nueva de seguridad P1... 2021-03-07 08:00:00
5  <html><body><h2>Portal de vacaciones y permiso... 2021-03-14 08:00:00
6  <html><body><h2>Actualizacion de beneficios in... 2021-03-21 08:00:00
7  <html><body><h2>Revision de firma electronica ... 2021-03-28 08:00:00
8  <html><body><h2>Confirmacion de acceso remoto ... 2021-04-04 08:00:00
9  <html><body><h2>Validacion de directorio inter... 2021-04-11 08:00:00
  envelope_sender
0            None
1            None
2            None
```

Tabla 1. Vista de `templates`. Sirve para confirmar que el campo `text` contiene contenido suficiente y semanticamente interpretable para el pipeline NLP.

2.2. Dataset maestro resultante de la integracion SQL

El notebook construye un dataset maestro mediante una consulta SQL que integra resultados de campaña, seguimiento de usuario, plantilla y solicitudes de correo. La logica es convertir un ecosistema de tablas transaccionales en una tabla analitica de grano fino: una fila por observacion de interaccion.

```
   result_id  campaign_id  user_id                       r_id  \
0          1            1     4393  RID000104393000001zhgGnGad
1          2            1      937  RID000100937000002H2tW3Q7K
2          3            1     2521  RID000102521000003W6F2zLQZ
3          4            1     4105  RID000104105000004zVlqsmwj
4          5            1     1225  RID000101225000005JEMdEMFB
                                   email first_name last_name  \
0          jose.fuentes4393@corp-demo.com       Jose   Fuentes
1        carmen.mendez937@ventas-demo.com     Carmen    Mendez
2  samuel.navarro2521@industrial-demo.com     Samuel   Navarro
3            diana.ruiz4105@corp-demo.com      Diana      Ruiz
4   ernesto.acosta1225@servicios-demo.com    Ernesto    Acosta
                     position result_status               ip  ...  \
0              Jefe de Taller  Email Opened   166.218.131.95  ...
1               Recepcionista  Email Opened   142.32.201.148  ...
2  Supervisor de Mantenimiento  Email Opened  197.170.111.248  ...
3          Tecnico de Soporte  Email Opened      64.1.36.163  ...
4        Asistente de Finanzas  Email Opened  117.130.146.252  ...
                        template_subject  \
0  Actualizacion de cuenta corporativa P1-1
1  Actualizacion de cuenta corporativa P1-1
2  Actualizacion de cuenta corporativa P1-1
3  Actualizacion de cuenta corporativa P1-1
4  Actualizacion de cuenta corporativa P1-1
                                     template_text template_modified_date  \
0  Actualizacion de cuenta corporativa P1-1. Se s...    2021-02-07 08:00:00
1  Actualizacion de cuenta corporativa P1-1. Se s...    2021-02-07 08:00:00
2  Actualizacion de cuenta corporativa P1-1. Se s...    2021-02-07 08:00:00
3  Actualizacion de cuenta corporativa P1-1. Se s...    2021-02-07 08:00:00
4  Actualizacion de cuenta corporativa P1-1. Se s...    2021-02-07 08:00:00
               from_address                           request_url  \
0  seguridad1@corp-demo.com  https://portal-1-001.demo.local/login
1  seguridad1@corp-demo.com  https://portal-1-001.demo.local/login
2  seguridad1@corp-demo.com  https://portal-1-001.demo.local/login
3  seguridad1@corp-demo.com  https://portal-1-001.demo.local/login
```

Tabla 2. Muestra del dataset maestro. Se observan identificadores, variables de campaña, usuario, `r_id` de seguimiento y el estado real de interaccion.

2.3. Tabla de clasificacion textual

La tabla `text_clasification` funciona como un lexicon etiquetado. Asocia palabras y frases con contexto, subcontexto, riesgo, tipo de mensaje y señales binarias como urgencia o presencia de credenciales. En terminos metodologicos, es un conocimiento experto externalizado en forma de datos.

	word	doc_count	doc_ratio
0	en	7344	0.550525
1	el	7097	0.532009
2	de	5285	0.396177
3	enlace	4888	0.366417
4	institucional	4408	0.330435
5	este	4294	0.321889
6	desde	4294	0.321889
7	con	4294	0.321889
8	relacionado	3700	0.277361
9	tu	2747	0.205922
10	antes	2387	0.178936
11	para	2376	0.178111
12	a	2256	0.169115
13	la	2040	0.152924
14	portal	1855	0.139055
15	plataforma	1648	0.123538
16	las	1560	0.116942
17	sistema	1483	0.111169
18	acceso	1420	0.106447
19	oficial	1356	0.101649
20	del	1319	0.098876
21	solicitud	1223	0.091679
22	se	1188	0.089055
23	cuenta	1109	0.083133
24	aplicacion	1052	0.078861
25	sitio	1026	0.076912
26	web	1026	0.076912
27	correo	1010	0.075712
28	pago	991	0.074288
29	gestiona	957	0.071739

Tabla 3. Frecuencia documental de terminos. Este resumen permite identificar vocabulario muy comun y separar tokens poco informativos de tokens discriminantes.

2.4. Dataset final para modelado

Una vez enriquecidos los registros, el notebook conforma un dataset final para entrenamiento. Aqui conviven texto consolidado, banderas semanticas, riesgo, contexto y la variable objetivo.

	text_full	risk_flag	urgent_flag	\
0	actualizacion de cuenta corporativa p1 1 actua...	1	1	
1	actualizacion de cuenta corporativa p1 1 actua...	1	1	
2	actualizacion de cuenta corporativa p1 1 actua...	1	1	
3	actualizacion de cuenta corporativa p1 1 actua...	1	1	
4	actualizacion de cuenta corporativa p1 1 actua...	1	1	

	credentials_flag	context_detected	risk_level	result_status
0	0	Administrativo	Medio	Email Opened
1	0	Administrativo	Medio	Email Opened
2	0	Administrativo	Medio	Email Opened
3	0	Administrativo	Medio	Email Opened
4	0	Administrativo	Medio	Email Opened

Tabla 4. Muestra del dataset final preparado para ML. Las columnas combinan texto, banderas y atributos derivados.

3. Explicacion del codigo por etapas

3.1 Inspeccion y conexion

Los primeros bloques abren la conexion a MySQL y realizan consultas exploratorias. La idea no es solo leer datos, sino validar que las columnas necesarias existen y que los tipos son compatibles con el flujo posterior.

3.2 Construccion del dataset maestro

La consulta SQL une `results`, `email_requests`, plantillas y metadatos. El principio de diseño es formar una tabla denormalizada para analitica. Este paso ahorra complejidad en las fases posteriores y reduce dependencias dispersas.

3.3 Normalizacion textual

Se aplican transformaciones como minusculas, eliminacion de acentos y homogeneizacion de espacios. En NLP esto reduce la variabilidad superficial y evita que terminos equivalentes se traten como diferentes.

3.4 Diccionario semantico y matcher

El notebook transforma la tabla `text_clasification` en estructuras indexadas. Luego define funciones que comparan el texto real del correo con palabras y frases etiquetadas. Este bloque corresponde a un enfoque rule-based, util cuando se desea interpretabilidad.

3.5 Enriquecimiento del dataset

Cada mensaje se convierte en un vector de rasgos: contexto detectado, nivel de riesgo, urgencia, solicitud de accion, URL, credenciales y score de coincidencia. En ciencia de datos, esta fase es ingenieria de caracteristicas.

3.6 Modelado supervisado

El pipeline usa `TfidfVectorizer` para el texto, codificacion one-hot para variables categoricas y `LogisticRegression` para clasificar `result_status`. La implementacion se hace con `Pipeline` y `ColumnTransformer`, lo que garantiza reproducibilidad.

3.7 Evaluacion y almacenamiento

Una vez entrenado el modelo, el notebook calcula accuracy, precision, recall, F1 y matriz de confusion. Despues guarda el modelo con `joblib` y registra metadata del experimento en MySQL.

3.8 Dashboard y reporteria

Finalmente, se construyen tablas y graficos de distribucion, comparacion real-vs-predicho, riesgo agregado y predicciones a seis meses.

4. Modelos, calculos y conceptos estadisticos

4.1 TF-IDF

El texto de las plantillas no se usa directamente. Primero se vectoriza con TF-IDF. La intuicion es que una palabra importa mas si aparece con frecuencia en un documento pero no en todos los documentos.

Formula general: TF-IDF(t,d) = TF(t,d) x log(N / DF(t)). Aqui `TF` es la frecuencia del termino en el documento, `N` es el numero total de documentos y `DF` es el numero de documentos que contienen el termino.

4.2 Regresion logistica multiclase

El clasificador final es regresion logistica. Este modelo estima probabilidades por clase a partir de una combinacion lineal de variables. En binario, la funcion base es la sigmoide p = 1 / (1 + e^(-z)); en multiclase se generaliza mediante softmax.

4.3 Train/test split

El dataset se divide en entrenamiento y prueba. Esta separacion permite aproximar el error de generalizacion: se entrena en una parte y se valida en otra que el modelo no vio durante el ajuste.

4.4 Matriz de confusion y metricas

La matriz de confusion muestra aciertos y errores por clase. A partir de ella se derivan metricas como precision, recall y F1-score. En problemas con clases desbalanceadas, estas metricas aportan mas informacion que la accuracy por si sola.

4.5 Riesgo generalizado

En varios graficos el notebook transforma estados de interaccion en un puntaje de severidad. Por ejemplo: Email Sent = 1, Email Opened = 2, Clicked Link = 3, Submitted Data = 4. Luego calcula un promedio ponderado por porcentaje, obteniendo un score resumen interpretable.

4.6 Proyeccion temporal

Las predicciones a seis meses combinan nivel reciente, tendencia, estacionalidad aproximada y ruido residual controlado. Despues convierten la salida a porcentajes por mes y por nivel de riesgo.

5. Lectura de tablas y graficos para presentacion

Esta seccion resume el significado de las salidas visuales mas importantes. Cada figura puede usarse como una diapositiva o como soporte visual en la defensa del proyecto.

Distribucion de estados finales

Resume la frecuencia observada de estados finales. El mensaje para presentacion es: cual es la interaccion dominante en el conjunto historico y que tan frecuente es la entrega, apertura, clic o envio de datos.

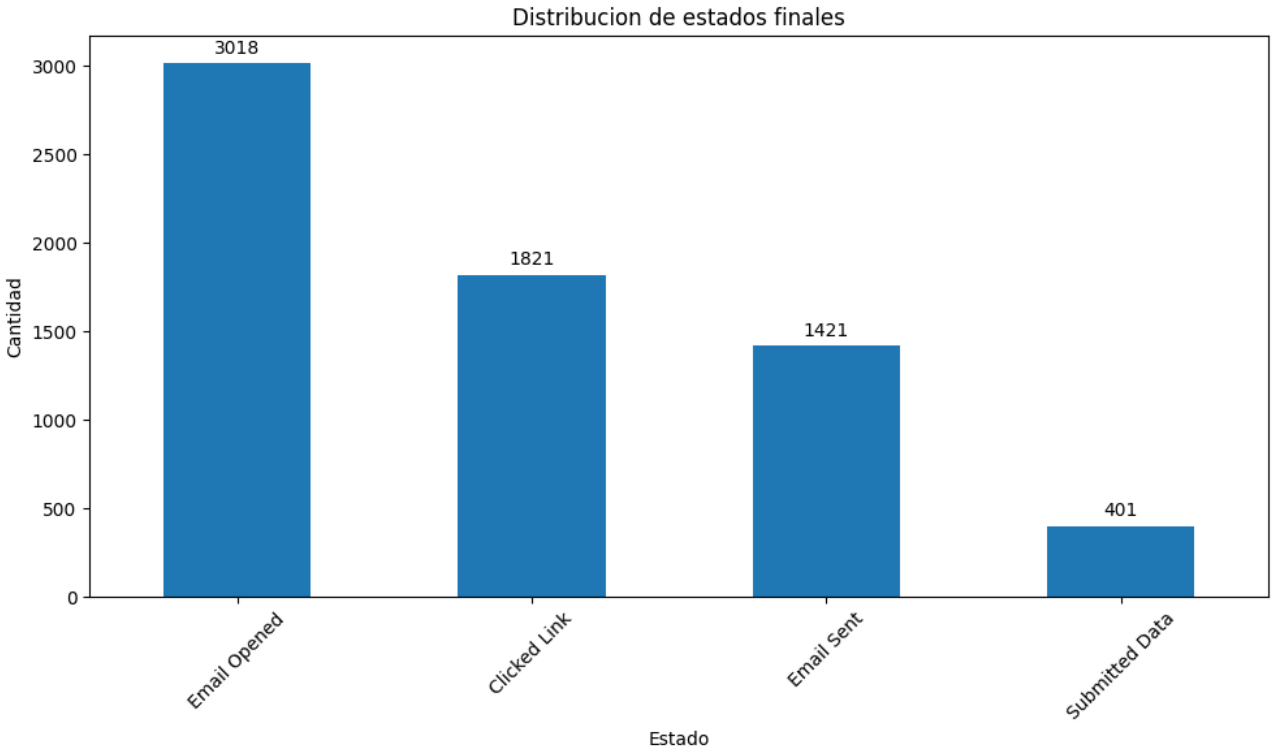

Figura. Distribucion de estados finales.

Distribucion de niveles de riesgo

Muestra la composicion del corpus por nivel de riesgo. Es clave para discutir balance de clases y predominio de riesgo medio.

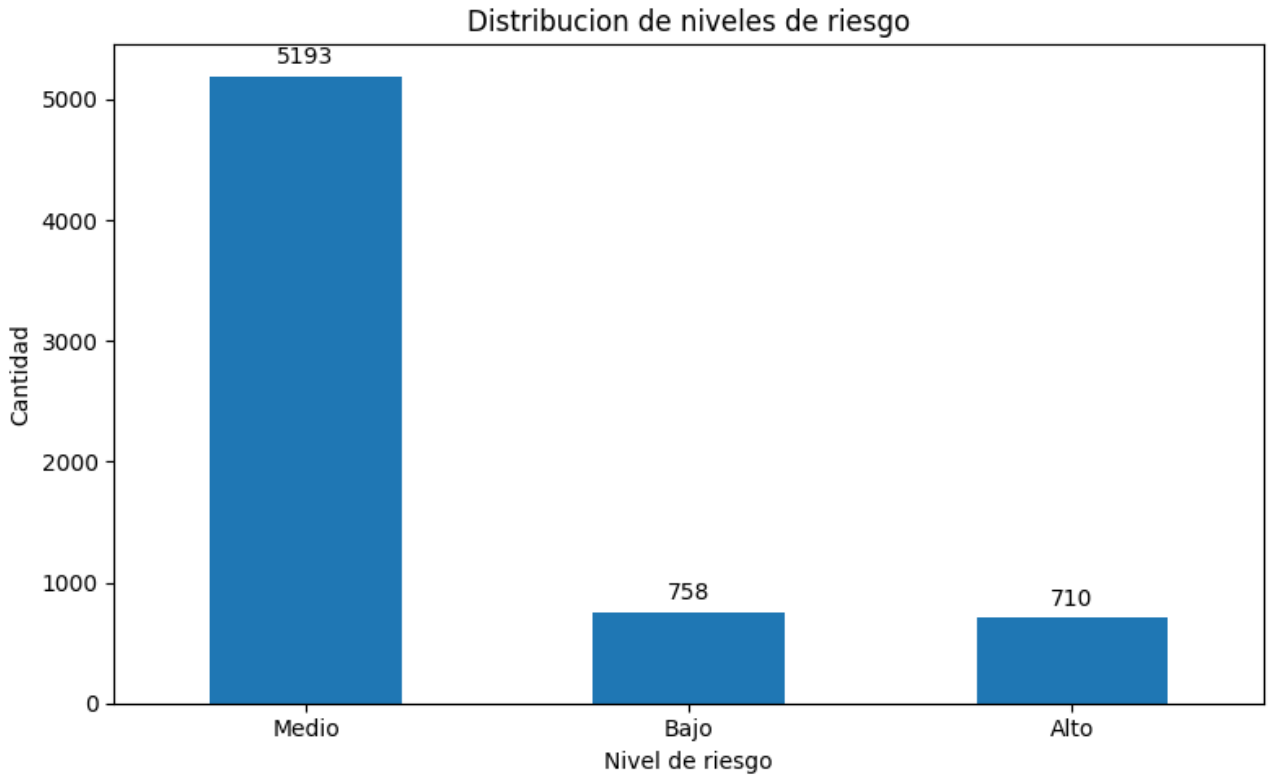

Figura. Distribucion de niveles de riesgo.

Mensajes con bandera de riesgo

Indica cuantos mensajes presentan una bandera semantica de riesgo. Se interpreta como una primera señal de severidad textual.

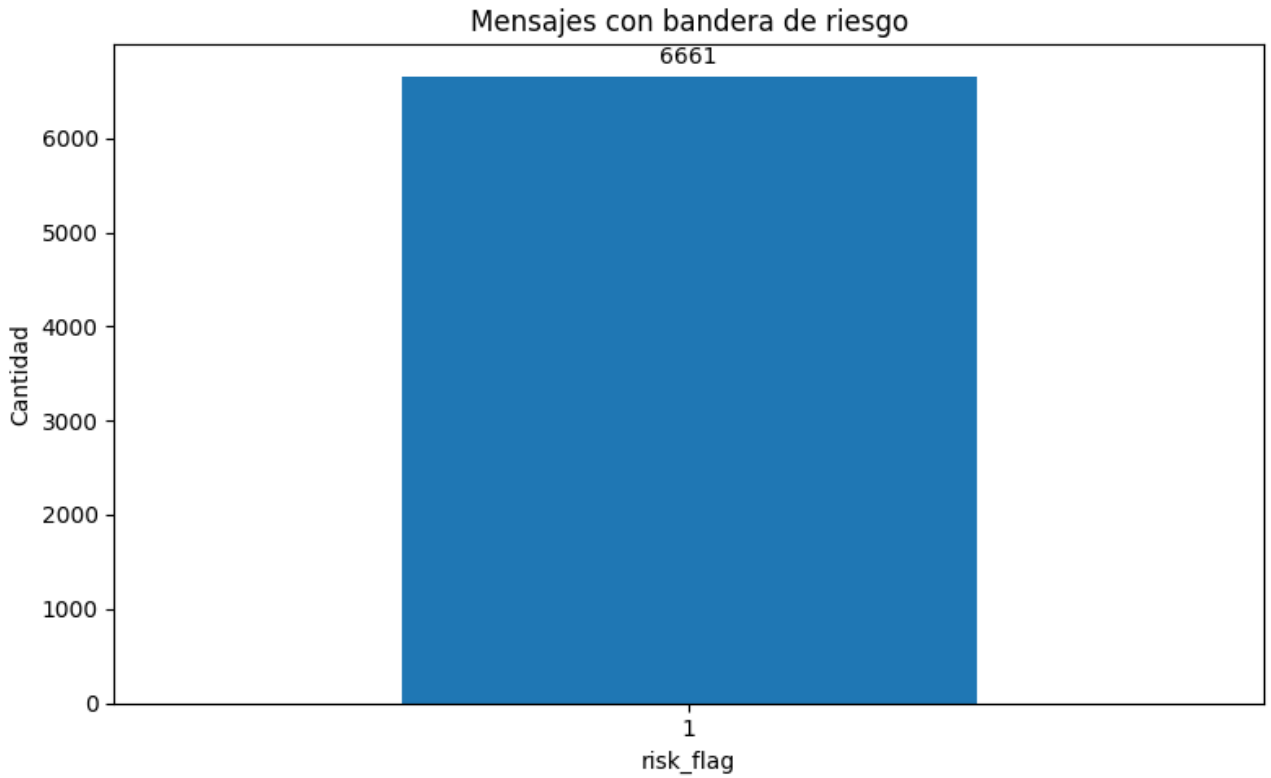

Figura. Mensajes con bandera de riesgo.

Mensajes con urgencia detectada

Cuantifica urgencia detectada. En phishing, la urgencia actua como disparador conductual y por eso se incorpora como feature.

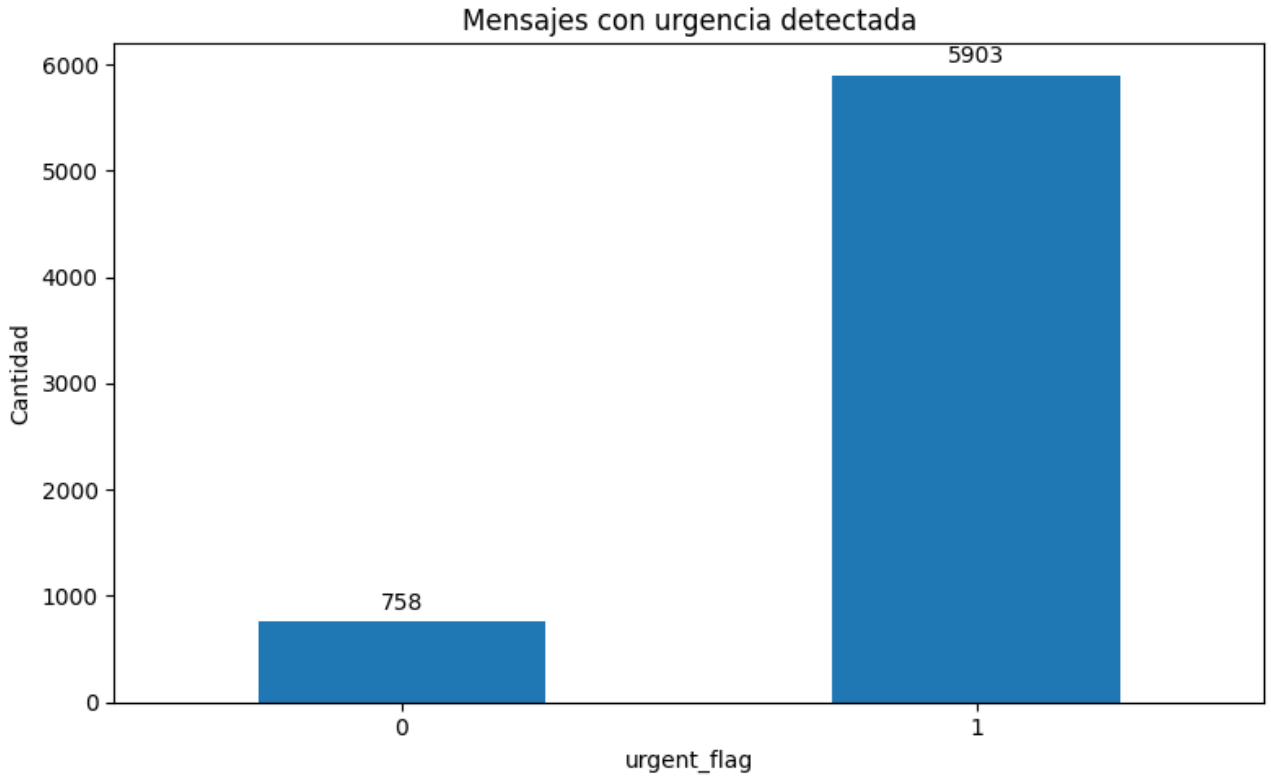

Figura. Mensajes con urgencia detectada.

Mensajes con solicitud de credenciales

Resume solicitudes de credenciales. Esta bandera es una de las señales mas sensibles dentro de un correo malicioso.

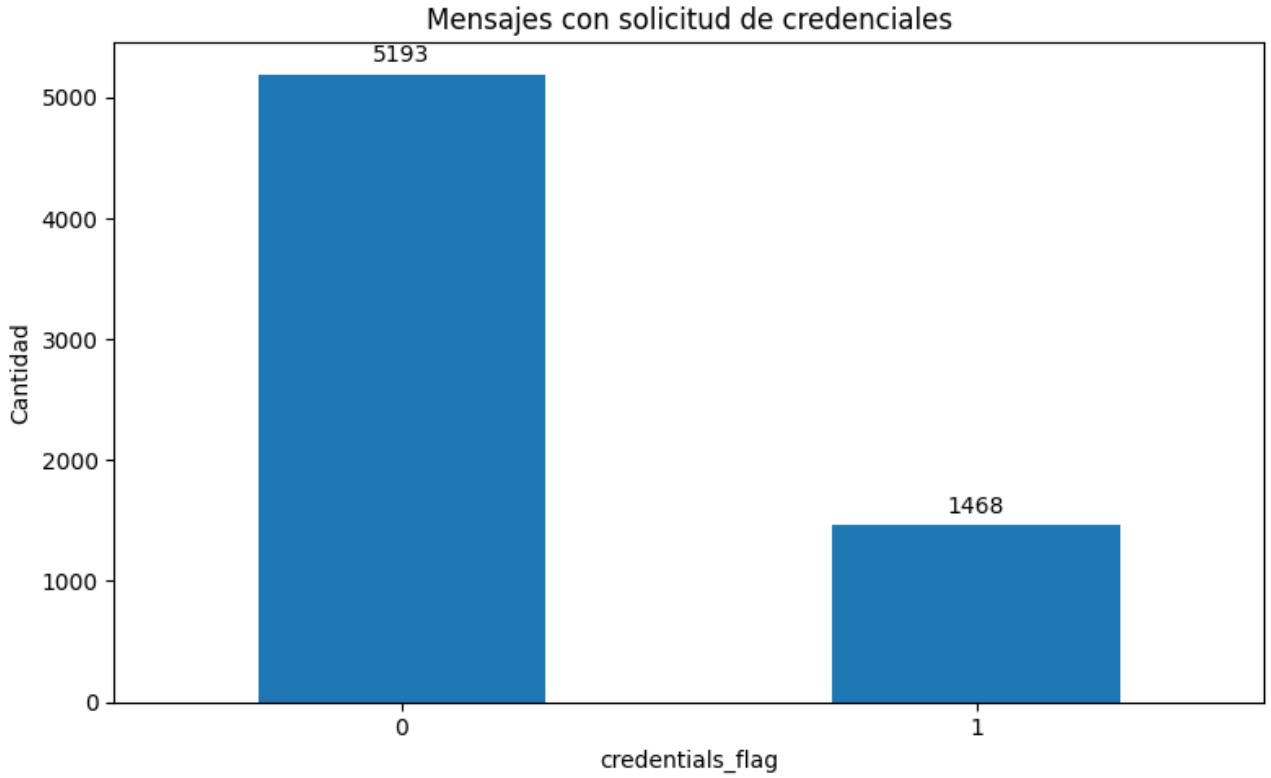

Figura. Mensajes con solicitud de credenciales.

Contextos detectados en los mensajes

Distribuye los contextos detectados. Permite explicar en que dominios semanticos se concentra la campaña, por ejemplo academico, bancario o administrativo.

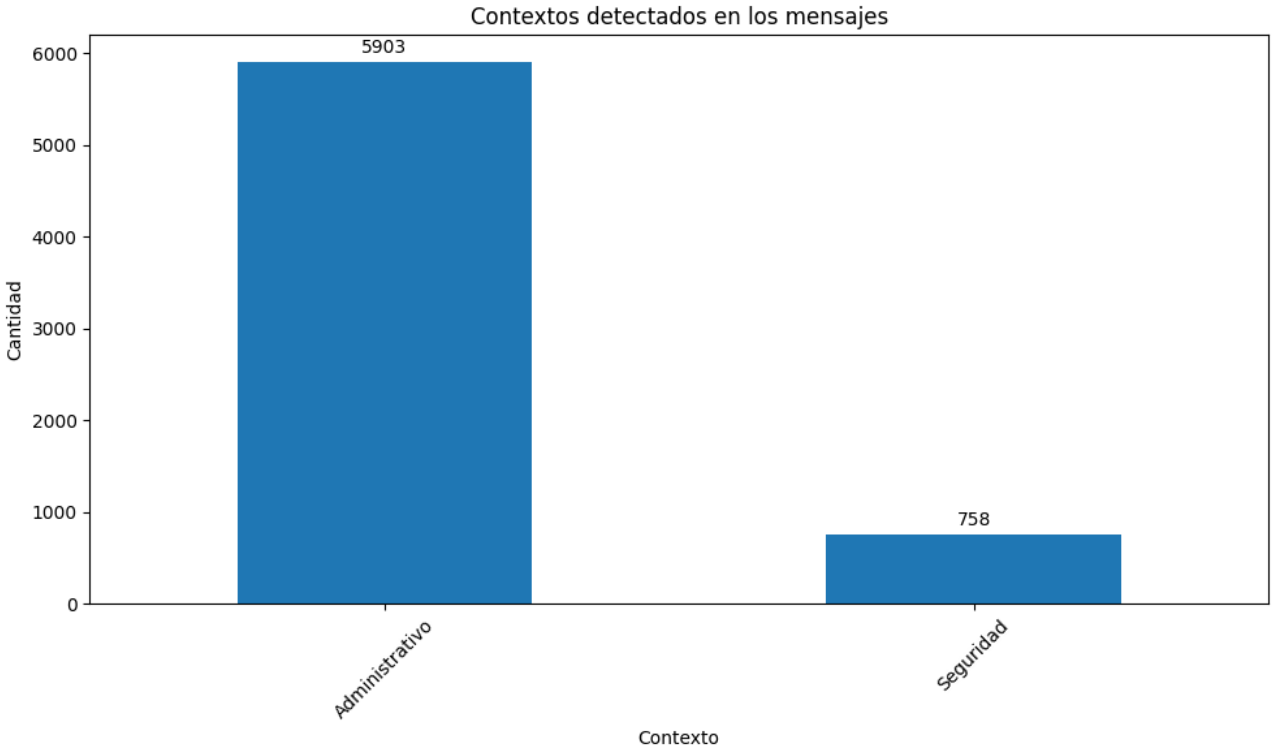

Figura. Contextos detectados en los mensajes.

Top 10 campañas por volumen de interacciones

Identifica campañas con mayor volumen de interacciones, util para priorizar analisis o controles.

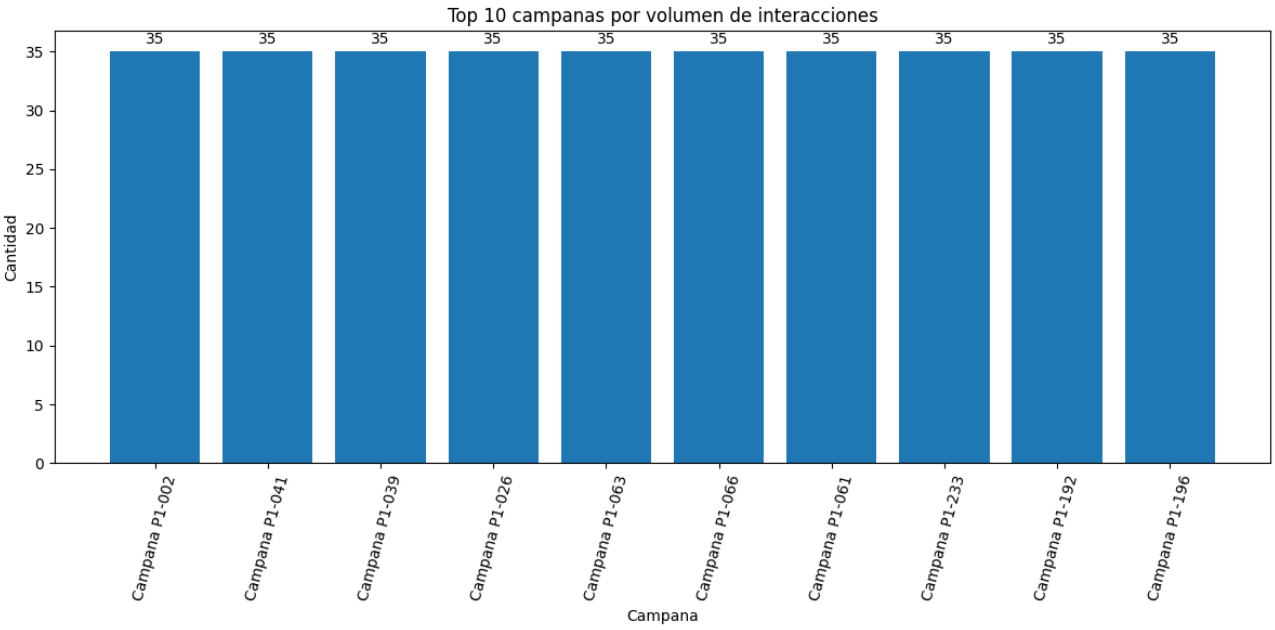

Figura. Top 10 campañas por volumen de interacciones.

Distribucion de riesgo por contexto detectado

Cruza contexto y riesgo, mostrando que ciertos contextos concentran niveles mas altos de severidad.

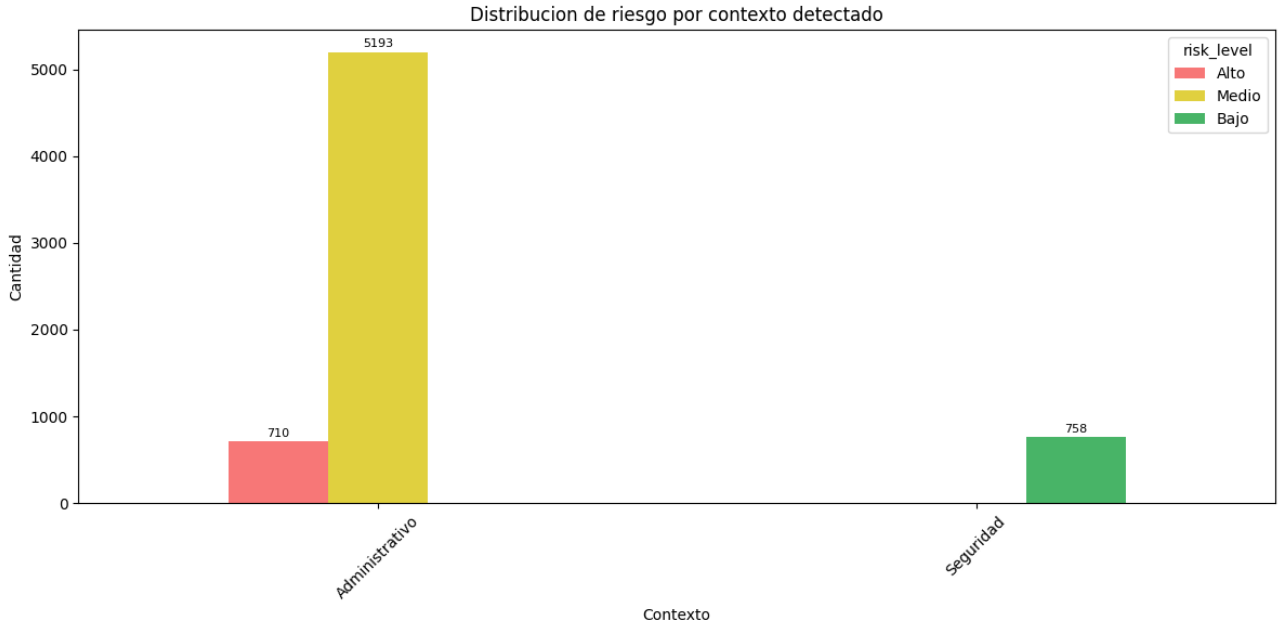

Figura. Distribucion de riesgo por contexto detectado.

Distribucion de match_score

Muestra el puntaje de coincidencia textual. Sirve para justificar los umbrales de riesgo derivados del match_score.

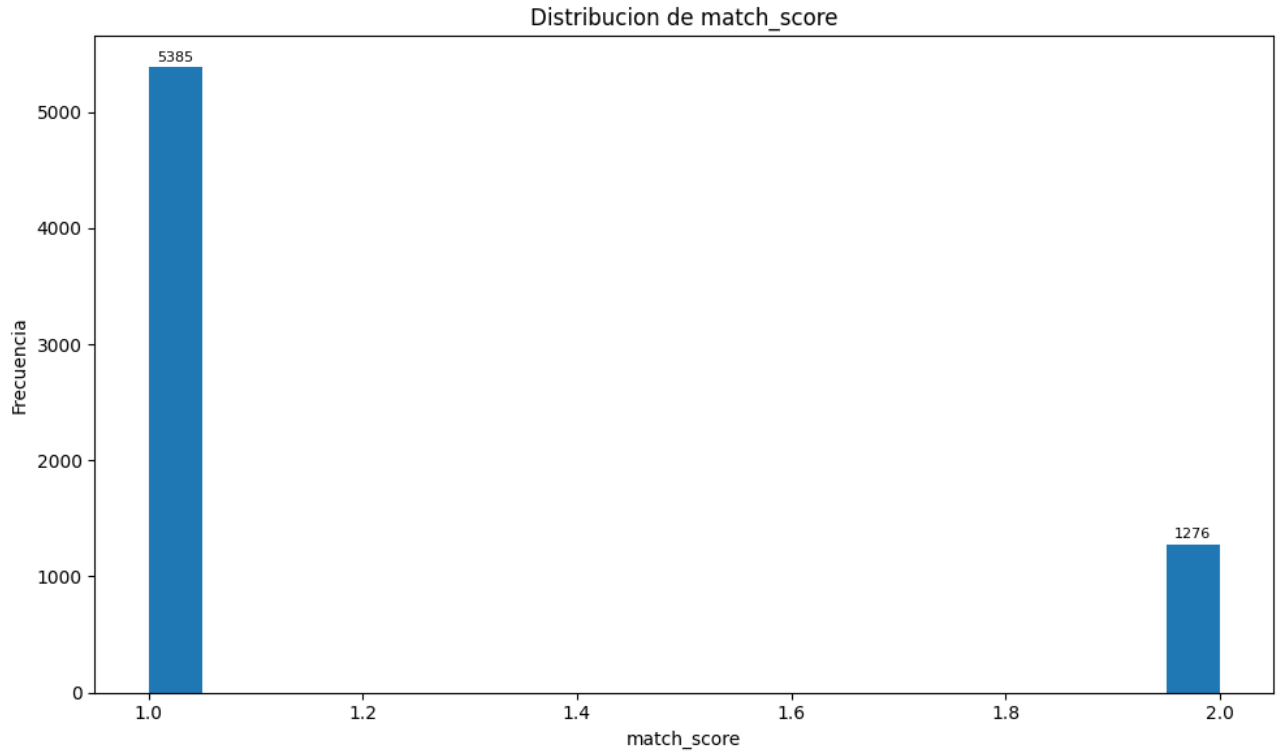

Figura. Distribucion de match_score.

Distribucion de estados predichos

Distribucion de clases predichas por el modelo. Es la fotografia general de salida del clasificador.

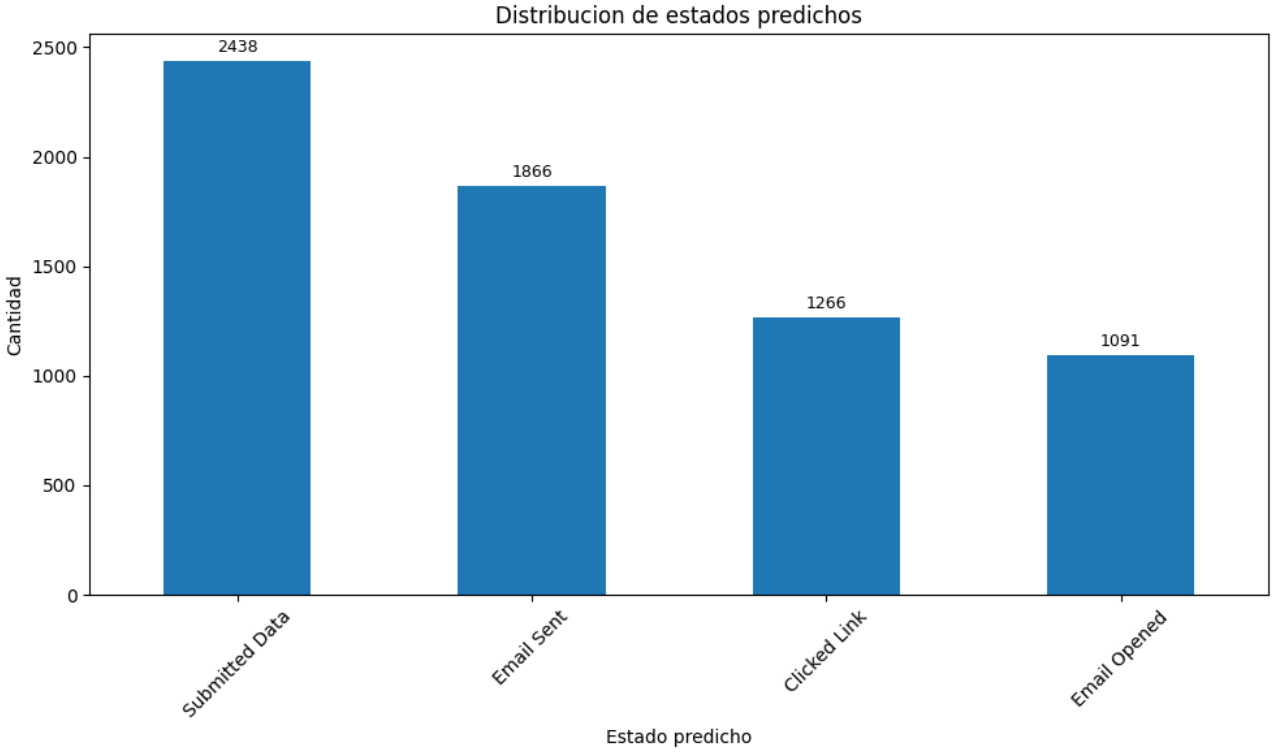

Figura. Distribucion de estados predichos.

Porcentaje de niveles de riesgo por estado

Compara proporciones de riesgo por estado real. Se interpreta mejor que los conteos cuando los grupos tienen tamanos distintos.

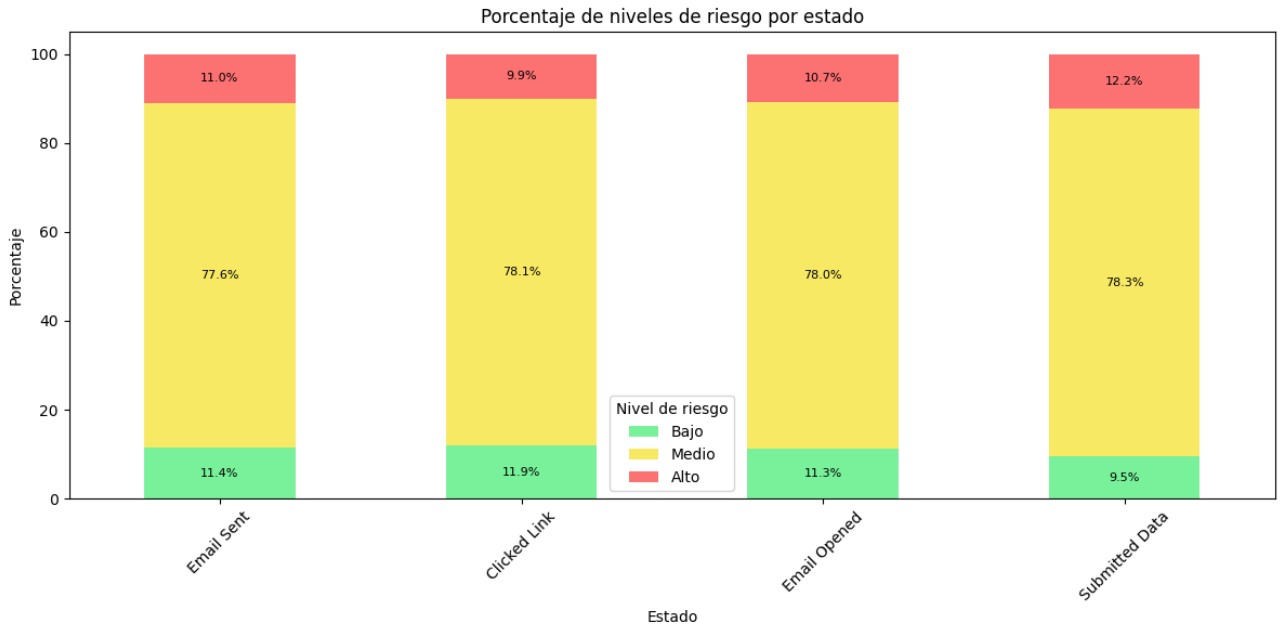

Figura. Porcentaje de niveles de riesgo por estado.

Estados actuales por nivel de riesgo

Distribucion real de estados dentro de cada riesgo. Ayuda a explicar el cambio de comportamiento del usuario conforme crece la severidad.

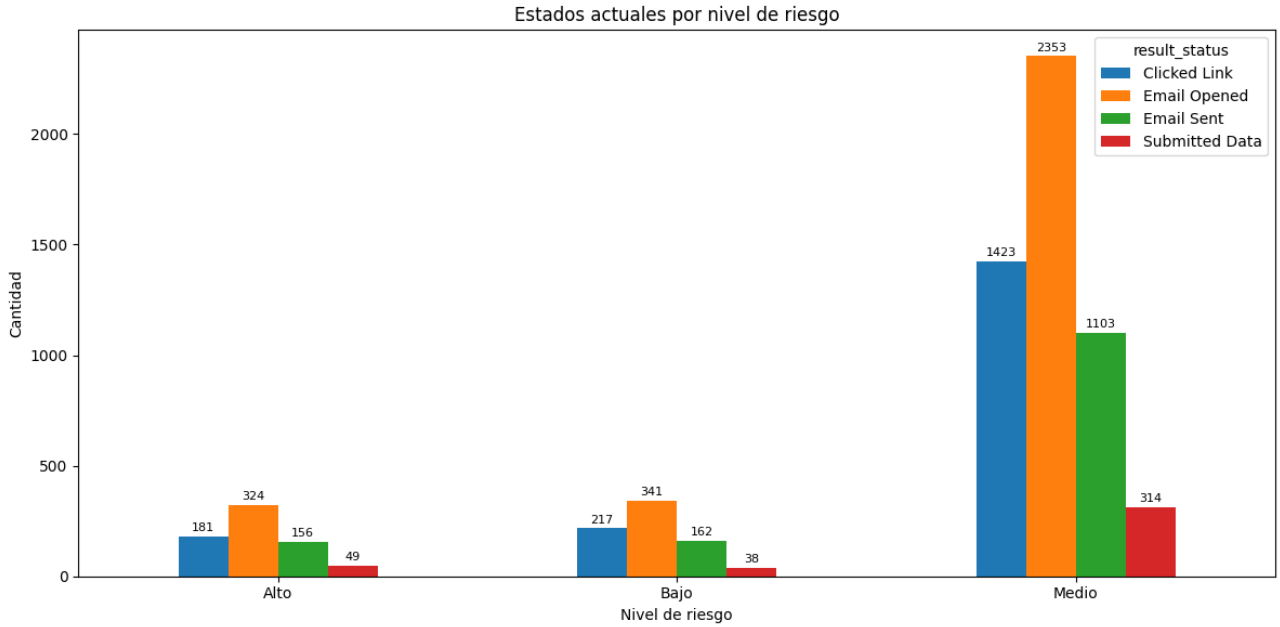

Figura. Estados actuales por nivel de riesgo.

Estados predichos por nivel de riesgo

Distribucion predicha de estados dentro de cada riesgo. Es la contrapartida modelada del grafico anterior.

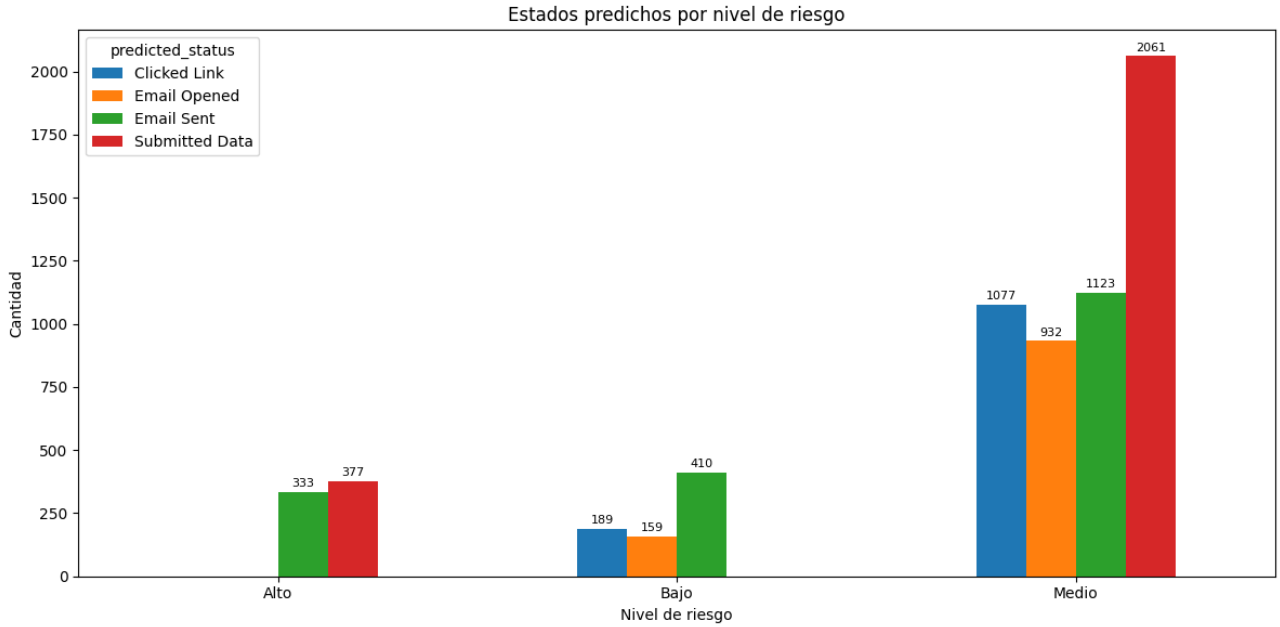

Figura. Estados predichos por nivel de riesgo.

Estados predichos por contexto detectado

Cruza contexto detectado y estados predichos. Muy util para narrativa causal o semantica.

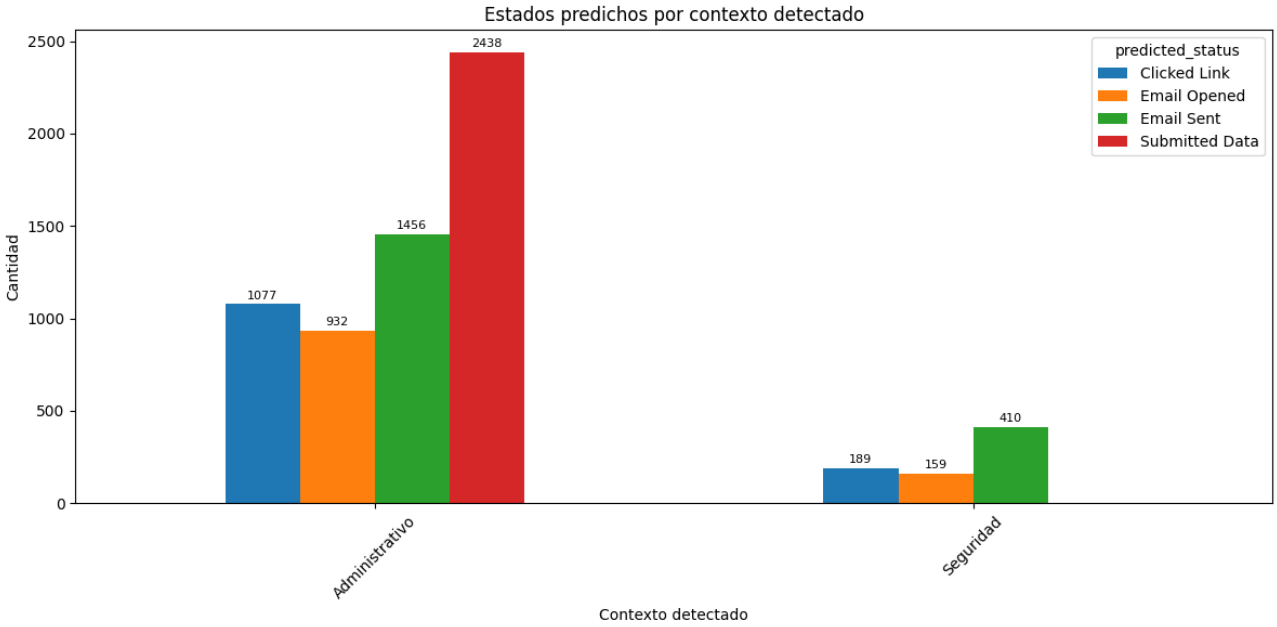

Figura. Estados predichos por contexto detectado.

Distribucion de confianza de las predicciones

Histograma de confianza. Permite hablar de calibracion, seguridad del modelo e incertidumbre.

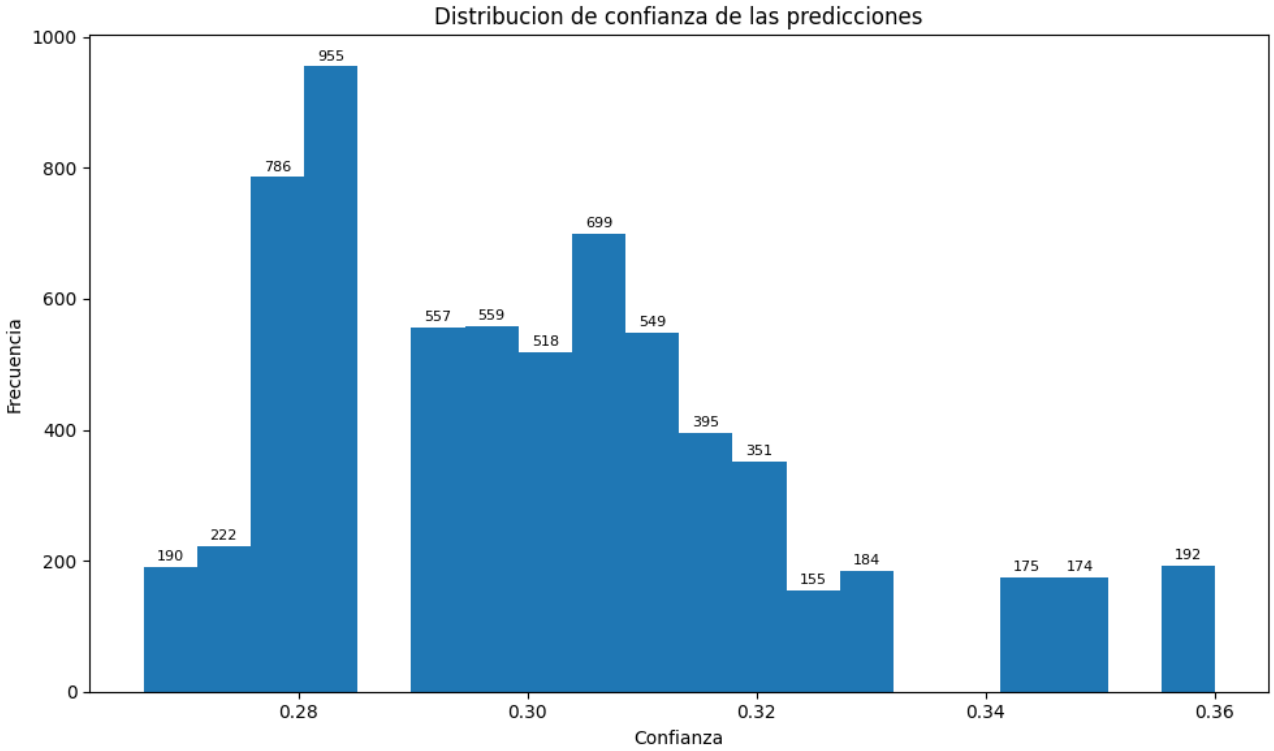

Figura. Distribucion de confianza de las predicciones.

Top 10 campañas por volumen de predicciones

Top de campañas por volumen de predicciones. Aporta lectura operativa.

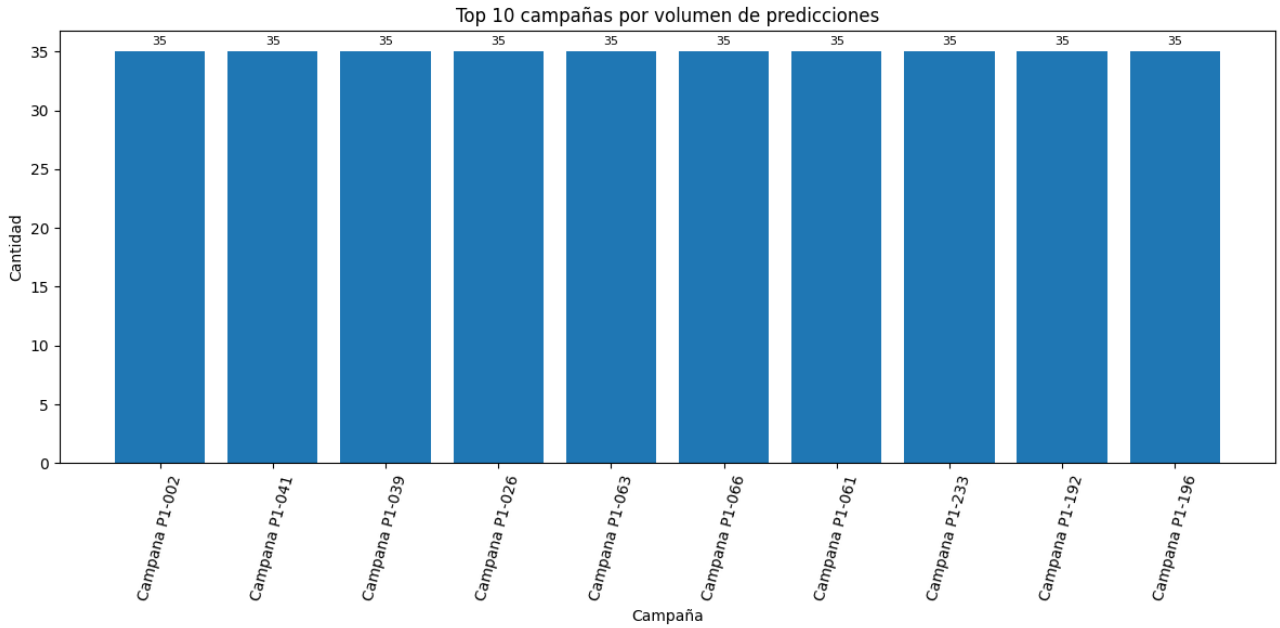

Figura. Top 10 campañas por volumen de predicciones.

Estados actuales por nivel de riesgo (%)

Version porcentual de estados reales por riesgo. Facilita comparacion entre grupos.

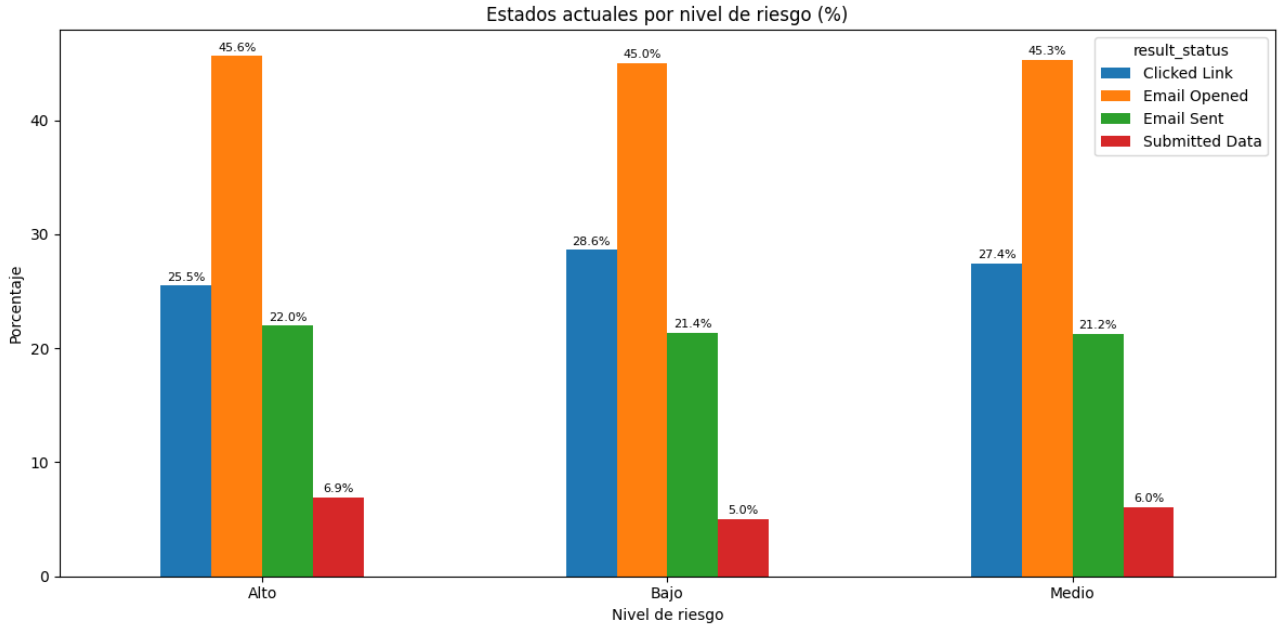

Figura. Estados actuales por nivel de riesgo (%).

Estados predichos por nivel de riesgo (%)

Version porcentual de estados predichos por riesgo.

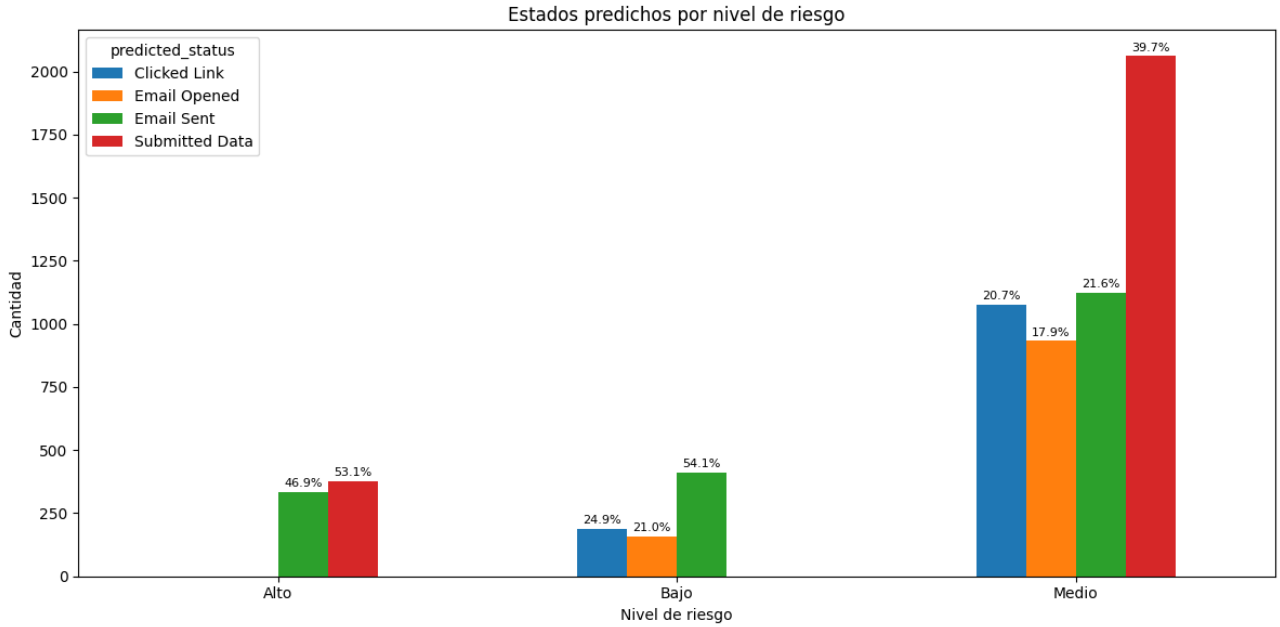

Figura. Estados predichos por nivel de riesgo (%).

Tendencia del riesgo general actual vs predicho

Tendencia del riesgo general actual vs predicho. Se interpreta como una sintesis ejecutiva del comportamiento observado y estimado.

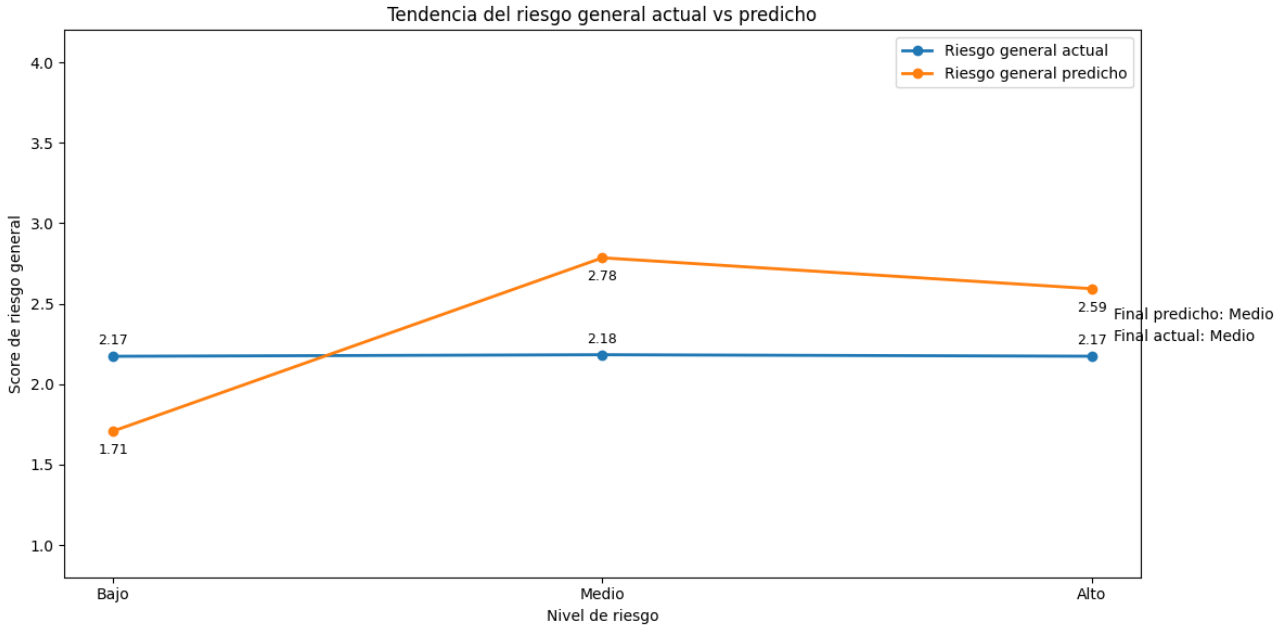

Figura. Tendencia del riesgo general actual vs predicho.

Real vs Prediccion de palabras/frases mas utilizadas segun el riesgo

Relaciona riesgo con palabras o frases dominantes. Es un puente entre NLP y visualizacion semantica.

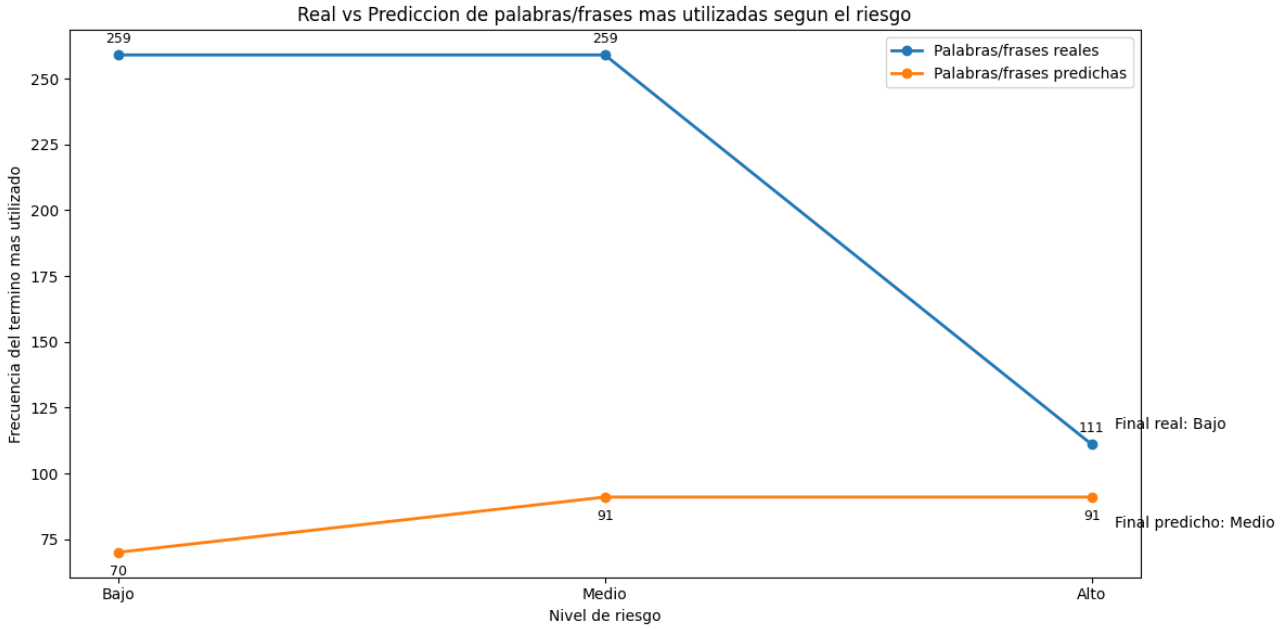

Figura. Real vs Prediccion de palabras/frases mas utilizadas segun el riesgo.

Real vs Prediccion de palabras/frases mas utilizadas segun el riesgo (version consolidada)

Version consolidada del analisis de terminos dominantes por riesgo.

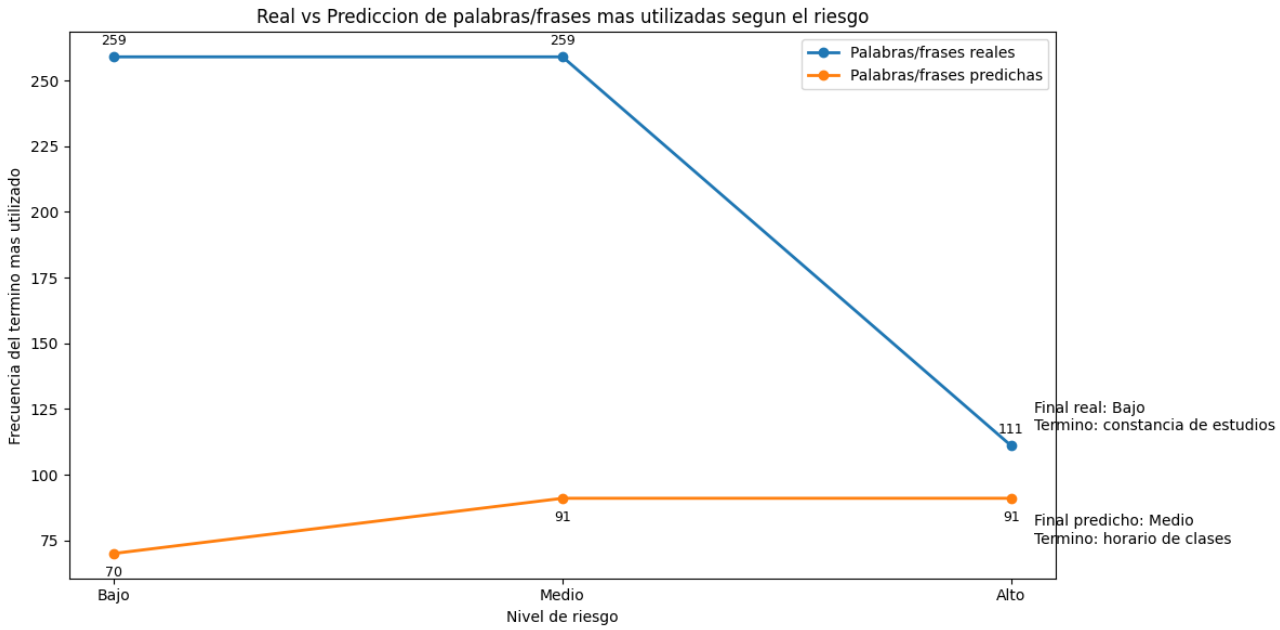

Figura. Real vs Prediccion de palabras/frases mas utilizadas segun el riesgo (version consolidada).

Tendencia del riesgo por puntos: real vs predicho

Riesgo por puntos con terminos. Convierte la frecuencia en severidad acumulada.

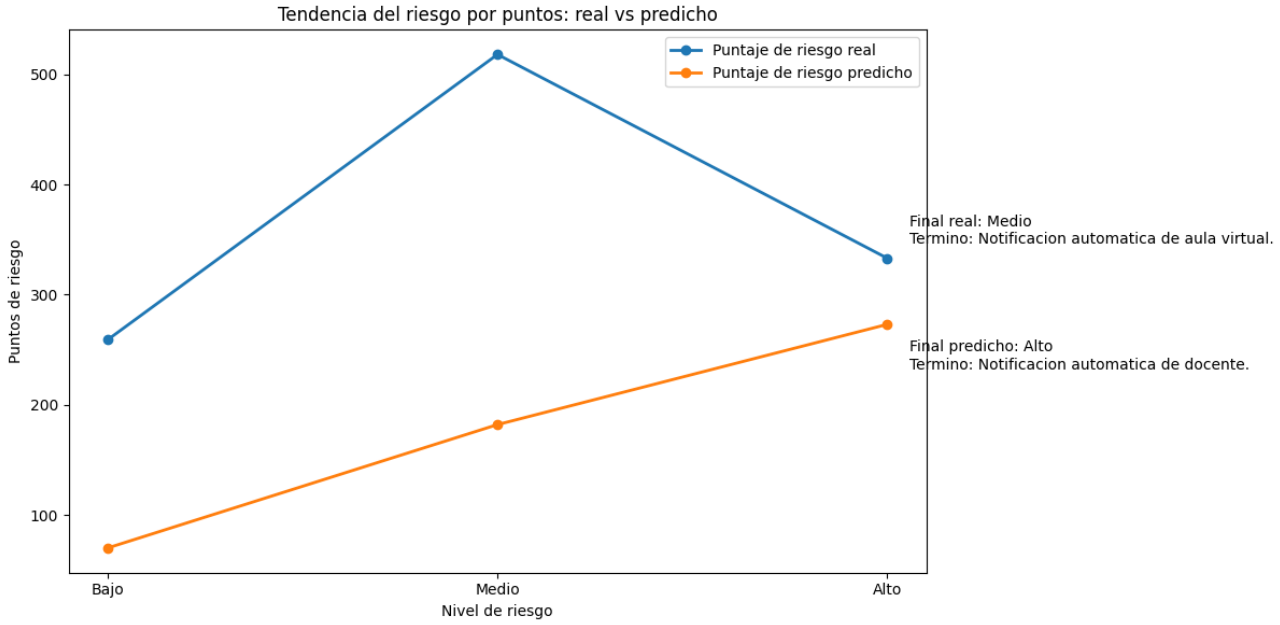

Figura. Tendencia del riesgo por puntos: real vs predicho.

Tendencia del riesgo por puntaje promedio: real vs predicho

Riesgo por puntaje promedio. Esta version normaliza el indicador y facilita comparaciones estables.

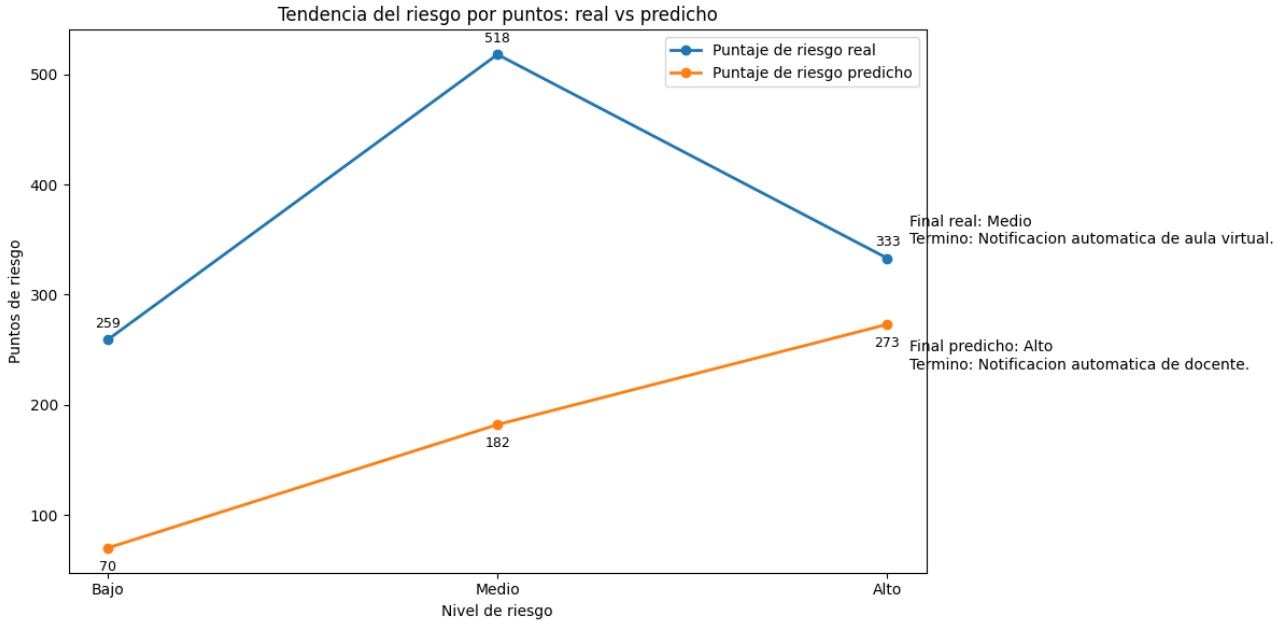

Figura. Tendencia del riesgo por puntaje promedio: real vs predicho.

Riesgo segun contexto actual vs predicho

Compara riesgo por contexto actual vs predicho. Ayuda a explicar que dominios semanticos son mas peligrosos.

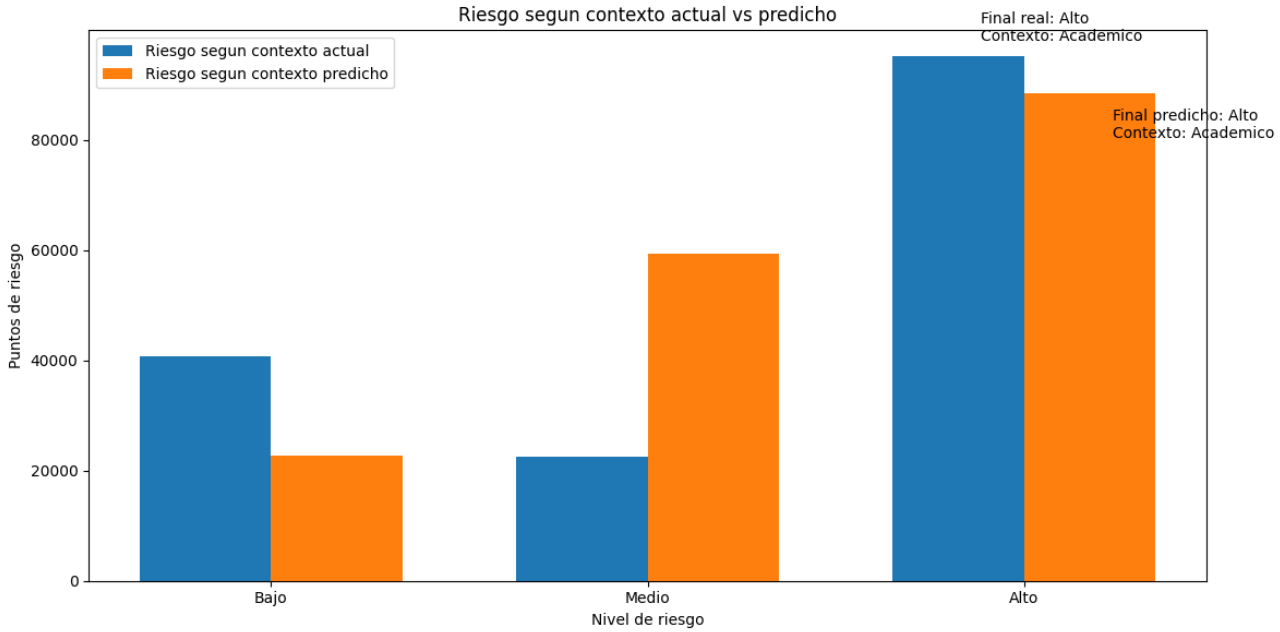

Figura. Riesgo segun contexto actual vs predicho.

Prediccion a 6 meses (%) de usuarios que abriran emails segun nivel de riesgo

Proyeccion porcentual a seis meses de aperturas por riesgo.

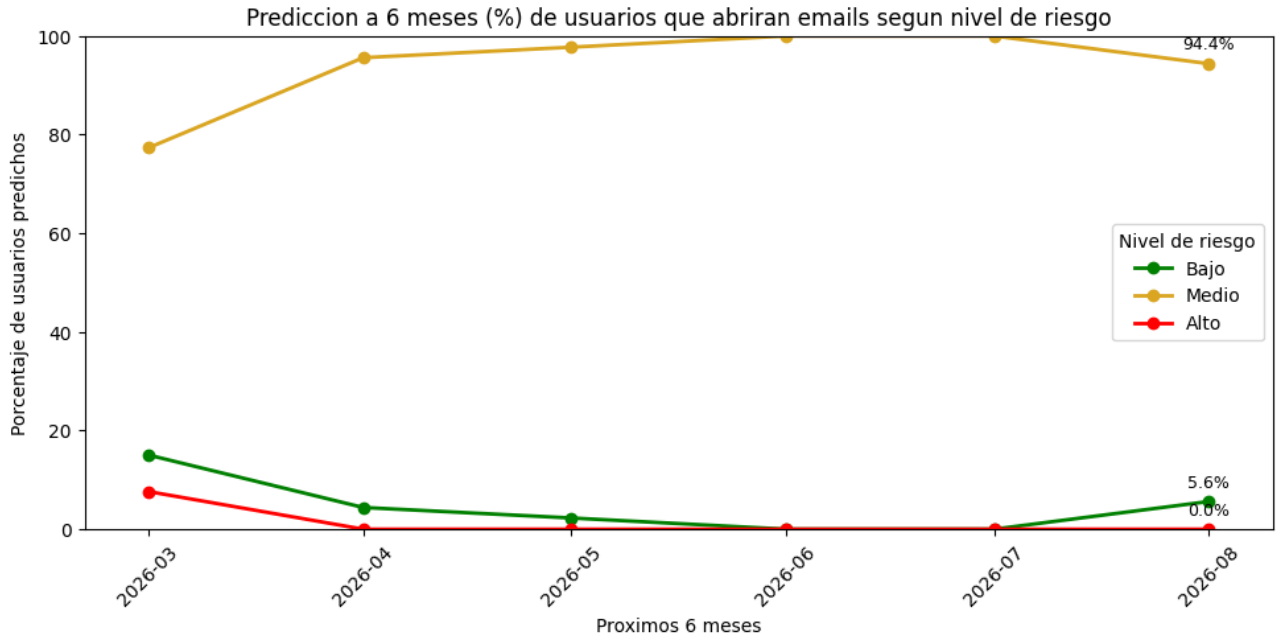

Figura. Prediccion a 6 meses (%) de usuarios que abriran emails segun nivel de riesgo.

Prediccion a 6 meses (%) de usuarios que haran click en enlaces segun nivel de riesgo

Proyeccion porcentual a seis meses de clics por riesgo.

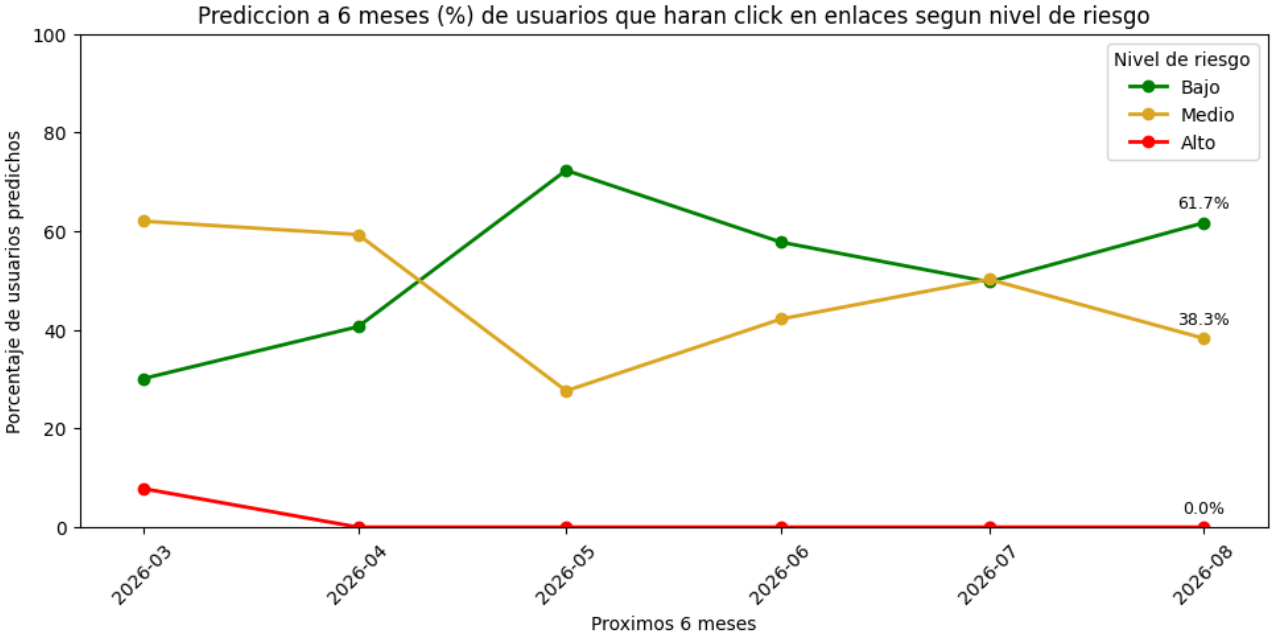

Figura. Prediccion a 6 meses (%) de usuarios que haran click en enlaces segun nivel de riesgo.

Prediccion a 6 meses (%) de usuarios que ingresaran informacion segun nivel de riesgo

Proyeccion porcentual a seis meses de envios de informacion por riesgo.

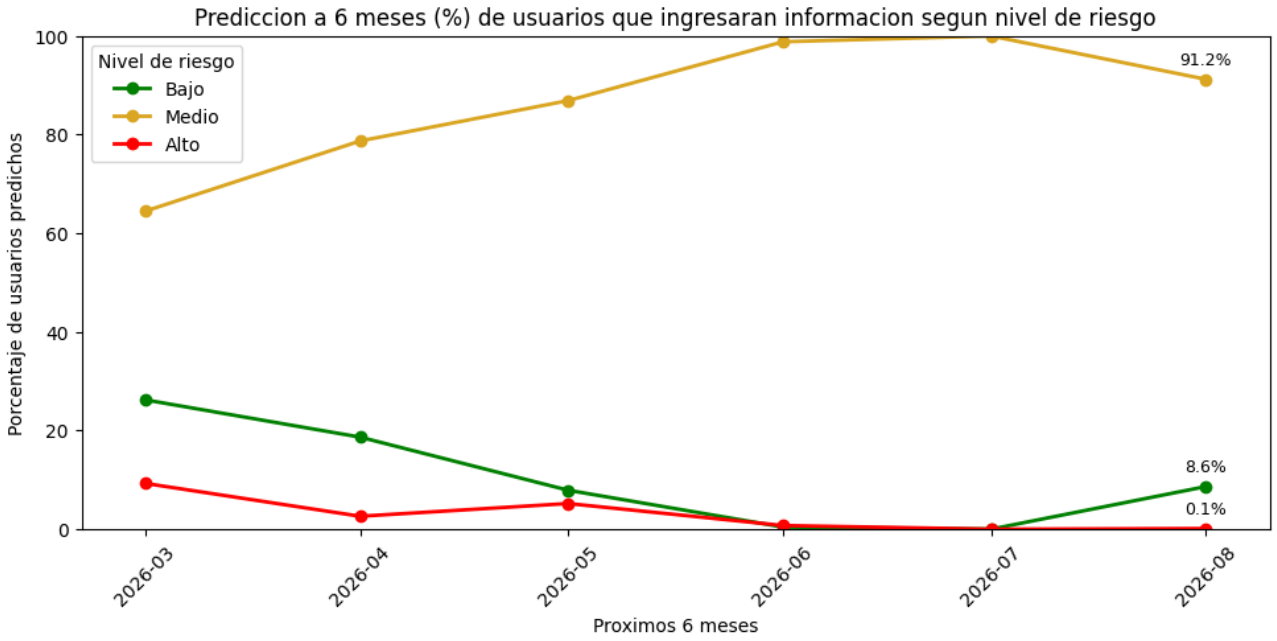

Figura. Prediccion a 6 meses (%) de usuarios que ingresaran informacion segun nivel de riesgo.

Prediccion a 6 meses (%) de usuarios que reportaran emails segun nivel de riesgo

Proyeccion porcentual a seis meses de reportes por riesgo.

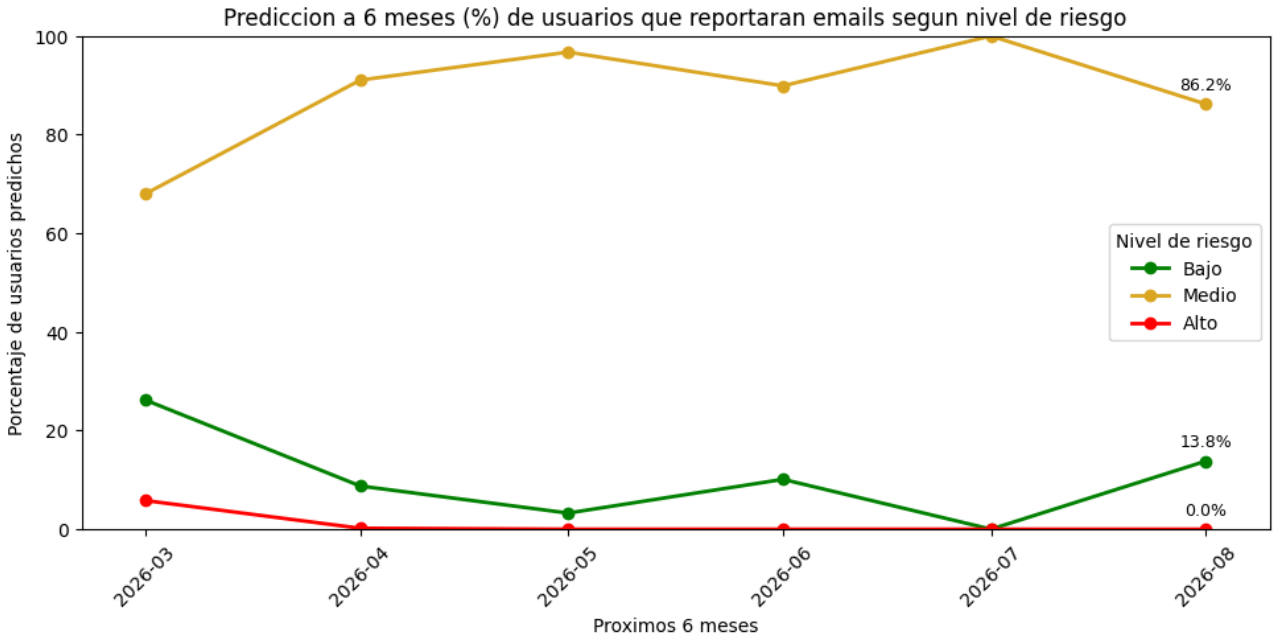

Figura. Prediccion a 6 meses (%) de usuarios que reportaran emails segun nivel de riesgo.

6. Paradigmas utilizados

El notebook mezcla cuatro paradigmas complementarios. Primero, analitica descriptiva: tablas, distribuciones y cruces para comprender el fenomeno. Segundo, ingenieria semantica basada en reglas: el diccionario de clasificacion y las banderas expertas. Tercero, aprendizaje supervisado: un clasificador

multiclase entrenado con ejemplos etiquetados. Cuarto, proyeccion exploratoria temporal: estimaciones a seis meses para abrir espacio a escenarios futuros.

Desde el punto de vista epistemologico, el cuaderno es hibrido y pragmatico. No depende de un unico modelo end-to-end, sino que integra conocimiento experto con modelos estadisticos. Esto es especialmente valioso cuando se requiere interpretabilidad, defensa academica y trazabilidad.

7. Conclusiones para exposicion

La contribucion principal del notebook es transformar datos operativos de GoPhish en un sistema analitico interpretable. El proyecto no solo clasifica estados de interaccion; tambien explica por que el riesgo es alto o bajo a traves de contexto, terminos, banderas y scores.

En una presentacion, el hilo conductor recomendado es: primero validar estructura y calidad de datos; despues mostrar como el texto se convierte en variables; luego explicar el pipeline de ML; finalmente presentar resultados, graficos de riesgo y proyecciones.

En terminos de valor academico, el trabajo demuestra integracion entre bases de datos, NLP, aprendizaje supervisado, visualizacion y razonamiento de riesgo. En terminos practicos, proporciona una base replicable para monitoreo y deteccion de patrones de ingenieria social.