DOSSIER ANALITICO

REPORTE TECNICO EXHAUSTIVO DEL NOTEBOOK

Explicacion de codigo, terminos especializados, tablas, graficas y hallazgos

Estetica documental sobria de expediente tecnico institucional

Archivo analizado: test_002_refinado_documentado_tesis_comentado_final_sin_reg_lineal(2).ipynb

Documento tecnico generado a partir del notebook adjunto

1. Resumen ejecutivo

El notebook analizado implementa un flujo de ciencia de datos aplicado al estudio de correos de phishing y patrones de ingenieria social. Su arquitectura integra extraccion relacional desde GoPhish, enriquecimiento semantico por reglas, construccion de datasets analiticos en distintos niveles de granularidad y modelado supervisado para tres objetivos: deteccion de patrones, clasificacion de riesgo derivado y prediccion de reporte por parte del usuario.

Desde el punto de vista metodologico, el cuaderno combina paradigma rule-based y machine learning supervisado. El enfoque rule-based se usa para traducir conocimiento del dominio —urgencia, amenaza, curiosidad, solicitud de credenciales, contexto corporativo— en variables interpretables. El enfoque supervisado se usa despues para evaluar si dichas señales permiten clasificar observaciones nuevas con capacidad de generalizacion.

A nivel de resultados, el modelo de reporte con Random Forest obtiene el mayor accuracy global, mientras que el detector de patrones de urgencia logra el mejor Macro F1 entre los componentes comparados. Sin embargo, el notebook deja claro que el principal problema estructural del proyecto es el fuerte desbalance de clases en la tarea de reporte y el numero reducido de plantillas unicas disponibles para entrenamiento semantico.

2. Arquitectura tecnica del notebook

El flujo completo puede describirse en siete capas: (1) preparacion de entorno y conexion, (2) extraccion SQL desde tablas operativas de GoPhish, (3) enriquecimiento semantico mediante tabla de clasificacion textual, (4) agregacion a nivel de resultado y a nivel de plantilla, (5) definicion de variables derivadas como riesgo compuesto, (6) entrenamiento y evaluacion de modelos supervisados, y (7) generacion de visualizaciones, tablas de respaldo y exportables de cierre.

La calidad del notebook es adecuada para una memoria tecnica o tesis aplicada, porque no se limita a entrenar un modelo unico, sino que construye un pipeline explicable, compara alternativas y cierra con limitaciones metodologicas explicitas. Esto es deseable en contextos academicos, donde la trazabilidad y la justificacion de decisiones importan tanto como la metrica final.

3. Explicacion detallada por bloque de codigo

Celda 2. 1. Importacion de librerias y configuracion de conexion

Este bloque establece el entorno técnico completo del notebook. Agrupa las dependencias de sistema, manipulación de datos, modelado supervisado, visualización y evaluación. También prepara la conexión a MySQL mediante un helper externo, lo cual desacopla las credenciales de la lógica analítica y mejora la mantenibilidad del proyecto.

Conceptos y terminos clave

- MySQL Engine: Motor de base de datos utilizado para almacenar y consultar la informacion estructurada del proyecto; permite ejecutar consultas SQL sobre tablas relacionales.
- pandas DataFrame: Estructura tabular en memoria de Python que organiza datos en filas y columnas para filtrado, union, agregacion y analisis.
- NumPy: Biblioteca base para calculo numerico en Python; aporta arreglos eficientes y operaciones vectorizadas sobre grandes volúmenes de datos.
- scikit-learn: Biblioteca de aprendizaje automatico de Python usada para preprocesamiento, entrenamiento, validacion y evaluacion de modelos supervisados.
- Pipeline: Estructura de scikit-learn que encadena pasos de transformacion y modelado para asegurar que todo el flujo se ejecute de forma ordenada y reproducible.

- ColumnTransformer: Componente que permite aplicar transformaciones distintas a grupos diferentes de columnas, por ejemplo texto por un lado y variables numericas por otro.
- TF-IDF: Metodo de vectorizacion textual que pondera terminos segun su frecuencia en un documento y su rareza en el corpus, destacando palabras informativas.
- OneHotEncoder: Transformador que convierte variables categoricas en columnas binarias para que los algoritmos puedan trabajar con ellas sin asumir orden numerico.
- RandomForestClassifier: Clasificador de ensamble basado en multiples arboles de decision; mejora robustez y reduce la varianza frente a un solo arbol.
- OneVsRestClassifier: Estrategia que entrena un clasificador por cada clase, comparando una clase contra todas las demas para resolver problemas multiclase o multietiqueta.

Arquitectónicamente, este bloque cumple la función de bootstrap del proyecto: unifica el stack de ciencia de datos y evita redefiniciones posteriores. El uso de `sys.path.append` indica una estructura modular del repositorio, donde la conexión a base de datos vive fuera del notebook.

Contexto declarado en el notebook: 1. Importacion de librerias y configuracion de conexion Este bloque centraliza las dependencias necesarias para el acceso a MySQL, el procesamiento tabular, la ingenieria de caracteristicas, la modelacion supervisada y la visualizacion de resultados. Tambien define la conexion al servidor para que el resto del cuaderno trabaje sobre un unico `engine` reutilizable.

Codigo fuente analizado:

```
# ==============================================================================
# Importaciones y configuración
# ==============================================================================
# Este bloque importa las librerías principales del proyecto y deja preparada la conexión a
# MySQL. Se incluyen componentes para extracción de datos, procesamiento tabular, modelado
# supervisado, visualización, y métricas de evaluación. El objetivo es centralizar el
# entorno de trabajo para que todo el notebook use la misma configuración y el mismo
# `engine` de base de datos.

# Importa dependencias necesarias para la siguiente fase del análisis.
import sys
# Importa dependencias necesarias para la siguiente fase del análisis.
import os
# Importa dependencias necesarias para la siguiente fase del análisis.
import re
# Importa dependencias necesarias para la siguiente fase del análisis.
import unicodedata
# Importa dependencias necesarias para la siguiente fase del análisis.
import numpy as np
# Importa dependencias necesarias para la siguiente fase del análisis.
import pandas as pd
# Importa dependencias necesarias para la siguiente fase del análisis.
import matplotlib.pyplot as plt

# Importa dependencias necesarias para fijar semillas y reproducibilidad.
import random
# Importa dependencias necesarias para serializar modelos finales.
import joblib

# Importa dependencias para trabajar on JSON
import json



# Importa dependencias necesarias para la siguiente fase del análisis.
```

```
from sklearn.model_selection import GroupShuffleSplit, LeaveOneOut
# Importa dependencias necesarias para la siguiente fase del análisis.
from sklearn.pipeline import Pipeline
# Importa dependencias necesarias para la siguiente fase del análisis.
from sklearn.compose import ColumnTransformer
# Importa dependencias necesarias para la siguiente fase del análisis.
from sklearn.feature_extraction.text import TfidfVectorizer
# Importa dependencias necesarias para la siguiente fase del análisis.
from sklearn.preprocessing import OneHotEncoder
# Importa dependencias necesarias para la siguiente fase del análisis.
from sklearn.linear_model import LogisticRegression
# Importa dependencias necesarias para la siguiente fase del análisis.
from sklearn.multiclass import OneVsRestClassifier
# Importa dependencias necesarias para la siguiente fase del análisis.
from sklearn.ensemble import RandomForestClassifier
# Importa dependencias necesarias para la siguiente fase del análisis.
from sklearn.metrics import (
    classification_report,
    confusion_matrix,
    accuracy_score,
    f1_score,
    precision_score,
    recall_score
)

# Configuracion de conexion
sys.path.append(os.path.abspath('..'))

# Importa dependencias necesarias para la siguiente fase del análisis.
from helpers.mysql_connections import create_mysql_engine


engine = create_mysql_engine()
```

Celda 4. 1.1 Reproducibilidad experimental

Aquí se fija la semilla global de aleatoriedad. Esto es crítico porque varias etapas del flujo —particiones, ordenamientos internos y modelos como Random Forest— pueden producir resultados ligeramente distintos si no se congela la generación pseudoaleatoria.

Conceptos y terminos clave

- Reproducibilidad experimental: Capacidad de repetir el experimento bajo las mismas condiciones y obtener resultados equivalentes, algo clave para la validez academica.
- random seed: Valor inicial que fija el comportamiento de procesos aleatorios para que particiones, muestras y modelos puedan repetirse de manera consistente.
- estado pseudoaleatorio: Secuencia generada por algoritmos que simulan aleatoriedad, pero que puede reproducirse exactamente cuando se usa la misma semilla.
- estabilidad de particiones: Consistencia en la division entre entrenamiento y prueba cuando el procedimiento se repite con la misma configuracion.
- replicabilidad: Posibilidad de que otra persona reproduzca el procedimiento y confirme hallazgos equivalentes usando el mismo metodo y datos comparables.

En contexto académico y técnico, reproducibilidad significa que una segunda ejecución bajo las mismas condiciones debe producir resultados comparables. Esta decisión fortalece la trazabilidad del análisis y la validez del reporte final.

Contexto declarado en el notebook: 1.1 Reproducibilidad experimental Este bloque fija una semilla global para los componentes aleatorios del cuaderno. Con ello se mejora la estabilidad de particiones, modelos y resultados exportados, permitiendo repetir el experimento con mayor consistencia.

Codigo fuente analizado:

```
# ==============================================================================
# Configuración de reproducibilidad
# ==============================================================================
# Este bloque fija semillas globales para reducir variaciones entre ejecuciones del
# notebook y facilitar la reproducibilidad de los resultados finales.

# Define la semilla global que será reutilizada en el resto del cuaderno.
GLOBAL_RANDOM_STATE = 42

# Fija la semilla del generador aleatorio estándar de Python.
random.seed(GLOBAL_RANDOM_STATE)
# Fija la semilla del generador aleatorio de NumPy.
np.random.seed(GLOBAL_RANDOM_STATE)

# Imprime la semilla activa para dejar evidencia del valor utilizado.
print("GLOBAL_RANDOM_STATE =", GLOBAL_RANDOM_STATE)
```

Salida textual relevante:

```
GLOBAL_RANDOM_STATE = 42
```

Celda 6. 2. Extraccion de datos y construccion del dataset maestro

Este es uno de los bloques nucleares del proyecto. Ejecuta una extracción SQL multi-tabla sobre el esquema de GoPhish y luego incorpora una tabla de clasificación textual. Después, realiza coincidencias entre términos clasificados y el contenido de las plantillas, generando el dataset maestro enriquecido `df_final`.

Conceptos y terminos clave

- LEFT JOIN: Operacion SQL que conserva todas las filas de la tabla izquierda y agrega coincidencias de la tabla derecha cuando existen.
- extracción ETL: Fase de extraccion, transformacion y carga en la que los datos operativos se convierten en datos utiles para analisis.
- dataset maestro: Conjunto principal de datos consolidado que integra varias fuentes y sirve como base para las etapas posteriores del analisis.
- matching textual: Proceso de buscar correspondencias entre palabras o frases del texto y un diccionario o conjunto de etiquetas predefinidas.
- enriquecimiento semántico: Adicion de significado analitico al dato original mediante etiquetas, categorias o atributos inferidos a partir del contenido textual.
- esquema relacional: Organizacion estructurada de tablas, columnas y relaciones de una base de datos relacional.
- GoPhish: Plataforma de simulacion y gestion de campañas de phishing de la cual se extraen datos operativos para el analisis.

La importancia de este bloque radica en que transforma una base operativa transaccional en una base analítica. El notebook deja de depender de eventos aislados y comienza a construir observaciones con atributos semánticos, conductuales y operativos.

Contexto declarado en el notebook: 2. Extraccion de datos y construccion del dataset maestro Este bloque obtiene la informacion operativa principal desde la base de datos de GoPhish y la tabla de clasificacion textual. La estrategia evita una union SQL masiva por coincidencias de texto y traslada esa operacion a Python para mejorar control y trazabilidad. El resultado de esta fase es

`df_final`, un dataset enriquecido que relaciona: - eventos de resultados, - campañas, - plantillas, - solicitudes, - registros de envio, - y coincidencias con el vocabulario clasificado.

Codigo fuente analizado:

```
# ==============================================================================
# Extracción SQL y dataset maestro
# ==============================================================================
# Este bloque consulta la base de datos GoPhish para unir resultados, campañas, plantillas,
# solicitudes y registros de envío. Luego carga la tabla de clasificación textual y busca
# coincidencias entre los términos clasificados y el texto de cada plantilla. El resultado
# final es `df_final`, que sirve como dataset enriquecido base para el resto del análisis.

# Define la consulta SQL principal para extraer resultados, campañas, plantillas y eventos relacionados.
q_master = """
SELECT
    r.id AS result_id,
    r.campaign_id,
    r.user_id,
    r.r_id,
    r.email,
    r.first_name,
    r.last_name,
    r.position,
    r.status AS result_status,
    r.ip,
    r.latitude,
    r.longitude,
    r.send_date AS result_send_date,
    r.reported,
    r.modified_date,

    c.name AS campaign_name,
    c.status AS campaign_status,
    c.created_date AS campaign_created_date,
    c.completed_date AS campaign_completed_date,
    c.template_id,
    c.page_id,
    c.smtp_id,
    c.url AS campaign_url,
    c.launch_date,

    t.name AS template_name,
    t.subject AS template_subject,
    t.text AS template_text,
    t.modified_date AS template_modified_date,

    e.from_address,
    e.url AS request_url,
    e.template_id AS er_template_id,
    e.page_id AS er_page_id,

    m.send_date AS mail_send_date,
    m.send_attempt,
    m.processing

FROM gophish.results r
LEFT JOIN gophish.campaigns c
    ON r.campaign_id = c.id
```

```
LEFT JOIN gophish.templates t
    ON c.template_id = t.id
LEFT JOIN gophish.email_requests e
    ON r.r_id = e.r_id
LEFT JOIN gophish.mail_logs m
    ON r.r_id = m.r_id
"""

query_text_clasification = """
SELECT
    id,
    text,
    context,
    subcontext,
    risk,
    message_type,
    text_level,
    intention,
    action_required,
    is_urgent,
    has_url,
    has_credentials
FROM gophish.text_clasification
"""

# Ejecuta la consulta anterior y carga el resultado en un DataFrame de pandas.
df_master = pd.read_sql(q_master, engine)
# Ejecuta la consulta anterior y carga el resultado en un DataFrame de pandas.
df_text_clasification = pd.read_sql(query_text_clasification, engine)

# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
df_master["template_text"] = df_master["template_text"].fillna("").str.lower()
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
df_text_clasification["text"] = df_text_clasification["text"].fillna("").str.lower()

matches = []

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for _, tc_row in df_text_clasification.iterrows():
    term = tc_row["text"].strip()
# Evalúa una condición para controlar el flujo del procesamiento.
    if not term:
        continue

# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    mask = df_master["template_text"].str.contains(term, regex=False, na=False)
    matched_rows = df_master.loc[mask, ["result_id", "template_id"]].copy()

# Evalúa una condición para controlar el flujo del procesamiento.
    if not matched_rows.empty:
        matched_rows["classification_id"] = tc_row["id"]
        matched_rows["classification_text"] = tc_row["text"]
        matched_rows["context"] = tc_row["context"]
        matched_rows["subcontext"] = tc_row["subcontext"]
        matched_rows["risk"] = tc_row["risk"]
        matched_rows["message_type"] = tc_row["message_type"]
        matched_rows["text_level"] = tc_row["text_level"]
        matched_rows["intention"] = tc_row["intention"]
```

```
        matched_rows["action_required"] = tc_row["action_required"]
        matched_rows["is_urgent"] = tc_row["is_urgent"]
        matched_rows["has_url"] = tc_row["has_url"]
        matched_rows["has_credentials"] = tc_row["has_credentials"]
        matches.append(matched_rows)

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_matches = pd.concat(matches, ignore_index=True) if matches else pd.DataFrame()

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_final = df_master.merge(
    df_matches,
    on=["result_id", "template_id"],
    how="left"
)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Shape df_master:", df_master.shape)
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Shape df_text_clasification:", df_text_clasification.shape)
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Shape df_final:", df_final.shape)
```

Salida textual relevante:

```
Shape df_master: (10811, 35)
Shape df_text_clasification: (27241, 12)
Shape df_final: (234155, 47)
```

Celda 8. 3. Agregacion a nivel de observacion analitica

Este bloque consolida múltiples coincidencias textuales en una sola observación por `result_id`. Para ello usa funciones de agregación, banderas máximas y selección modal de contextos. El resultado es un dataset más estable y apto para modelado supervisado.

Conceptos y terminos clave

- Agregación analítica: Proceso de resumir varias observaciones detalladas en una sola unidad de analisis mas estable y util para modelado.
- granularidad: Nivel de detalle con el que se representa un dato; una granularidad fina muestra eventos individuales y una agregada resume grupos.
- modo estadístico: Valor mas frecuente dentro de un conjunto de observaciones; aqui se usa para identificar la categoria dominante.
- feature engineering: Diseno y construccion de variables derivadas que aumentan la capacidad explicativa del modelo.
- variable dominante: Atributo o categoria que prevalece dentro de varias observaciones asociadas a una misma unidad analitica.
- observación a nivel resultado: Unidad de analisis definida por cada registro final consolidado, en lugar de trabajar con coincidencias textuales individuales.

Sin esta agregación, un mismo correo podría aparecer muchas veces por contener varias frases coincidentes, generando sesgo de duplicación. La reducción a una fila por resultado mejora coherencia estadística y evita inflación artificial del conjunto de entrenamiento.

Contexto declarado en el notebook: 3. Agregacion a nivel de observacion analitica El dataset anterior contiene coincidencias múltiples por frase. Para modelado supervisado se requiere una estructura mas estable, por lo que este bloque consolida la

informacion a nivel de `result_id`, resumiento contexto, riesgo, intencion y banderas binarias. El resultado es `df_ml`, que funciona como base principal para la ingenieria de variables y los modelos posteriores.

Codigo fuente analizado:

```
# ==============================================================================
# Agregación analítica a nivel resultado
# ==============================================================================
# Aquí se limpia el dataset enriquecido y se consolida la información a nivel de
# `result_id`. Se calculan contextos dominantes, banderas máximas y términos coincidentes
# agregados. El propósito es transformar múltiples coincidencias por frase en una
# observación más estable para modelado.

# Define la función auxiliar `first_mode` para reutilizar lógica en el pipeline.
def first_mode(series):
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    s = series.dropna().astype(str).str.strip()
    s = s[s != ""]
# Evalúa una condición para controlar el flujo del procesamiento.
    if s.empty:
# Devuelve el valor calculado por la función.
        return ""
    mode_vals = s.mode()
# Evalúa una condición para controlar el flujo del procesamiento.
    if len(mode_vals) == 0:
# Devuelve el valor calculado por la función.
        return s.iloc[0]
# Devuelve el valor calculado por la función.
    return mode_vals.iloc[0]

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_work = df_final.copy()

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for col in [
    "template_text", "template_subject", "context", "subcontext", "risk",
    "message_type", "text_level", "intention", "action_required",
    "position", "result_status"
]:
# Evalúa una condición para controlar el flujo del procesamiento.
    if col in df_work.columns:
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
        df_work[col] = df_work[col].fillna("").astype(str).str.strip()

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for col in ["is_urgent", "has_url", "has_credentials", "reported"]:
# Evalúa una condición para controlar el flujo del procesamiento.
    if col in df_work.columns:
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
        df_work[col] = pd.to_numeric(df_work[col], errors="coerce").fillna(0).astype(int)

group_cols_base = [
    "result_id", "campaign_id", "user_id", "r_id", "email", "first_name", "last_name",
    "position", "result_status", "ip", "latitude", "longitude", "result_send_date",
    "reported", "modified_date", "campaign_name", "campaign_status",
    "campaign_created_date", "campaign_completed_date", "template_id", "page_id",
    "smtp_id", "campaign_url", "launch_date", "template_name", "template_subject",
    "template_text", "template_modified_date", "from_address", "request_url",
    "er_template_id", "er_page_id", "mail_send_date", "send_attempt", "processing"
```

```python
]

group_cols_base = [c for c in group_cols_base if c in df_work.columns]

agg_dict = {
    "context": first_mode,
    "subcontext": first_mode,
    "risk": first_mode,
    "message_type": first_mode,
    "text_level": first_mode,
    "intention": first_mode,
    "action_required": first_mode,
    "is_urgent": "max",
    "has_url": "max",
    "has_credentials": "max",
    "classification_text": lambda x: " | ".join(sorted(set([str(v).strip() for v in x.dropna() if str(v).strip() != ""]))),
    "classification_id": "count"
}

agg_dict = {k: v for k, v in agg_dict.items() if k in df_work.columns}

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning = (
    df_work
    .groupby(group_cols_base, dropna=False, as_index=False)
    .agg(agg_dict)
    .rename(columns={
        "context": "context_detected",
        "subcontext": "subcontext_detected",
        "risk": "risk_detected",
        "message_type": "message_type_detected",
        "text_level": "text_level_detected",
        "intention": "intention_detected",
        "action_required": "action_required_detected",
        "is_urgent": "urgent_flag",
        "has_url": "url_flag",
        "has_credentials": "credentials_flag",
        "classification_text": "matched_terms",
        "classification_id": "match_count"
    })
)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Shape df_machine_learning:", df_machine_learning.shape)
df_machine_learning.head()
```

Salida textual relevante:

```
Shape df_machine_learning: (10811, 47)
```

Tabla derivada / evidencia tabular:

Unnamed: 0	result_id	campaign_id	user_id	r_id	email	first_name	last_name
0	1	1	1001	RID000101001000001mNnNDB	claudia.rivas1001@ventas-demo.com	Claudia	Rivas

1	2	1	1002	RID000101002000002QkWQul	ricardo.gomez1002@industrial-demo.com	Ricardo	Gomez
2	3	1	1003	RID000101003000003UgC1uv	marta.ramirez1003@servicios-demo.com	Marta	Ramirez
3	4	1	1004	RID00010100400000442JXaf	luis.navarro1004@logistica-demo.com	Luis	Navarro
4	5	1	1005	RID000101005000005dVnub8	ana.castro1005@corp-demo.com	Ana	Castro

Celda 10. 4. Normalizacion textual y definicion final de patrones de ingenieria social

Este bloque normaliza texto, define reglas finales de patrones de ingeniería social y construye `df_templates_final`, que resume el comportamiento semántico de cada plantilla única. También calcula positivos, negativos y tasas de activación por patrón.

Conceptos y terminos clave

- Normalización textual: Proceso de limpiar y homogeneizar texto para reducir ruido, por ejemplo unificando mayusculas, acentos o signos.
- etiquetado por reglas: Clasificacion basada en reglas explicitas definidas manualmente, en vez de depender solo de inferencia estadistica.
- patrones de ingeniería social: Estrategias discursivas usadas para manipular a la victima, como urgencia, autoridad, miedo o solicitud de credenciales.
- feature binaria: Variable que solo puede tomar dos valores, normalmente 0 y 1, para indicar ausencia o presencia de una condicion.
- tasa positiva: Proporcion de casos en los que una condicion o etiqueta aparece como presente dentro de un conjunto analizado.
- plantilla única: Conteo o identificacion de plantillas sin duplicados, util para medir cobertura real y no frecuencia inflada.

Metodológicamente, este punto separa el nivel de plantilla del nivel de resultado. Eso es correcto, porque los patrones semánticos pertenecen al contenido del mensaje, no a la reacción individual de cada usuario.

Contexto declarado en el notebook: 4. Normalizacion textual y definicion final de patrones de ingenieria social Este bloque implementa la version final de las reglas de etiquetado. Se eliminaron reglas intermedias que producian etiquetas casi constantes y se conservaron solo las expresiones que ofrecieron una distribucion mas util para entrenamiento. Los patrones considerados son: - urgencia, - autoridad, - solicitud de credenciales, - amenaza, - validacion, - incentivo, - curiosidad, - contexto corporativo. Estas etiquetas se utilizan despues tanto para caracterizacion como para prediccion de riesgo y de reporte.

Codigo fuente analizado:

```
# ==============================================================================
# Normalización textual y reglas finales de patrones
# ==============================================================================
# Este bloque normaliza el texto de asunto y cuerpo, define expresiones regulares para
# patrones de ingeniería social y aplica reglas finales para etiquetar cada plantilla. La
# intención es construir variables interpretables que representen urgencia, autoridad,
# amenaza, validación, curiosidad, credenciales, incentivo y contexto corporativo.
```

```
# Define la función auxiliar `normalize_text` para reutilizar lógica en el pipeline.
def normalize_text(text):
    text = "" if pd.isna(text) else str(text)
    text = text.lower().strip()
    text = unicodedata.normalize("NFKD", text)
    text = "".join([c for c in text if not unicodedata.combining(c)])
    text = re.sub(r"\s+", " ", text)
# Devuelve el valor calculado por la función.
    return text

# Define la función auxiliar `count_matches` para reutilizar lógica en el pipeline.
def count_matches(text, patterns):
# Devuelve el valor calculado por la función.
    return sum(1 for p in patterns if re.search(p, text))

# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
df_machine_learning["subject_norm"] = df_machine_learning["template_subject"].fillna("").apply(normalize_text)
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
df_machine_learning["body_norm"] = df_machine_learning["template_text"].fillna("").apply(normalize_text)
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
df_machine_learning["text_full_norm"] = (df_machine_learning["subject_norm"] + " " +
df_machine_learning["body_norm"]).str.strip()

# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
txt = df_machine_learning["text_full_norm"].fillna("")

urgency_soft = [
    r"\burgente\b", r"\baccion requerida\b", r"\baccion obligatoria\b",
    r"\binmediata\b", r"\binmediato\b", r"\bprioridad alta\b"
]
urgency_hard = [
    r"\bultim[oa] aviso\b", r"\bantes de\b", r"\ben las proximas? 24 horas\b",
    r"\bexpira hoy\b", r"\bvenc[eé] hoy\b", r"\bplazo final\b"
]
authority_patterns = [
    r"\bdepartamento de ti\b", r"\bequipo de seguridad\b", r"\bseguridad institucional\b",
    r"\bsoporte tecnico\b", r"\bmesa de ayuda\b", r"\badministrador del sistema\b",
    r"\bservicio de correo\b", r"\brecursos humanos\b", r"\brrhh\b",
    r"\bdepartamento financiero\b", r"\barea financiera\b", r"\binstitucional\b", r"\bcorporativo\b"
]
credentials_strong = [
    r"\binicie sesion\b", r"\biniciar sesion\b", r"\bcredencial digital\b",
    r"\bcredenciales\b", r"\bactualice sus credenciales\b", r"\brestablezca su clave\b",
    r"\busuario y contrasena\b", r"\bcontrasena\b", r"\bclave de acceso\b"
]
credentials_soft_a = [r"\bacceso\b", r"\bcuenta\b", r"\bperfil\b", r"\bcredencial\b"]
credentials_soft_b = [r"\bverificacion\b", r"\bvalidacion\b", r"\brestablecimiento\b", r"\brenovacion\b",
r"\bactualizacion\b"]
credentials_exclusions = [r"\bconvocatoria\b", r"\bbeneficio\b"]

threat_patterns = [
    r"\bbloquead[oa]\b", r"\bsuspendid[oa]\b", r"\brestringid[oa]\b",
    r"\bacceso denegado\b", r"\bperdera acceso\b", r"\bentrega retenida\b",
    r"\bpago retenido\b", r"\bexcedio el limite\b", r"\binconsistencia documental\b",
    r"\bdesactivad[oa]\b", r"\bincumplimiento\b"
]
validation_strong = [
    r"\bverificacion de acceso\b", r"\bvalidacion de cuenta\b",
```

```
    r"\bconfirmacion de datos\b", r"\bconfirmacion obligatoria de datos\b",
    r"\bactualizacion de datos\b", r"\bconfirmar datos laborales\b",
    r"\bverifique su cuenta\b", r"\bverifique su informacion\b"
]
validation_soft = [
    r"\bverificacion\b", r"\bverificar\b", r"\bverifique\b", r"\bvalidacion\b",
    r"\bvalidar\b", r"\bconfirme\b", r"\bconfirmacion\b",
    r"\bactualizacion\b", r"\bactualice\b", r"\bactualizar\b"
]
validation_exclusions = [
    r"\bconvocatoria\b", r"\bbeneficio\b", r"\bfactura pendiente\b",
    r"\bpago retenido\b", r"\bdocumento compartido\b"
]
incentive_patterns = [r"\bbeneficio\b", r"\bbono\b", r"\bpremio\b", r"\brecompensa\b", r"\bdescuento\b",
r"\breembolso\b", r"\bincentivo\b", r"\boferta\b"]
curiosity_patterns = [r"\bactividad inusual\b", r"\bdocumento compartido\b", r"\bfactura pendiente\b", r"\bpago
retenido\b", r"\barchivo adjunto\b", r"\bconsulte el documento\b", r"\bvea el archivo\b", r"\bnotificacion interna\b",
r"\bse detecto actividad\b", r"\bmensaje pendiente\b"]
corporate_strong = [r"\bvpn\b", r"\bcorreo corporativo\b", r"\bportal interno\b", r"\bintranet\b", r"\bcredencial
digital\b"]
corporate_soft = [r"\bbuzon\b", r"\bdatos laborales\b", r"\brecursos humanos\b", r"\brrhh\b", r"\barea financiera\b",
r"\bdepartamento financiero\b", r"\balmacenamiento\b", r"\bperfil\b", r"\bcorporativo\b", r"\binstitucional\b"]

# Define la función auxiliar `rule_urgency` para reutilizar lógica en el pipeline.
def rule_urgency(text):
# Devuelve el valor calculado por la función.
    return int((count_matches(text, urgency_soft) >= 2) or (count_matches(text, urgency_hard) >= 1))

# Define la función auxiliar `rule_authority` para reutilizar lógica en el pipeline.
def rule_authority(text):
# Devuelve el valor calculado por la función.
    return int(count_matches(text, authority_patterns) >= 1)

# Define la función auxiliar `rule_credentials` para reutilizar lógica en el pipeline.
def rule_credentials(text):
# Evalúa una condición para controlar el flujo del procesamiento.
    if any(re.search(p, text) for p in credentials_exclusions):
# Devuelve el valor calculado por la función.
        return 0
# Devuelve el valor calculado por la función.
    return int((count_matches(text, credentials_strong) >= 1) or ((count_matches(text, credentials_soft_a) >= 1) and
(count_matches(text, credentials_soft_b) >= 1)))

# Define la función auxiliar `rule_threat` para reutilizar lógica en el pipeline.
def rule_threat(text):
# Devuelve el valor calculado por la función.
    return int(count_matches(text, threat_patterns) >= 1)

# Define la función auxiliar `rule_validation` para reutilizar lógica en el pipeline.
def rule_validation(text):
# Evalúa una condición para controlar el flujo del procesamiento.
    if any(re.search(p, text) for p in validation_exclusions):
# Devuelve el valor calculado por la función.
        return 0
# Devuelve el valor calculado por la función.
    return int((count_matches(text, validation_strong) >= 1) or (count_matches(text, validation_soft) >= 2))

# Define la función auxiliar `rule_incentive` para reutilizar lógica en el pipeline.
```

```
def rule_incentive(text):
# Devuelve el valor calculado por la función.
    return int(count_matches(text, incentive_patterns) >= 1)

# Define la función auxiliar `rule_curiosity` para reutilizar lógica en el pipeline.
def rule_curiosity(text):
# Devuelve el valor calculado por la función.
    return int(count_matches(text, curiosity_patterns) >= 1)

# Define la función auxiliar `rule_corporate` para reutilizar lógica en el pipeline.
def rule_corporate(text):
# Devuelve el valor calculado por la función.
    return int((count_matches(text, corporate_strong) >= 1) or (count_matches(text, corporate_soft) >= 2))

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning["pattern_urgency"] = txt.apply(rule_urgency)
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning["pattern_authority"] = txt.apply(rule_authority)
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning["pattern_credentials"] = txt.apply(rule_credentials)
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning["pattern_threat"] = txt.apply(rule_threat)
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning["pattern_validation"] = txt.apply(rule_validation)
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning["pattern_incentive"] = txt.apply(rule_incentive)
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning["pattern_curiosity"] = txt.apply(rule_curiosity)
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_machine_learning["pattern_corporate_context"] = txt.apply(rule_corporate)

# Define la lista de columnas objetivo o de análisis relacionadas con patrones de ingeniería social.
pattern_cols = [
    "pattern_urgency", "pattern_authority", "pattern_credentials", "pattern_threat",
    "pattern_validation", "pattern_incentive", "pattern_curiosity", "pattern_corporate_context"
]

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_templates_final = (
    df_machine_learning[
        ["template_id", "template_subject", "template_text", "text_full_norm"] + pattern_cols
    ]
    .drop_duplicates(subset=["template_id"])
    .sort_values("template_id")
    .reset_index(drop=True)
)

summary_final = pd.DataFrame({
    "positives": df_templates_final[pattern_cols].sum(),
    "negatives": len(df_templates_final) - df_templates_final[pattern_cols].sum(),
    "positive_rate": df_templates_final[pattern_cols].mean()
}).sort_values("positive_rate", ascending=False)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Shape df_templates_final:", df_templates_final.shape)
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(summary_final)
```

Salida textual relevante:

```
Shape df_templates_final: (13, 12)
                          positives  negatives  positive_rate
pattern_credentials              11          2       0.846154
pattern_validation                8          5       0.615385
pattern_corporate_context         6          7       0.461538
pattern_urgency                   5          8       0.384615
pattern_curiosity                 4          9       0.307692
pattern_threat                    3         10       0.230769
pattern_authority                 2         11       0.153846
pattern_incentive                 1         12       0.076923
```

Celda 12. 5. Validacion del detector de patrones a nivel de plantilla unica

Aquí se valida el detector de patrones con Leave-One-Out sobre plantillas únicas. Cada iteración deja una plantilla fuera y entrena con todas las demás. Es un esquema adecuado cuando el número de plantillas es pequeño y se desea maximizar el uso del conjunto disponible.

Conceptos y terminos clave

- Leave-One-Out: Esquema de validacion en el que se entrena con todos los casos menos uno y se prueba sobre el caso excluido, repitiendo el ciclo para cada observacion.
- validación cruzada exhaustiva: Forma intensiva de evaluacion que explora muchas particiones posibles para medir con mas detalle la capacidad de generalizacion.
- multietiqueta: Problema en el que una misma observacion puede pertenecer a varias etiquetas simultaneamente.
- One-vs-Rest: Enfoque que resuelve un problema de multiples clases entrenando un clasificador independiente para cada clase frente al resto.
- sobreajuste: Fenomeno en el que el modelo aprende demasiado bien el ruido o particularidades del entrenamiento y rinde peor con datos nuevos.
- generalización: Capacidad del modelo para mantener buen desempeño cuando se aplica a observaciones no vistas durante el entrenamiento.

Dado que solo existen 13 plantillas, una partición convencional podría desperdiciar demasiada información. Leave-One-Out permite evaluar robustez con el máximo aprovechamiento del corpus disponible, aunque mantiene alta varianza por el tamaño reducido.

Contexto declarado en el notebook: 5. Validacion del detector de patrones a nivel de plantilla unica La evaluacion de patrones se realiza exclusivamente con `templates` unicos y validacion Leave-One-Out. Esta decision evita fuga de informacion entre ejemplos duplicados y permite una evaluacion mas honesta del clasificador multietiqueta. El modelo combina: - TF-IDF sobre asunto y cuerpo, - regresion logistica, - estrategia One-vs-Rest para multiples etiquetas simultaneas.

Codigo fuente analizado:

```
# ==============================================================================
# Validación de patrones con Leave-One-Out
# ==============================================================================
# Este bloque evalúa el detector de patrones a nivel de plantilla única. Usa TF-IDF sobre el
# texto completo y una estrategia One-vs-Rest con regresión logística. Se emplea Leave-One-
# Out porque el número de plantillas únicas es pequeño y se busca una validación más honesta
# sin fuga de información.

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_eval = df_templates_final.copy()
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_eval["text_full"] = (
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_eval["template_subject"].fillna("").astype(str).str.strip() + " " +
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
```

```
    df_eval["template_text"].fillna("").astype(str).str.strip()
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
).str.strip()

X = df_eval["text_full"].reset_index(drop=True)
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
Y = df_eval[pattern_cols].fillna(0).astype(int).reset_index(drop=True)

# Configura la estrategia de partición o validación del conjunto de datos.
loo = LeaveOneOut()
# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
all_true = []
# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
all_pred = []
# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
rows_compare = []

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for fold, (train_idx, test_idx) in enumerate(loo.split(X), start=1):
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    X_train, X_test = X.iloc[train_idx], X.iloc[test_idx]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    y_train, y_test = Y.iloc[train_idx], Y.iloc[test_idx]

    trainable_cols = []
    skipped_cols = []

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
    for col in pattern_cols:
# Evalúa una condición para controlar el flujo del procesamiento.
        if y_train[col].nunique() >= 2:
            trainable_cols.append(col)
# Continúa la lógica condicional definida en el bloque anterior.
        else:
            skipped_cols.append(col)

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    y_pred_fold = pd.DataFrame(index=y_test.index)

# Evalúa una condición para controlar el flujo del procesamiento.
    if trainable_cols:
# Construye un pipeline de procesamiento y modelado para encapsular pasos repetibles.
        model_patterns_final = Pipeline([
# Configura la vectorización TF-IDF para transformar texto en representaciones numéricas.
            ("tfidf", TfidfVectorizer(ngram_range=(1, 2), min_df=1)),
            ("clf", OneVsRestClassifier(
# Inicializa un clasificador de regresión logística para la tarea supervisada correspondiente.
                LogisticRegression(max_iter=2000, class_weight="balanced")
            ))
        ])

# Entrena el modelo con los datos de entrenamiento.
        model_patterns_final.fit(X_train, y_train[trainable_cols])
# Genera predicciones o probabilidades a partir del modelo entrenado.
        pred_partial = model_patterns_final.predict(X_test)

        pred_partial_df = pd.DataFrame(
            pred_partial,
```

```
        columns=trainable_cols,
        index=y_test.index
    )
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    y_pred_fold = pd.concat([y_pred_fold, pred_partial_df], axis=1)

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
  for col in skipped_cols:
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    y_pred_fold[col] = y_train[col].iloc[0]

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
  y_pred_fold = y_pred_fold[pattern_cols]

# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
  all_true.append(y_test.values[0])
# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
  all_pred.append(y_pred_fold.values[0])

  row_result = {
    "fold": fold,
    "template_id": df_eval.iloc[test_idx[0]]["template_id"],
    "template_subject": df_eval.iloc[test_idx[0]]["template_subject"]
  }
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
  for col in pattern_cols:
    row_result[f"real_{col}"] = int(y_test.iloc[0][col])
    row_result[f"pred_{col}"] = int(y_pred_fold.iloc[0][col])
# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
  rows_compare.append(row_result)

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_true_patterns = np.array(all_true)
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_pred_patterns = np.array(all_pred)

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for i, col in enumerate(pattern_cols):
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
  print("\n" + "=" * 80)
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
  print(f"REPORTE DE CLASIFICACION - {col}")
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
  print("=" * 80)
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
  print(classification_report(y_true_patterns[:, i], y_pred_patterns[:, i], zero_division=0))

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_compare_templates = pd.DataFrame(rows_compare)
df_compare_templates.head()
```

Salida textual relevante:

```
================================================================================
REPORTE DE CLASIFICACION - pattern_urgency
================================================================================
              precision    recall  f1-score   support

           0       0.86      0.75      0.80         8
```

```
           1       0.67      0.80      0.73         5

    accuracy                           0.77        13
   macro avg       0.76      0.78      0.76        13
weighted avg       0.78      0.77      0.77        13


================================================================================
REPORTE DE CLASIFICACION - pattern_authority
================================================================================
              precision    recall  f1-score   support

           0       0.85      1.00      0.92        11
           1       0.00      0.00      0.00         2

    accuracy                           0.85        13
   macro avg       0.42      0.50
0.46        13
weighted avg       0.72      0.85      0.78        13


================================================================================
REPORTE DE CLASIFICACION - pattern_credentials
================================================================================
              precision    recall  f1-score   support

           0       0.00      0.00      0.00         2
           1       0.85      1.00      0.92        11

    accuracy                           0.85        13
   macro avg       0.42      0.50      0.46        13
weighted avg       0.72      0.85      0.78        13


================================================================================
REPORTE DE CLASIFICACION - pattern_threat
================================================================================
              precision    recall  f1-score   support

           0       0.77      1.00      0.87        10
           1       0.00      0.00      0.00         3

    accuracy
                           0.77        13
   macro avg       0.38      0.50      0.43        13
weighted avg       0.59      0.77      0.67        13


================================================================================
REPORTE DE CLASIFICACION - pattern_validation
================================================================================
              precision    recall  f1-score   support

           0       0.00      0.00      0.00         5
           1       0.62      1.00      0.76
```

Tabla derivada / evidencia tabular:

Unnamed: 0	fold	template_id	template_subject	real_pattern_urgency	pred_pattern_urgency	real_pattern_authority	pred_pattern_authority
0	1	1	Verificacion urgente de acceso institucional	0	0	1	0

1	2	2	Entrega retenida - accion requerida	1	0	0	0
2	3	3	Actividad inusual detectada en su perfil	0	0	0	0
3	4	4	Accion requerida: actualizacion de VPN corpora...	0	1	0	0
4	5	5	Documento compartido requiere revision inmediata	1	1	0	0

Celda 14. 6. Construccion del riesgo derivado por reglas

Este bloque crea una variable de riesgo derivado mediante reglas. La razón es técnica: la variable de riesgo original no tenía variabilidad suficiente para soportar un modelado multiclase útil. Por ello se define un puntaje compuesto y luego una etiqueta discreta de riesgo bajo, medio o alto.

Conceptos y terminos clave

- Variable derivada: Variable creada a partir de otras variables originales mediante reglas, calculos o transformaciones.
- scoring rule-based: Sistema de puntuacion construido con reglas expertas en lugar de ser aprendido directamente por un algoritmo.
- discretización: Transformacion de una variable continua o numerica en categorias o intervalos definidos.
- clases ordinales: Categorias con orden natural entre ellas, como bajo, medio y alto.
- señal analítica: Patron o indicio contenido en los datos que aporta informacion util para explicar o predecir un fenomeno.
- ingeniería de variables: Proceso de seleccionar, crear y transformar variables para que representen mejor el problema analitico.

En proyectos aplicados es válido derivar variables cuando la variable original no es informativa. Lo importante es declarar la lógica de construcción y no presentar la nueva etiqueta como una verdad observada, sino como una construcción analítica sustentada.

Contexto declarado en el notebook: 6. Construccion del riesgo derivado por reglas La variable de riesgo original no presento variabilidad suficiente para modelado multiclase. Por ello se construye un riesgo derivado a partir de una puntuacion ponderada que integra: - amenaza, - credenciales, - urgencia, - validacion, - autoridad, - contexto corporativo, - banderas tecnicas. La transformacion final asigna tres niveles: - Bajo, - Medio, - Alto.

Codigo fuente analizado:

```
# ==============================================================================
# Construcción del riesgo derivado
# ==============================================================================
# Aquí se crea una variable de riesgo derivado a partir de una puntuación ponderada que
```

```
# combina patrones de ingeniería social y banderas técnicas. Luego se transforma la
# puntuación en clases Bajo, Medio y Alto, para permitir una tarea multiclase con
# variabilidad suficiente.

# Define el conjunto base de columnas que se conservarán para construir el dataset específico.
risk_cols_base = [
    "template_id", "template_subject", "template_text", "text_full_norm", "risk_detected",
    "urgent_flag", "url_flag", "credentials_flag",
    "context_detected", "subcontext_detected", "message_type_detected",
    "text_level_detected", "intention_detected", "action_required_detected"
] + pattern_cols

# Define el conjunto base de columnas que se conservarán para construir el dataset específico.
risk_cols_base = [c for c in risk_cols_base if c in df_machine_learning.columns]

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_risk = (
    df_machine_learning[risk_cols_base]
    .drop_duplicates(subset=["template_id"])
    .copy()
)

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_risk["text_full"] = (
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_risk["template_subject"].fillna("").astype(str).str.strip() + " " +
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_risk["template_text"].fillna("").astype(str).str.strip()
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
).str.strip()

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_risk_rules = df_risk.copy()

rule_num_cols = [
    "urgent_flag", "url_flag", "credentials_flag",
    "pattern_urgency", "pattern_authority", "pattern_credentials",
    "pattern_threat", "pattern_validation", "pattern_incentive",
    "pattern_curiosity", "pattern_corporate_context"
]

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for c in rule_num_cols:
# Evalúa una condición para controlar el flujo del procesamiento.
    if c in df_risk_rules.columns:
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
        df_risk_rules[c] = pd.to_numeric(df_risk_rules[c], errors="coerce").fillna(0)

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_risk_rules["risk_score"] = (
    2.0 * df_risk_rules.get("pattern_threat", 0) +
    2.0 * df_risk_rules.get("pattern_credentials", 0) +
    1.5 * df_risk_rules.get("pattern_urgency", 0) +
    1.5 * df_risk_rules.get("pattern_validation", 0) +
    1.0 * df_risk_rules.get("pattern_authority", 0) +
    1.0 * df_risk_rules.get("pattern_corporate_context", 0) +
    1.0 * df_risk_rules.get("credentials_flag", 0) +
    0.5 * df_risk_rules.get("url_flag", 0) +
```

```
    0.5 * df_risk_rules.get("pattern_curiosity", 0) +
    0.5 * df_risk_rules.get("pattern_incentive", 0)
)

# Define la función auxiliar `map_risk` para reutilizar lógica en el pipeline.
def map_risk(score):
# Evalúa una condición para controlar el flujo del procesamiento.
    if score <= 2.0:
# Devuelve el valor calculado por la función.
        return 0
# Continúa la lógica condicional definida en el bloque anterior.
    elif score <= 5.0:
# Devuelve el valor calculado por la función.
        return 1
# Devuelve el valor calculado por la función.
    return 2

# Establece un diccionario de apoyo para mapear clases numéricas a etiquetas legibles.
risk_label_map = {0: "Bajo", 1: "Medio", 2: "Alto"}

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_risk_rules["risk_target_rule"] = df_risk_rules["risk_score"].apply(map_risk)
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_risk_rules["risk_label_rule"] = df_risk_rules["risk_target_rule"].map(risk_label_map)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(df_risk_rules[["template_id", "risk_score", "risk_target_rule", "risk_label_rule"]].sort_values(["risk_target_rule",
"risk_score"]))
```

Salida textual relevante:

```
       template_id  risk_score  risk_target_rule risk_label_rule
10810           16         0.0                 0            Bajo
423             10         1.5                 0            Bajo
94               3         5.0                 1           Medio
188              5         5.0                 1           Medio
282              7         5.0                 1           Medio
141              4         5.5                 2            Alto
329              8         5.5                 2            Alto
517             12         5.5                 2            Alto
0                1         6.5                 2            Alto
235              6         6.5                 2            Alto
470             11         7.0                 2            Alto
47               2         8.0                 2            Alto
376              9         9.0                 2            Alto
```

Celda 16. 7. Modelo de riesgo con validacion Leave-One-Out

Este bloque entrena y evalúa el modelo de riesgo derivado. Usa una arquitectura híbrida: texto vectorizado con TF-IDF, variables numéricas, variables categóricas y un clasificador de regresión logística multiclase.

Conceptos y terminos clave

- TF-IDF: Metodo de vectorizacion textual que pondera terminos segun su frecuencia en un documento y su rareza en el corpus, destacando palabras informativas.
- regresión logística multiclase: Extension de la regresion logistica para distinguir entre mas de dos clases posibles.
- features estructuradas: Variables no textuales ya organizadas en columnas, como banderas, conteos o categorias codificadas.
- matriz de confusión: Tabla que compara clases reales contra clases predichas para visualizar aciertos y tipos de error del modelo.

- Macro F1: Promedio simple del F1 de cada clase; da el mismo peso a todas, incluso a las minoritarias.
- Weighted F1: Promedio del F1 ponderado por el numero de ejemplos de cada clase, por lo que refleja mejor la distribucion real del dataset.

El interés técnico aquí es doble: combinar texto libre con variables tabulares y evaluar un problema multiclase con métricas más informativas que el simple accuracy. Macro F1 es particularmente valioso cuando las clases no están perfectamente balanceadas.

Contexto declarado en el notebook: 7. Modelo de riesgo con validacion Leave-One-Out Este modelo estima el riesgo derivado utilizando una arquitectura híbrida: - texto vectorizado con TF-IDF, - banderas numericas, - variables categoricas codificadas, - regresion logistica multiclase. La evaluacion Leave-One-Out es apropiada por el bajo numero de plantillas unicas y permite observar la capacidad de generalizacion del modelo ante plantillas no vistas.

Codigo fuente analizado:

```
# ==============================================================================
# Modelo de riesgo derivado
# ==============================================================================
# Este bloque entrena y evalúa el modelo de riesgo. Integra texto vectorizado con TF-IDF,
# variables numéricas y categóricas, y usa regresión logística multiclase con validación
# Leave-One-Out. También construye la matriz de confusión final del modelo.

text_col = "text_full"

num_cols_risk = [
    "urgent_flag", "url_flag", "credentials_flag",
    "pattern_urgency", "pattern_authority", "pattern_credentials",
    "pattern_threat", "pattern_validation", "pattern_incentive",
    "pattern_curiosity", "pattern_corporate_context"
]
num_cols_risk = [c for c in num_cols_risk if c in df_risk_rules.columns]

cat_cols_risk = [
    "context_detected", "subcontext_detected", "message_type_detected",
    "text_level_detected", "intention_detected", "action_required_detected"
]
cat_cols_risk = [c for c in cat_cols_risk if c in df_risk_rules.columns]

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for c in cat_cols_risk:
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_risk_rules[c] = df_risk_rules[c].fillna("").astype(str).str.strip()

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for c in num_cols_risk:
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_risk_rules[c] = pd.to_numeric(df_risk_rules[c], errors="coerce").fillna(0)

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
X_risk = df_risk_rules[[text_col] + num_cols_risk + cat_cols_risk].copy()
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_risk = df_risk_rules["risk_target_rule"].copy()

# Define un preprocesador que aplica transformaciones distintas a texto, variables numéricas y categóricas.
preprocessor_risk = ColumnTransformer([
# Configura la vectorización TF-IDF para transformar texto en representaciones numéricas.
    ("text", TfidfVectorizer(ngram_range=(1, 2), min_df=1), text_col),
    ("num", "passthrough", num_cols_risk),
```

```
    ("cat", OneHotEncoder(handle_unknown="ignore"), cat_cols_risk)
])

# Configura la estrategia de partición o validación del conjunto de datos.
loo = LeaveOneOut()
risk_true = []
risk_pred = []
# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
rows_compare_risk = []

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for fold, (train_idx, test_idx) in enumerate(loo.split(X_risk), start=1):
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    X_train = X_risk.iloc[train_idx]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    X_test = X_risk.iloc[test_idx]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    y_train = y_risk.iloc[train_idx]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
    y_test = y_risk.iloc[test_idx]

# Evalúa una condición para controlar el flujo del procesamiento.
    if y_train.nunique() < 2:
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
        y_pred_fold = np.array([int(y_train.mode().iloc[0])])
# Continúa la lógica condicional definida en el bloque anterior.
    else:
# Construye un pipeline de procesamiento y modelado para encapsular pasos repetibles.
        model_risk_rule = Pipeline([
            ("prep", preprocessor_risk),
# Inicializa un clasificador de regresión logística para la tarea supervisada correspondiente.
            ("clf", LogisticRegression(max_iter=2000, class_weight="balanced"))
        ])
# Entrena el modelo con los datos de entrenamiento.
        model_risk_rule.fit(X_train, y_train)
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
        y_pred_fold = model_risk_rule.predict(X_test)

    risk_true.append(int(y_test.iloc[0]))
    risk_pred.append(int(y_pred_fold[0]))

# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
    rows_compare_risk.append({
        "fold": fold,
        "template_id": int(df_risk_rules.iloc[test_idx[0]]["template_id"]),
        "template_subject": df_risk_rules.iloc[test_idx[0]]["template_subject"],
        "real_risk": int(y_test.iloc[0]),
        "pred_risk": int(y_pred_fold[0])
    })

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_true_risk = np.array(risk_true)
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_pred_risk = np.array(risk_pred)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(classification_report(y_true_risk, y_pred_risk, zero_division=0))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
```

```
print("Accuracy :", round(accuracy_score(y_true_risk, y_pred_risk), 4))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Macro F1 :", round(f1_score(y_true_risk, y_pred_risk, average="macro", zero_division=0), 4))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Weighted F1 :", round(f1_score(y_true_risk, y_pred_risk, average="weighted", zero_division=0), 4))

# Calcula métricas de evaluación para medir el desempeño del modelo.
cm_risk = confusion_matrix(y_true_risk, y_pred_risk, labels=[0, 1, 2])
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_cm_risk = pd.DataFrame(
# Convierte la salida numérica a una estructura tabular para facilitar la interpretación.
    cm_risk,
    index=["Real_Bajo", "Real_Medio", "Real_Alto"],
    columns=["Pred_Bajo", "Pred_Medio", "Pred_Alto"]
)
df_cm_risk
```

Salida textual relevante:

```
              precision    recall  f1-score   support

           0       1.00      0.50      0.67         2
           1       0.50      0.67      0.57         3
           2       0.88      0.88      0.88         8

    accuracy                           0.77        13
   macro avg       0.79      0.68      0.70        13
weighted avg       0.81      0.77      0.77        13

Accuracy : 0.7692
Macro F1 : 0.7044
Weighted F1 : 0.7729
```

Tabla derivada / evidencia tabular:

Unnamed: 0	Pred_Bajo	Pred_Medio	Pred_Alto
Real_Bajo	1	1	0
Real_Medio	0	2	1
Real_Alto	0	1	7

Celda 18. 8. Interpretabilidad del modelo de riesgo

Se abre la caja negra relativa del modelo de riesgo mediante análisis de coeficientes. Al inspeccionar pesos positivos y negativos por clase, el notebook identifica qué variables empujan más fuertemente hacia riesgo bajo, medio o alto.

Conceptos y terminos clave

- Interpretabilidad: Grado en que puede entenderse por que un modelo produce determinada prediccion y que variables influyen en ella.
- coeficiente lineal: Peso numerico que un modelo lineal asigna a una variable para indicar su contribucion a la salida.
- magnitud absoluta: Valor absoluto del coeficiente, usado para medir fuerza de influencia sin importar el signo.
- dirección del efecto: Sentido en que una variable empuja la prediccion, ya sea aumentando o disminuyendo la probabilidad de una clase.
- feature importance en modelos lineales: Lectura de importancia basada en el tamaño de los coeficientes aprendidos por el modelo.

Esto es fundamental para una tesis o reporte técnico serio: no basta con predecir, también debe explicarse por qué el modelo tomó ciertas decisiones y qué patrones dominan la clasificación.

Contexto declarado en el notebook: 8. Interpretabilidad del modelo de riesgo Para obtener una lectura tecnica de las variables mas influyentes, se entrena el modelo final sobre todo el conjunto disponible y se inspeccionan los coeficientes de la regresion logistica. Esta fase permite identificar: - terminos textuales que empujan hacia un nivel de riesgo, - patrones de ingenieria social con mayor peso, - y variables estructuradas con mayor poder explicativo.

Codigo fuente analizado:

```
# ==============================================================================
# Interpretabilidad del modelo de riesgo
# ==============================================================================
# Este bloque entrena el modelo final de riesgo sobre todo el conjunto disponible y extrae
# los coeficientes de la regresión logística. El propósito es identificar qué variables
# textuales y estructuradas empujan la predicción hacia cada nivel de riesgo.

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
X_all = df_risk_rules[[text_col] + num_cols_risk + cat_cols_risk].copy()
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_all = df_risk_rules["risk_target_rule"].copy()

# Configura la vectorización TF-IDF para transformar texto en representaciones numéricas.
tfidf = TfidfVectorizer(ngram_range=(1, 2), min_df=1)
# Define un preprocesador que aplica transformaciones distintas a texto, variables numéricas y categóricas.
preprocessor_full_risk = ColumnTransformer([
    ("text", tfidf, text_col),
    ("num", "passthrough", num_cols_risk),
    ("cat", OneHotEncoder(handle_unknown="ignore"), cat_cols_risk)
])

# Construye un pipeline de procesamiento y modelado para encapsular pasos repetibles.
model_risk_final = Pipeline([
    ("prep", preprocessor_full_risk),
# Inicializa un clasificador de regresión logística para la tarea supervisada correspondiente.
    ("clf", LogisticRegression(max_iter=2000, class_weight="balanced"))
])

# Entrena el modelo con los datos de entrenamiento.
model_risk_final.fit(X_all, y_all)

feature_names_risk = model_risk_final.named_steps["prep"].get_feature_names_out()
coef_matrix_risk = model_risk_final.named_steps["clf"].coef_

# Establece un diccionario de apoyo para mapear clases numéricas a etiquetas legibles.
class_map = {0: "Bajo", 1: "Medio", 2: "Alto"}

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for class_idx, class_label in class_map.items():
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
    df_imp = pd.DataFrame({
        "feature": feature_names_risk,
        "coef": coef_matrix_risk[class_idx],
        "abs_coef": np.abs(coef_matrix_risk[class_idx])
    }).sort_values("coef", ascending=False)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
    print("\n" + "=" * 90)
```

```
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(f"TOP VARIABLES QUE EMPUJAN HACIA RIESGO {class_label.upper()}")
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("=" * 90)
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(df_imp.head(15)[["feature", "coef"]])
```

Salida textual relevante:

```
==========================================================================================
TOP VARIABLES QUE EMPUJAN HACIA RIESGO BAJO
==========================================================================================
                            feature      coef
1261          num__pattern_incentive  0.498350
194                  text__beneficio  0.165266
1264          cat__context_detected_  0.141573
1276        cat__intention_detected_  0.141573
1268       cat__subcontext_detected_  0.141573
1278  cat__action_required_detected_  0.141573
1274       cat__text_level_detected_  0.141573
1272     cat__message_type_detected_  0.141573
666                    text__interno  0.099159
1167              text__un beneficio  0.099159
196          text__beneficio interno  0.099159
667          text__interno pendiente  0.099159
353            text__de confirmacion  0.099159
840               text__pendiente de  0.070728
1151                  text__tiene un  0.066106
==========================================================================================
TOP VARIABLES QUE EMPUJAN HACIA RIESGO MEDIO
==========================================================================================
                                            feature      coef
1262                         num__pattern_curiosity  0.774465
1258                       num__pattern_credentials  0.313275
1265           cat__context_detected_Administrativo  0.236441
1256                           num__pattern_urgency  0.207780
1270            cat__subcontext_detected_Asistencia  0.174037
564                                   text__factura  0.104020
438                                 text__detectada  0.089080
100                         text__actividad inusual  0.089080
471                                 text__documento  0.081101
670                                   text__inusual  0.074185
1279              cat__action_required_detected_0.0  0.067515
1255
                          num__credentials_flag  0.067515
1275  cat__text_level_detected_Palabra o frase corta  0.067515
1277             cat__intention_detected_Referencia  0.067515
1273             cat__message_type_detected_Neutral  0.067515

==========================================================================================
TOP VARIABLES QUE EMPUJAN HACIA RIESGO ALTO
==========================================================================================
                                            feature
```

Celda 20. 9. Construccion del dataset de reporte a nivel de resultado

Este bloque construye el dataset de reporte a nivel de resultado. A diferencia de los patrones, el reporte sí es una conducta de usuario, por lo que la unidad analítica correcta es el resultado individual y no la plantilla agregada.

Conceptos y terminos clave

- Variable objetivo desbalanceada: Variable a predecir cuyas clases no tienen cantidades similares de ejemplos.

- comportamiento observado: Patron empirico que realmente aparece en los datos recolectados, sin asumir teoria previa.
- nivel de análisis: Escala concreta en la que se examina el fenomeno, por ejemplo por correo, por plantilla o por resultado.
- instancia individual: Cada fila o caso particular del dataset sobre el cual el modelo aprende o predice.
- clase minoritaria: Clase con menos ejemplos dentro del conjunto de datos y que suele ser mas dificil de detectar correctamente.

El conteo mostrado confirma un fuerte desbalance: apenas una fracción muy pequeña de correos fue reportada. Esto anticipa dificultades para entrenar un modelo sensible a la clase positiva.

Contexto declarado en el notebook: 9. Construccion del dataset de reporte a nivel de resultado A diferencia del riesgo, el reporte es un comportamiento individual del usuario y no debe modelarse solamente a nivel de plantilla. Por ello el dataset de reporte se construye a nivel de `result_id`, incorporando: - texto de la plantilla, - banderas tecnicas, - contexto, - cargo del usuario, - estado del correo, - patrones de ingenieria social, - y posteriormente el riesgo derivado.

Codigo fuente analizado:

```
# ==============================================================================
# Dataset de reporte a nivel resultado
# ==============================================================================
# Aquí se construye el dataset para la tarea de reporte usando observaciones a nivel de
# `result_id`. Se combinan texto, cargo, estado del correo, banderas, patrones y riesgo
# derivado. Esta estructura permite analizar el comportamiento de reporte como una acción
# individual del usuario.

# Define el conjunto base de columnas que se conservarán para construir el dataset específico.
report_cols_result = [
    "result_id", "template_id", "user_id", "email", "first_name", "last_name",
    "position", "result_status", "reported", "template_subject", "template_text",
    "urgent_flag", "url_flag", "credentials_flag",
    "context_detected", "subcontext_detected", "message_type_detected",
    "text_level_detected", "intention_detected", "action_required_detected"
] + pattern_cols

# Define el conjunto base de columnas que se conservarán para construir el dataset específico.
report_cols_result = [c for c in report_cols_result if c in df_machine_learning.columns]

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_report_result = df_machine_learning[report_cols_result].copy()
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_report_result["reported_target"] = pd.to_numeric(
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
    df_report_result["reported"], errors="coerce"
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
).fillna(0).astype(int)

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_report_result["text_full"] = (
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_report_result["template_subject"].fillna("").astype(str).str.strip() + " " +
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_report_result["template_text"].fillna("").astype(str).str.strip()
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
).str.strip()

risk_merge_cols = ["template_id", "risk_score", "risk_target_rule", "risk_label_rule"]
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
```

```
df_report_result = df_report_result.merge(
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
    df_risk_rules[risk_merge_cols].drop_duplicates(subset=["template_id"]),
    on="template_id",
    how="left"
)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Shape df_report_result:", df_report_result.shape)
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(df_report_result["reported_target"].value_counts(dropna=False))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(df_report_result["reported_target"].value_counts(normalize=True, dropna=False))
```

Salida textual relevante:

```
Shape df_report_result: (10811, 33)
reported_target
0    10619
1      192
Name: count, dtype: int64
reported_target
0    0.98224
1    0.01776
Name: proportion, dtype: float64
```

Celda 22. 10. Modelo de reporte con regresion logistica

Aquí se prueba un primer modelo de reporte basado en regresión logística. Mezcla texto, variables numéricas y variables categóricas para predecir si un resultado fue reportado como phishing.

Conceptos y terminos clave

- Clasificación binaria: Problema de prediccion donde solo existen dos posibles salidas o clases.
- clase positiva rara: Clase de interes presente en pocos casos, lo que dificulta el entrenamiento y la evaluacion.
- precision: Porcentaje de predicciones positivas que realmente eran correctas; mide que tanto ruido hay en las alertas emitidas.
- recall: Porcentaje de casos positivos reales que el modelo logra recuperar; mide sensibilidad para no dejar casos sin detectar.
- F1-score: Media armonica entre precision y recall; resume el equilibrio entre ambas metricas en un solo valor.
- frontera lineal: Limite de decision trazado por un modelo lineal para separar clases en el espacio de variables.
- probabilidad estimada: Valor entre 0 y 1 que representa la confianza del modelo en que una observacion pertenezca a una clase.

El modelo lineal ofrece una línea base interpretable. Sin embargo, sus resultados revelan la dificultad del problema: al intentar capturar la clase minoritaria, sacrifica mucho rendimiento global y produce una separación limitada.

Contexto declarado en el notebook: 10. Modelo de reporte con regresion logistica Este primer modelo intenta predecir el reporte a nivel de resultado combinando: - texto del correo, - variables numericas, - variables categoricas, - y agrupacion por `template_id` en la particion train/test. El objetivo de esta fase es medir si existe señal suficiente para discriminar correos reportados frente a no reportados bajo un escenario altamente desbalanceado.

Codigo fuente analizado:

```
# ==============================================================================
# Modelo de reporte con regresión logística
# ==============================================================================
# Este bloque entrena el primer modelo de reporte a nivel resultado. Combina texto,
# variables numéricas y categóricas, y divide train/test agrupando por `template_id` para
```

```
# reducir fuga de información entre observaciones que comparten la misma plantilla.

num_cols_report = [
    "urgent_flag", "url_flag", "credentials_flag", "risk_score", "risk_target_rule",
    "pattern_urgency", "pattern_authority", "pattern_credentials", "pattern_threat",
    "pattern_validation", "pattern_incentive", "pattern_curiosity", "pattern_corporate_context"
]
num_cols_report = [c for c in num_cols_report if c in df_report_result.columns]

cat_cols_report = [
    "position", "result_status", "context_detected", "subcontext_detected",
    "message_type_detected", "text_level_detected", "intention_detected",
    "action_required_detected", "risk_label_rule"
]
cat_cols_report = [c for c in cat_cols_report if c in df_report_result.columns]

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for c in cat_cols_report:
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_report_result[c] = df_report_result[c].fillna("").astype(str).str.strip()

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for c in num_cols_report:
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    df_report_result[c] = pd.to_numeric(df_report_result[c], errors="coerce").fillna(0)

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
X_report = df_report_result[["text_full"] + num_cols_report + cat_cols_report].copy()
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_report = df_report_result["reported_target"].copy()
groups_report = df_report_result["template_id"]

# Define un preprocesador que aplica transformaciones distintas a texto, variables numéricas y categóricas.
preprocessor_report = ColumnTransformer([
# Configura la vectorización TF-IDF para transformar texto en representaciones numéricas.
    ("text", TfidfVectorizer(ngram_range=(1, 2), min_df=2), "text_full"),
    ("num", "passthrough", num_cols_report),
    ("cat", OneHotEncoder(handle_unknown="ignore"), cat_cols_report)
])

# Configura la estrategia de partición o validación del conjunto de datos.
gss = GroupShuffleSplit(n_splits=1, test_size=0.2, random_state=42)
train_idx, test_idx = next(gss.split(X_report, y_report, groups=groups_report))

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
X_train = X_report.iloc[train_idx]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
X_test = X_report.iloc[test_idx]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_train = y_report.iloc[train_idx]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_test = y_report.iloc[test_idx]

# Construye un pipeline de procesamiento y modelado para encapsular pasos repetibles.
model_report_result = Pipeline([
    ("prep", preprocessor_report),
# Inicializa un clasificador de regresión logística para la tarea supervisada correspondiente.
    ("clf", LogisticRegression(max_iter=2000, class_weight="balanced"))
```

```
])

# Entrena el modelo con los datos de entrenamiento.
model_report_result.fit(X_train, y_train)
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_pred_report_lr = model_report_result.predict(X_test)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(classification_report(y_test, y_pred_report_lr, zero_division=0))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Accuracy :", round(accuracy_score(y_test, y_pred_report_lr), 4))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Macro F1 :", round(f1_score(y_test, y_pred_report_lr, average="macro", zero_division=0), 4))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Weighted F1 :", round(f1_score(y_test, y_pred_report_lr, average="weighted", zero_division=0), 4))

# Calcula métricas de evaluación para medir el desempeño del modelo.
cm_report_lr = confusion_matrix(y_test, y_pred_report_lr, labels=[0, 1])
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_cm_report_lr = pd.DataFrame(
# Convierte la salida numérica a una estructura tabular para facilitar la interpretación.
    cm_report_lr,
    index=["Real_NoReportado", "Real_Reportado"],
    columns=["Pred_NoReportado", "Pred_Reportado"]
)
df_cm_report_lr
```

Salida textual relevante:

```
              precision    recall  f1-score   support

           0       0.98      0.62      0.76      2676
           1       0.02      0.36      0.03        50

    accuracy                           0.61      2726
   macro avg       0.50      0.49      0.39      2726
weighted avg       0.96      0.61      0.74      2726

Accuracy : 0.6104
Macro F1 : 0.3944
Weighted F1 : 0.7428
```

Tabla derivada / evidencia tabular:

Unnamed: 0	Pred_NoReportado	Pred_Reportado
Real_NoReportado	1646	1030
Real_Reportado	32	18

Celda 24. 11. Analisis de umbral de decision para la clase reportada

Este bloque estudia thresholds alternativos para la probabilidad de la clase reportada. En problemas desbalanceados, el umbral por defecto de 0.5 suele ser subóptimo; explorar distintos umbrales permite balancear precisión y recall según el objetivo operativo.

Conceptos y terminos clave

- Threshold: Umbral a partir del cual una probabilidad se convierte en decision de clase positiva.
- calibración de decisión: Ajuste del umbral o criterio de clasificacion para adaptarlo al costo operativo de errores.

- trade-off precisión-recall: Compensacion entre emitir menos falsos positivos y detectar mas casos verdaderos; mejorar uno suele afectar al otro.
- clase minoritaria: Clase con menos ejemplos dentro del conjunto de datos y que suele ser mas dificil de detectar correctamente.
- sensibilidad operativa: Capacidad practica del sistema para detectar eventos relevantes bajo condiciones reales de uso.

Desde una perspectiva de ciberseguridad, a menudo interesa elevar recall aunque baje precisión, porque perder eventos realmente reportables puede ser más costoso que revisar falsos positivos.

Contexto declarado en el notebook: 11. Analisis de umbral de decision para la clase reportada Dado el fuerte desbalance entre correos reportados y no reportados, se inspeccionan las probabilidades del modelo lineal con distintos umbrales. Esta fase permite observar el intercambio entre: - precision, - recall, - F1 de la clase positiva, - y volumen de positivos predichos.

Codigo fuente analizado:

```
# ==============================================================================
# Análisis de umbrales del modelo de reporte
# ==============================================================================
# Este bloque usa las probabilidades del modelo lineal para comparar distintos umbrales de
# decisión. Se calcula accuracy, precision, recall y F1 para la clase reportada, con el fin
# de inspeccionar la calibración del clasificador bajo desbalance severo.

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_prob_report = model_report_result.predict_proba(X_test)[:, 1]
# Define los umbrales que se compararán para analizar la calibración del clasificador.
thresholds = [0.10, 0.20, 0.30, 0.40, 0.50, 0.60, 0.70]

# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
rows_thresholds = []

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for thr in thresholds:
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
    y_pred_thr = (y_prob_report >= thr).astype(int)
# Inicializa contenedores para acumular resultados a lo largo del proceso de evaluación.
    rows_thresholds.append({
        "threshold": thr,
        "accuracy": accuracy_score(y_test, y_pred_thr),
        "precision_reported": precision_score(y_test, y_pred_thr, zero_division=0),
        "recall_reported": recall_score(y_test, y_pred_thr, zero_division=0),
        "f1_reported": f1_score(y_test, y_pred_thr, zero_division=0),
        "predicted_positives": int(y_pred_thr.sum())
    })

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_thresholds = pd.DataFrame(rows_thresholds)
df_thresholds
```

Tabla derivada / evidencia tabular:

Unnamed: 0	threshold	accuracy	precision_reported	recall_reported	f1_reported	predicted_positives
0.0	0.1	0.018342	0.018342	1.0	0.036023	2726.0
1.0	0.2	0.018342	0.018342	1.0	0.036023	2726.0
2.0	0.3	0.018342	0.018342	1.0	0.036023	2726.0

3.0	0.4	0.045488	0.018854	1.0	0.03701	2652.0
4.0	0.5	0.610418	0.017176	0.36	0.032787	1048.0
5.0	0.6	0.927733	0.019608	0.06	0.029557	153.0
6.0	0.7	0.981658	0.0	0.0	0.0	0.0

Celda 26. 12. Modelo de reporte tabular con Random Forest

Este es el modelo final para la tarea de reporte. Se reemplaza el componente textual por un Random Forest tabular para reducir ruido y aprovechar relaciones no lineales entre variables estructuradas.

Conceptos y terminos clave

- Random Forest: Metodo de ensamble que combina muchos arboles de decision entrenados sobre subconjuntos aleatorios para mejorar estabilidad y rendimiento.
- ensamble: Tecnica que combina varios modelos para obtener una prediccion final mas robusta que la de un solo modelo.
- árboles de decisión: Modelos que dividen los datos mediante reglas secuenciales hasta llegar a una prediccion en cada hoja.
- no linealidad: Capacidad de capturar relaciones complejas que no siguen una sola combinacion lineal de variables.
- importancia de variables: Medida de cuanto contribuye cada variable al poder predictivo del modelo.
- robustez tabular: Buen comportamiento de un algoritmo ante datos estructurados con mezcla de variables y cierto nivel de ruido.

La mejora de accuracy y Weighted F1 indica que el bosque captura mejor la estructura dominante de los datos. Sin embargo, el Macro F1 sigue siendo modesto, lo que evidencia que la clase positiva rara continúa siendo el cuello de botella real.

Contexto declarado en el notebook: 12. Modelo de reporte tabular con Random Forest Este bloque representa la version final de la tarea de reporte. Se elimina el texto para reducir ruido de alta dimensionalidad y se emplea un modelo de bosques aleatorios sobre variables estructuradas: - banderas tecnicas, - patrones de ingenieria social, - riesgo derivado, - cargo, - estado del correo, - contexto e intencion. El objetivo es evaluar si una estructura no lineal mejora la discriminacion de la clase positiva.

Codigo fuente analizado:

```
# ==============================================================================
# Modelo de reporte con Random Forest
# ==============================================================================
# Este bloque construye un modelo tabular de reporte usando Random Forest y solamente
# variables estructuradas. La intención es reducir el ruido del texto y observar si una
# estructura no lineal mejora la discriminación de la clase positiva.

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_report_rf = df_report_result.copy()

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
X_rf = df_report_rf[num_cols_report + [c for c in cat_cols_report if c != "risk_label_rule"] + ["risk_label_rule"]].copy()
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_rf = df_report_rf["reported_target"].copy()
groups_rf = df_report_rf["template_id"]

# Define un preprocesador que aplica transformaciones distintas a texto, variables numéricas y categóricas.
preprocessor_rf = ColumnTransformer([
    ("num", "passthrough", num_cols_report),
    ("cat", OneHotEncoder(handle_unknown="ignore"), [c for c in X_rf.columns if c not in num_cols_report])
```

```
])

# Configura la estrategia de partición o validación del conjunto de datos.
gss = GroupShuffleSplit(n_splits=1, test_size=0.2, random_state=42)
train_idx_rf, test_idx_rf = next(gss.split(X_rf, y_rf, groups=groups_rf))

# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
X_train_rf = X_rf.iloc[train_idx_rf]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
X_test_rf = X_rf.iloc[test_idx_rf]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_train_rf = y_rf.iloc[train_idx_rf]
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_test_rf = y_rf.iloc[test_idx_rf]

# Construye un pipeline de procesamiento y modelado para encapsular pasos repetibles.
model_report_rf = Pipeline([
    ("prep", preprocessor_rf),
# Inicializa un modelo Random Forest para capturar relaciones no lineales entre variables.
    ("clf", RandomForestClassifier(
        n_estimators=300,
        max_depth=None,
        min_samples_leaf=5,
        class_weight="balanced_subsample",
        random_state=42,
        n_jobs=-1
    ))
])

# Entrena el modelo con los datos de entrenamiento.
model_report_rf.fit(X_train_rf, y_train_rf)
# Define variables de entrada o salida para el proceso de entrenamiento y evaluación.
y_pred_report_rf = model_report_rf.predict(X_test_rf)

# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print(classification_report(y_test_rf, y_pred_report_rf, zero_division=0))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Accuracy :", round(accuracy_score(y_test_rf, y_pred_report_rf), 4))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Macro F1 :", round(f1_score(y_test_rf, y_pred_report_rf, average="macro", zero_division=0), 4))
# Muestra en pantalla un resultado intermedio útil para verificar el comportamiento del bloque.
print("Weighted F1 :", round(f1_score(y_test_rf, y_pred_report_rf, average="weighted", zero_division=0), 4))

# Calcula métricas de evaluación para medir el desempeño del modelo.
cm_report_rf = confusion_matrix(y_test_rf, y_pred_report_rf, labels=[0, 1])
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_cm_report_rf = pd.DataFrame(
# Convierte la salida numérica a una estructura tabular para facilitar la interpretación.
    cm_report_rf,
    index=["Real_NoReportado", "Real_Reportado"],
    columns=["Pred_NoReportado", "Pred_Reportado"]
)
df_cm_report_rf
```

Salida textual relevante:

```
              precision    recall  f1-score   support

           0       0.98      0.89      0.93      2676
```

```
           1       0.01      0.08      0.02        50

    accuracy                           0.87      2726
   macro avg       0.50      0.48      0.48      2726
weighted avg       0.96      0.87      0.92      2726

Accuracy : 0.8734
Macro F1 : 0.4775
Weighted F1 : 0.9157
```

Tabla derivada / evidencia tabular:

Unnamed: 0	Pred_NoReportado	Pred_Reportado
Real_NoReportado	2377	299
Real_Reportado	46	4

Celda 29. Grafica 1. Comparacion de accuracy entre modelos

La primera gráfica comparativa resume accuracy entre tres componentes del sistema: patrones, riesgo derivado y reporte RF. Funciona como vista ejecutiva de desempeño.

Conceptos y terminos clave

- accuracy: Proporcion total de aciertos del modelo sobre todas las observaciones evaluadas.
- comparación transversal de modelos: Analisis comparativo entre varios algoritmos usando las mismas metricas y el mismo dataset.
- indicador global: Metrica resumida que ofrece una vision general del desempeño total.

Aunque el Reporte RF lidera en accuracy, esto no implica automáticamente mejor equilibrio entre clases; por eso el notebook también presenta Macro F1 y Weighted F1.

Contexto declarado en el notebook: Grafica 1. Comparacion de accuracy entre modelos Esta visualizacion resume el desempeno general de tres componentes representativos del analisis: - deteccion de patrones, - clasificacion de riesgo, - prediccion de reporte con Random Forest.

Codigo fuente analizado:

```
# ==============================================================================
# Gráfica comparativa de accuracy
# ==============================================================================
# Este bloque arma una tabla de métricas resumidas y genera una gráfica de barras comparando
# el accuracy de los modelos principales del estudio.

# Calcula las métricas de un patrón representativo utilizando la etiqueta de urgencia.
pattern_accuracy = accuracy_score(y_true_patterns[:, 0], y_pred_patterns[:, 0])
# Calcula el Macro F1 del patrón representativo.
pattern_macro_f1 = f1_score(y_true_patterns[:, 0], y_pred_patterns[:, 0], average="macro", zero_division=0)
# Calcula el Weighted F1 del patrón representativo.
pattern_weighted_f1 = f1_score(y_true_patterns[:, 0], y_pred_patterns[:, 0], average="weighted", zero_division=0)

# Calcula el accuracy del modelo de riesgo derivado.
risk_accuracy = accuracy_score(y_true_risk, y_pred_risk)
# Calcula el Macro F1 del modelo de riesgo derivado.
risk_macro_f1 = f1_score(y_true_risk, y_pred_risk, average="macro", zero_division=0)
# Calcula el Weighted F1 del modelo de riesgo derivado.
risk_weighted_f1 = f1_score(y_true_risk, y_pred_risk, average="weighted", zero_division=0)

# Calcula el accuracy del modelo final de reporte con Random Forest.
```

```python
report_rf_accuracy = accuracy_score(y_test_rf, y_pred_report_rf)
# Calcula el Macro F1 del modelo final de reporte con Random Forest.
report_rf_macro_f1 = f1_score(y_test_rf, y_pred_report_rf, average="macro", zero_division=0)
# Calcula el Weighted F1 del modelo final de reporte con Random Forest.
report_rf_weighted_f1 = f1_score(y_test_rf, y_pred_report_rf, average="weighted", zero_division=0)

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_model_metrics = pd.DataFrame({
    "modelo": ["Patrones - Urgencia", "Riesgo derivado", "Reporte RF"],
    "accuracy": [pattern_accuracy, risk_accuracy, report_rf_accuracy],
    "macro_f1": [pattern_macro_f1, risk_macro_f1, report_rf_macro_f1],
    "weighted_f1": [pattern_weighted_f1, risk_weighted_f1, report_rf_weighted_f1]
})

# Muestra la tabla resumida de métricas para dejar evidencia reproducible.
print(df_model_metrics)

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(10, 5))
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.bar(df_model_metrics["modelo"], df_model_metrics["accuracy"])
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.title("Comparacion de Accuracy entre modelos")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Modelo")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Accuracy")
plt.xticks(rotation=25, ha="right")
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for i, v in enumerate(df_model_metrics["accuracy"]):
    plt.text(i, v + 0.01, f"{v:.2f}", ha="center")
plt.tight_layout()
# Renderiza la figura para mostrarla en la salida de Jupyter.
plt.show()
```

Salida textual relevante:

```
                modelo  accuracy  macro_f1  weighted_f1
0  Patrones - Urgencia  0.769231  0.763636     0.772028
1      Riesgo derivado  0.769231  0.704365     0.772894
2           Reporte RF  0.873441  0.477501     0.915654
```

Visual de salida asociado a la celda:

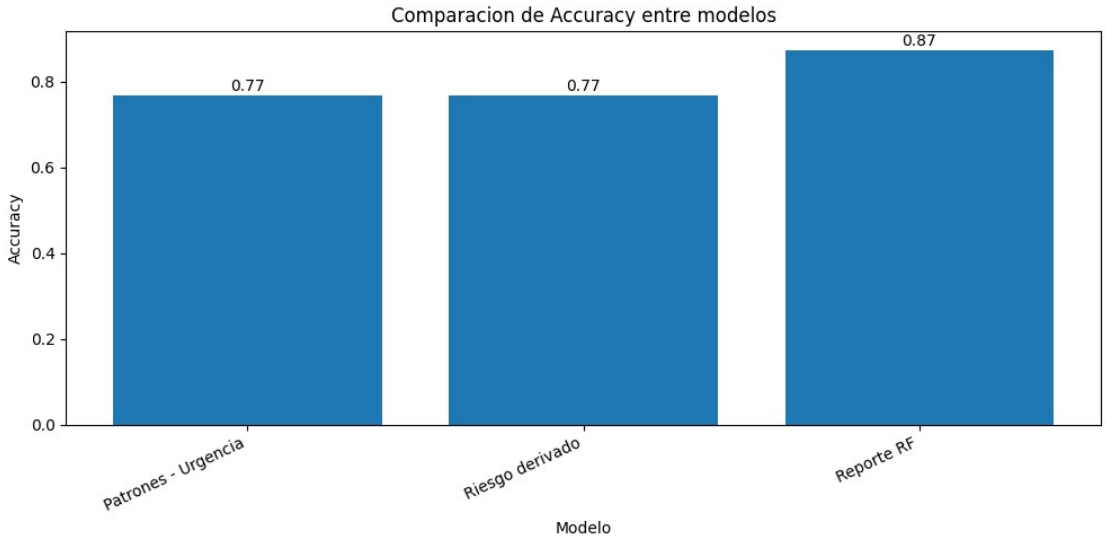

Celda 31. Grafica 2. Comparacion de Macro F1 entre modelos

La gráfica de Macro F1 compara la calidad promedio por clase sin favorecer a la clase mayoritaria.

Conceptos y terminos clave

- Macro F1: Promedio simple del F1 de cada clase; da el mismo peso a todas, incluso a las minoritarias.
- promedio no ponderado: Media que trata todas las clases por igual sin considerar cuantas observaciones tenga cada una.
- equilibrio por clase: Enfoque de evaluacion que evita que una clase muy frecuente domine la interpretacion del rendimiento.

Es la métrica más honesta cuando existe desbalance, pues penaliza modelos que solo aprenden la clase dominante.

Contexto declarado en el notebook: Grafica 2. Comparacion de Macro F1 entre modelos El Macro F1 resulta especialmente util cuando existe desbalance entre clases, ya que evalua el desempeno promedio sin favorecer a la clase mayoritaria.

Codigo fuente analizado:

```
# ==============================================================================
# Gráfica comparativa de Macro F1
# ==============================================================================
# Este bloque visualiza el Macro F1 de los modelos para destacar el desempeño promedio entre
# clases sin favorecer a la clase mayoritaria.

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(10, 5))
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.bar(df_model_metrics["modelo"], df_model_metrics["macro_f1"])
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.title("Comparacion de Macro F1 entre modelos")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Modelo")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Macro F1")
plt.xticks(rotation=25, ha="right")
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for i, v in enumerate(df_model_metrics["macro_f1"]):
    plt.text(i, v + 0.01, f"{v:.2f}", ha="center")
plt.tight_layout()
```

```
# Renderiza la figura para mostrarla en la salida del notebook.
plt.show()
```

Visual de salida asociado a la celda:

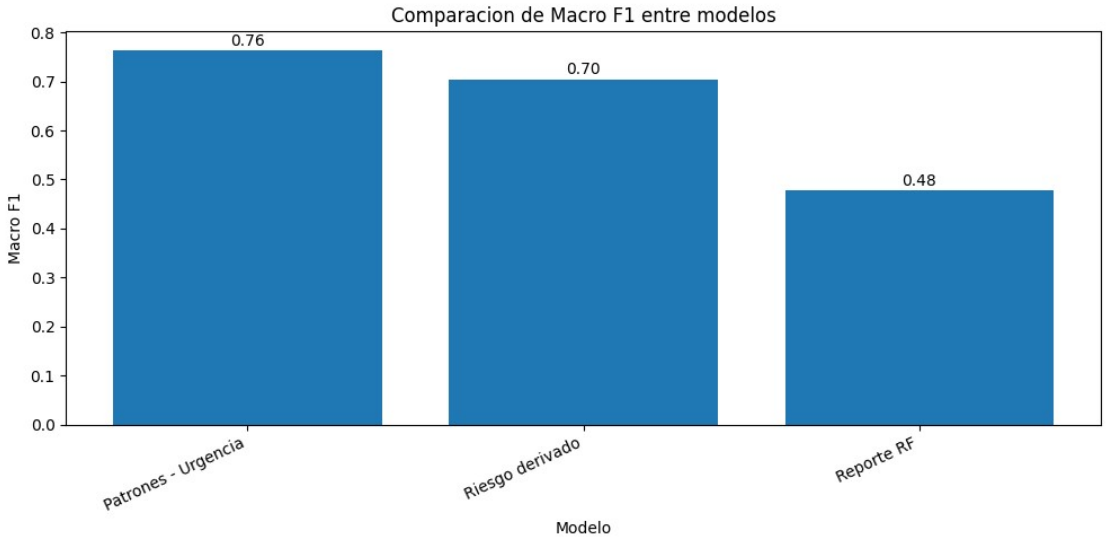

Celda 33. Grafica 3. Comparacion de Weighted F1 entre modelos

La gráfica de Weighted F1 incorpora el soporte de cada clase y ayuda a contextualizar el peso de la clase mayoritaria.

Conceptos y terminos clave

- Weighted F1: Promedio del F1 ponderado por el numero de ejemplos de cada clase, por lo que refleja mejor la distribucion real del dataset.
- soporte: Cantidad de ejemplos reales pertenecientes a una clase dentro del conjunto evaluado.
- ponderación por frecuencia: Asignacion de mayor peso a las clases con mas ejemplos al calcular una metrica agregada.

Complementa Macro F1: un valor alto aquí puede coexistir con un desempeño pobre en la clase minoritaria.

Contexto declarado en el notebook: Grafica 3. Comparacion de Weighted F1 entre modelos El Weighted F1 pondera el rendimiento por frecuencia de clase y ayuda a contextualizar el efecto del desbalance sobre los clasificadores.

Codigo fuente analizado:

```
# ==============================================================================
# Gráfica comparativa de Weighted F1
# ==============================================================================
# Este bloque genera una comparación del Weighted F1, útil para observar el desempeño
# ponderado por frecuencia de clase en escenarios desbalanceados.

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(10, 5))
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.bar(df_model_metrics["modelo"], df_model_metrics["weighted_f1"])
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.title("Comparacion de Weighted F1 entre modelos")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Modelo")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Weighted F1")
plt.xticks(rotation=25, ha="right")
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
```

```
for i, v in enumerate(df_model_metrics["weighted_f1"]):
    plt.text(i, v + 0.01, f"{v:.2f}", ha="center")
plt.tight_layout()
# Renderiza la figura para mostrarla en la salida del notebook.
plt.show()
```

Visual de salida asociado a la celda:

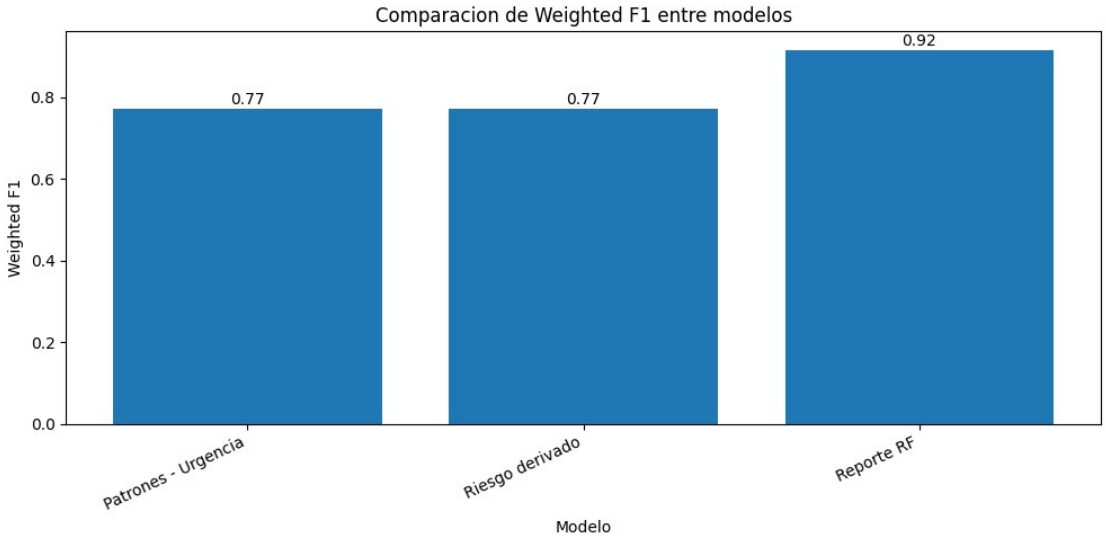

Celda 35. Grafica 4. Distribucion final de patrones de ingenieria social

La distribución de patrones por plantilla muestra cuántas plantillas activan cada patrón de ingeniería social.

Conceptos y terminos clave

- frecuencia de patrones: Numero de veces que aparecen determinados patrones o categorias dentro del corpus.
- cobertura semántica: Amplitud con la que las etiquetas o categorias logran representar el significado presente en los textos.
- prevalencia: Proporcion con la que una condicion o clase aparece en la poblacion analizada.

Sirve para entender qué tipos de manipulación son más comunes en el corpus y cuáles están subrepresentados.

Contexto declarado en el notebook: Grafica 4. Distribucion final de patrones de ingenieria social Esta figura resume cuantos templates activaron cada patron despues del proceso de depuracion semantica y balanceo de reglas.

Codigo fuente analizado:

```
# ==============================================================================
# Distribución de patrones por plantilla
# ==============================================================================
# Este bloque resume cuántas plantillas activaron cada patrón de ingeniería social y lo
# presenta en una gráfica de barras.

pattern_summary = pd.DataFrame({
    "pattern": pattern_cols,
    "positives": [df_templates_final[c].sum() for c in pattern_cols]
}).sort_values("positives", ascending=False)

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(10, 5))
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.bar(pattern_summary["pattern"], pattern_summary["positives"])
# Configura metadatos de la gráfica para hacerla legible e interpretable.
```

```
plt.title("Distribucion de patrones de ingenieria social por plantilla")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Patron")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Cantidad de templates positivos")
plt.xticks(rotation=30, ha="right")
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for i, v in enumerate(pattern_summary["positives"]):
    plt.text(i, v + 0.1, f"{int(v)}", ha="center")
plt.tight_layout()
# Renderiza la figura para mostrarla en la salida del notebook.
plt.show()
```

Visual de salida asociado a la celda:

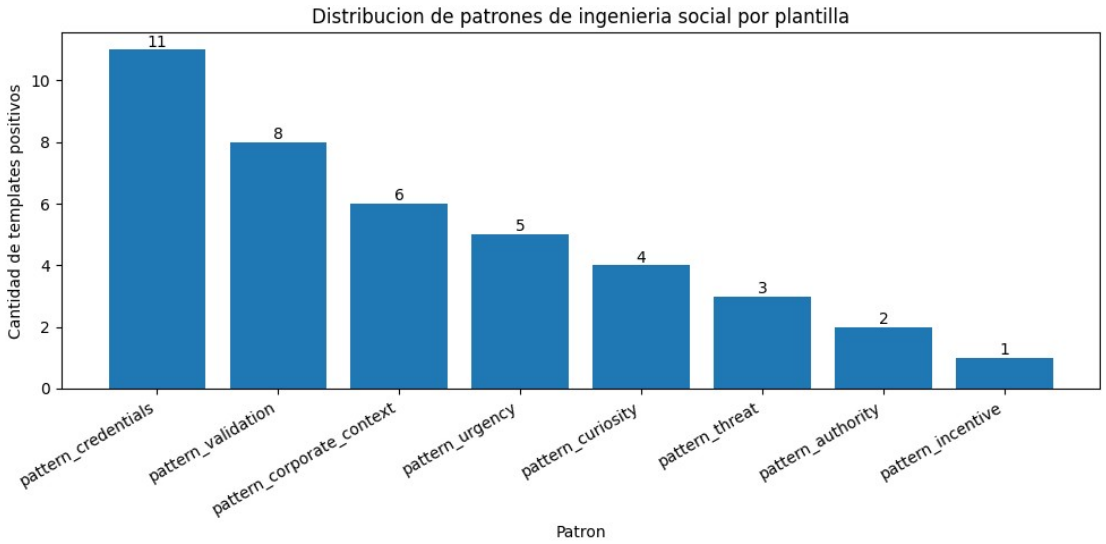

Celda 37. Grafica 5. Matriz de confusion del modelo de riesgo derivado

La matriz de confusión del riesgo derivado muestra aciertos y errores por clase Bajo, Medio y Alto.

Conceptos y terminos clave

- matriz de confusión: Tabla que compara clases reales contra clases predichas para visualizar aciertos y tipos de error del modelo.
- errores de confusión interclase: Equivocaciones en las que una clase se predice como otra, mostrando donde el modelo confunde categorias.
- verdaderos positivos por clase: Casos correctamente identificados dentro de cada clase especifica.

Permite ver no solo cuánto acierta el modelo, sino dónde falla: por ejemplo, si confunde riesgo medio con alto, o si colapsa hacia la clase dominante.

Contexto declarado en el notebook: Grafica 5. Matriz de confusion del modelo de riesgo derivado La matriz muestra la capacidad del modelo para discriminar entre riesgo bajo, medio y alto a partir de texto, patrones y banderas tecnicas.

Codigo fuente analizado:

```
# ==============================================================================
# Matriz de confusión del riesgo
# ==============================================================================
# Este bloque representa visualmente la matriz de confusión del modelo de riesgo derivado.

# Crea una nueva figura de matplotlib para la visualización.
```

```
plt.figure(figsize=(6, 5))
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.imshow(cm_risk, interpolation="nearest")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.title("Matriz de confusion - Riesgo derivado")
plt.colorbar()
plt.xticks(np.arange(3), ["Bajo", "Medio", "Alto"])
plt.yticks(np.arange(3), ["Bajo", "Medio", "Alto"])
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Prediccion")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Valor real")

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for i in range(cm_risk.shape[0]):
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
    for j in range(cm_risk.shape[1]):
        plt.text(j, i, str(cm_risk[i, j]), ha="center", va="center")

plt.tight_layout()
# Renderiza la figura para mostrarla en la salida del notebook.
plt.show()
```

Visual de salida asociado a la celda:

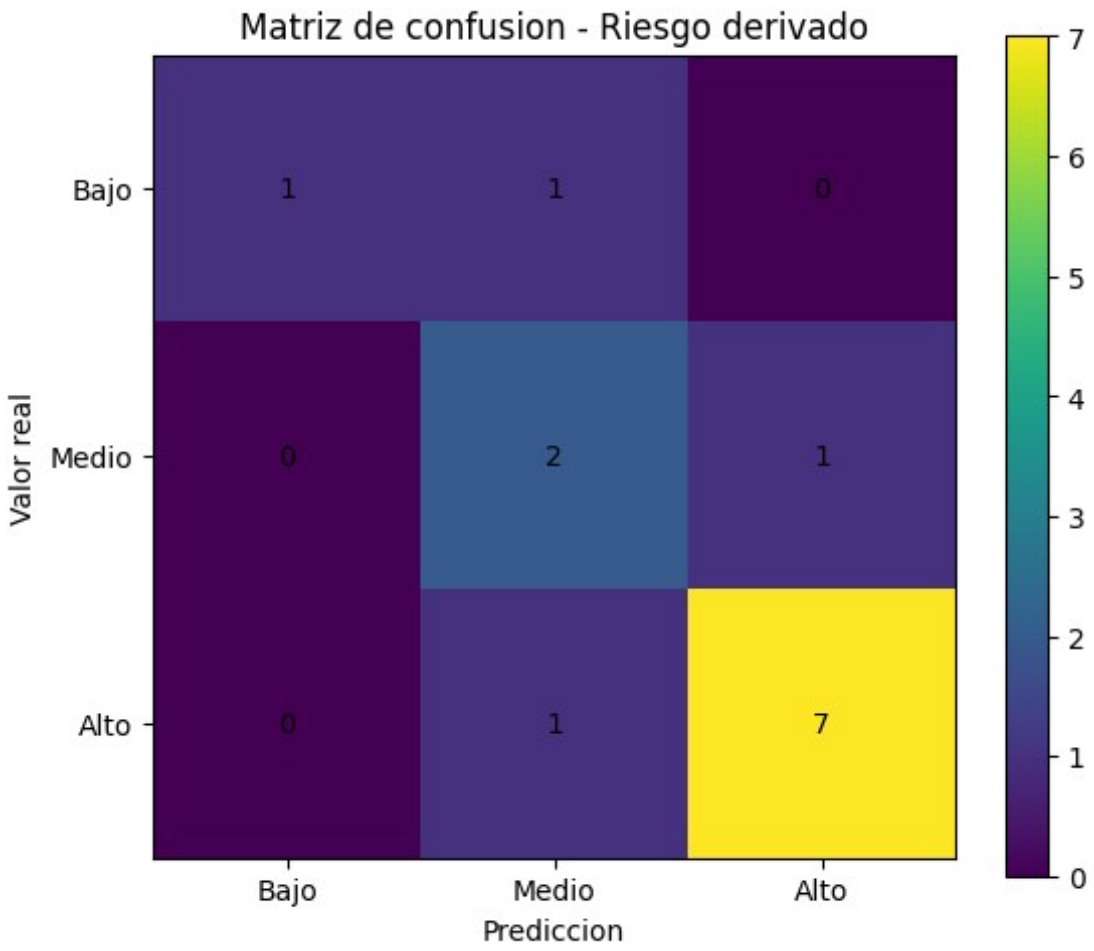

Celda 39. Grafica 6. Matriz de confusion del modelo de reporte con Random Forest

La matriz de confusión del reporte con Random Forest ilustra la capacidad real del modelo final para distinguir resultados reportados y no reportados.

Conceptos y terminos clave

- verdaderos negativos: Casos negativos que el modelo tambien clasifica correctamente como negativos.
- falsos positivos: Casos que el modelo marca como positivos aunque en realidad no lo eran.
- falsos negativos: Casos positivos reales que el modelo no detecta y clasifica como negativos.
- recall minoritario: Recall calculado para la clase menos frecuente, clave cuando esa clase tiene alta prioridad analitica.

La gran masa de no reportados domina la matriz; por eso debe leerse junto con precision, recall y F1 de la clase positiva.

Contexto declarado en el notebook: Grafica 6. Matriz de confusion del modelo de reporte con Random Forest Esta matriz representa el comportamiento final del mejor modelo obtenido para la tarea de reporte de correos.

Codigo fuente analizado:

```
# ==============================================================================
# Matriz de confusión del reporte con Random Forest
# ==============================================================================
# Este bloque representa visualmente la matriz de confusión del mejor modelo final de
# reporte.

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(6, 5))
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.imshow(cm_report_rf, interpolation="nearest")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.title("Matriz de confusion - Reporte (Random Forest)")
plt.colorbar()
plt.xticks(np.arange(2), ["No reportado", "Reportado"])
plt.yticks(np.arange(2), ["No reportado", "Reportado"])
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Prediccion")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Valor real")

# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for i in range(cm_report_rf.shape[0]):
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
    for j in range(cm_report_rf.shape[1]):
        plt.text(j, i, str(cm_report_rf[i, j]), ha="center", va="center")

plt.tight_layout()
# Renderiza la figura para mostrarla en la salida del notebook.
plt.show()
```

Visual de salida asociado a la celda:

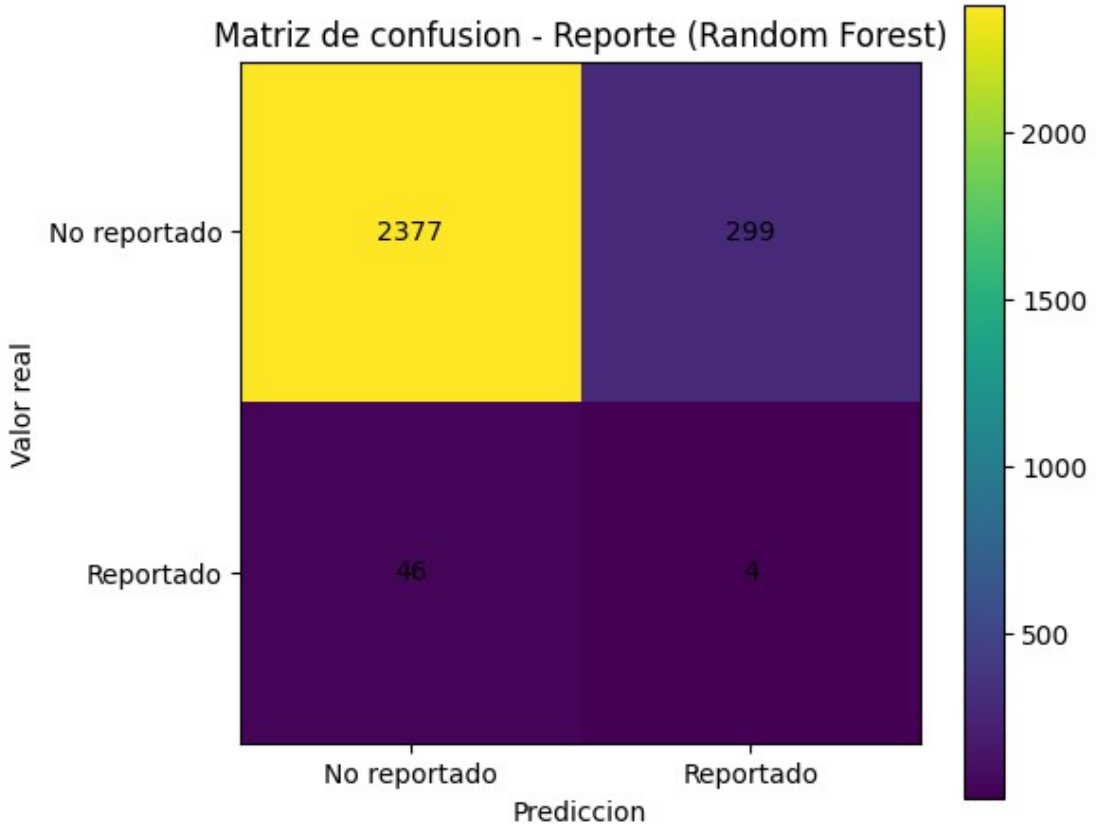

Celda 41. Grafica 7. Analisis de thresholds en el modelo lineal de reporte

La curva de thresholds grafica cómo cambian accuracy, precision, recall y F1 al mover el umbral.

Conceptos y terminos clave

- curva de decisión: Representacion del comportamiento del modelo cuando cambia el umbral de clasificacion o la regla de decision.
- sensibilidad: Sinonimo operativo de recall; expresa la capacidad de detectar casos positivos reales.
- especificidad práctica: Capacidad de evitar falsas alarmas en un contexto de uso real, cercana al concepto de especificidad aplicado operacionalmente.
- ajuste operativo: Modificacion del sistema para alinearlo con necesidades practicas, costos de error y prioridades del proyecto.

Es una herramienta de diseño operacional: ayuda a decidir en qué punto conviene desplegar el modelo según el costo de errores.

Contexto declarado en el notebook: Grafica 7. Analisis de thresholds en el modelo lineal de reporte Esta curva compara el efecto de diferentes umbrales sobre accuracy, precision, recall y F1 de la clase reportada, permitiendo evaluar la calibracion del clasificador.

Codigo fuente analizado:

```
# ==============================================================================
# Comparación de métricas por threshold
# ==============================================================================
# Este bloque grafica cómo cambian accuracy, precision, recall y F1 al modificar el umbral
# del modelo lineal de reporte.

# Crea una nueva figura de matplotlib para la visualización.
```

```
plt.figure(figsize=(10, 5))
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.plot(df_thresholds["threshold"], df_thresholds["accuracy"], marker="o", label="Accuracy")
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.plot(df_thresholds["threshold"], df_thresholds["precision_reported"], marker="o", label="Precision Reportado")
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.plot(df_thresholds["threshold"], df_thresholds["recall_reported"], marker="o", label="Recall Reportado")
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.plot(df_thresholds["threshold"], df_thresholds["f1_reported"], marker="o", label="F1 Reportado")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.title("Comparacion de metricas por threshold - Reporte")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Threshold")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Valor")
plt.legend()
plt.tight_layout()
# Renderiza la figura para mostrarla en la salida del notebook.
plt.show()
```

Visual de salida asociado a la celda:

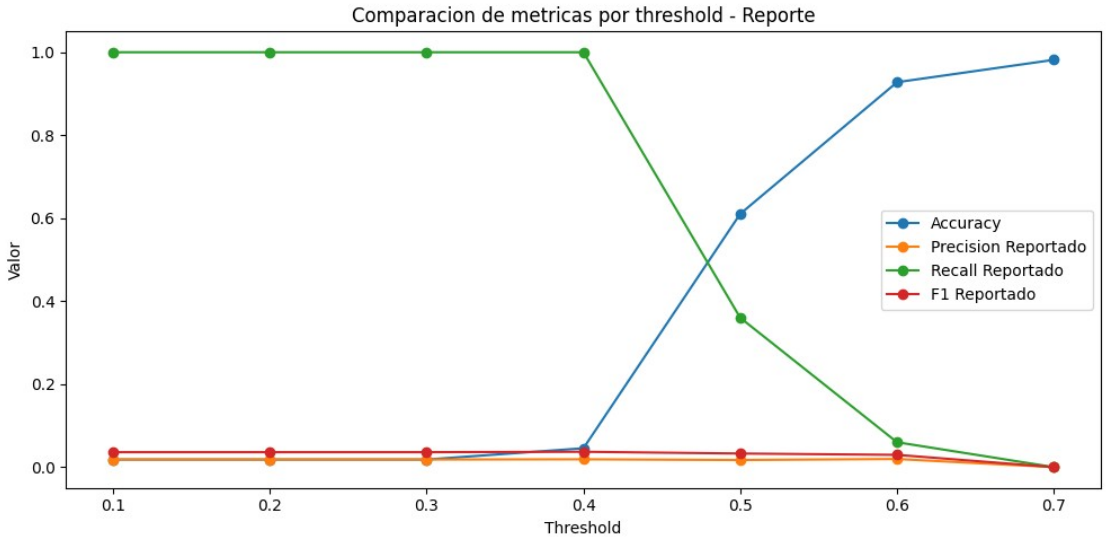

Celda 43. Grafica 8. Distribucion del riesgo derivado por plantilla

La distribución del riesgo derivado por plantilla resume la salida de las reglas de scoring.

Conceptos y terminos clave

- riesgo bajo/medio/alto: Escala ordinal usada para resumir el nivel de riesgo estimado o derivado en tres categorias comprensibles.
- scoring agregado: Puntaje final obtenido al combinar varias señales parciales en una sola medida de riesgo.
- histograma categórico: Grafico de barras que muestra la distribucion de frecuencias en categorias discretas.

Valida visualmente que el riesgo derivado sí tiene variabilidad útil para modelado.

Contexto declarado en el notebook: Grafica 8. Distribucion del riesgo derivado por plantilla Esta figura resume la cantidad de plantillas clasificadas en riesgo bajo, medio y alto segun la puntuacion derivada definida en el cuaderno.

Codigo fuente analizado:

```
# ==========================================================================
# Distribución del riesgo derivado
```

```
# ==============================================================================
# Este bloque resume la cantidad de plantillas clasificadas en Bajo, Medio y Alto según el
# riesgo derivado.

risk_dist = (
    df_risk_rules["risk_label_rule"]
    .value_counts()
    .reindex(["Bajo", "Medio", "Alto"], fill_value=0)
)

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(7, 5))
# Dibuja el elemento principal de la gráfica según el tipo de visualización requerido.
plt.bar(risk_dist.index, risk_dist.values)
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.title("Distribucion del riesgo derivado por plantilla")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Nivel de riesgo")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Cantidad de templates")
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for i, v in enumerate(risk_dist.values):
    plt.text(i, v + 0.1, str(int(v)), ha="center")
plt.tight_layout()
# Renderiza la figura para mostrarla en la salida del notebook.
plt.show()
```

Visual de salida asociado a la celda:

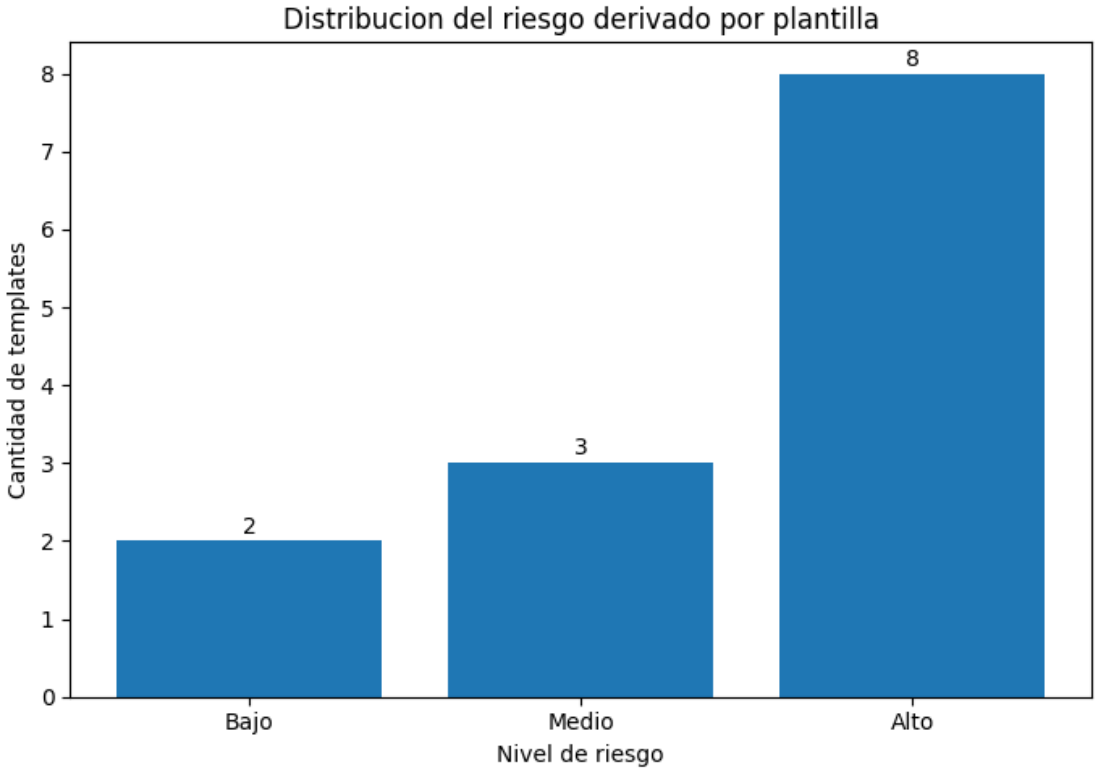

Celda 45. Grafica 9. Tasa de reporte observada por plantilla

La tasa de reporte observada por plantilla permite contrastar la reacción empírica de usuarios entre campañas o plantillas.

Conceptos y terminos clave

- tasa observada: Proporcion empirica calculada directamente a partir de los datos registrados.
- proporción empírica: Medida basada en conteos reales del dataset y no en supuestos teoricos.
- comportamiento por plantilla: Analisis que compara resultados segun la plantilla de correo utilizada.

Esta lectura es importante porque el reporte no depende solo del texto, sino del contexto y de variables humanas no totalmente observadas.

Contexto declarado en el notebook: Grafica 9. Tasa de reporte observada por plantilla La ultima visualizacion permite contrastar la frecuencia empirica de reporte por `template_id`, lo que ayuda a contextualizar la dificultad del problema conductual.

Codigo fuente analizado:

```
# ==============================================================================
# Tasa de reporte por plantilla
# ==============================================================================
# Este bloque calcula y grafica la proporción observada de reportes por `template_id`,
# permitiendo comparar el comportamiento empírico entre plantillas.

# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
df_report_by_template = (
# Crea o actualiza un DataFrame que será utilizado en la siguiente etapa del flujo.
    df_report_result.groupby(["template_id", "template_subject"], as_index=False)["reported_target"]
    .mean()
    .rename(columns={"reported_target": "reported_rate"})
    .sort_values("reported_rate", ascending=False)
)

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(11, 5))
# Normaliza o convierte el tipo de los datos para asegurar consistencia en el análisis.
plt.bar(df_report_by_template["template_id"].astype(str), df_report_by_template["reported_rate"])
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.title("Tasa de reporte observada por plantilla")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.xlabel("Template ID")
# Configura metadatos de la gráfica para hacerla legible e interpretable.
plt.ylabel("Proporcion reportada")
# Inicia un bucle para recorrer elementos y aplicar una transformación o cálculo repetitivo.
for i, v in enumerate(df_report_by_template["reported_rate"]):
    plt.text(i, v + 0.0005, f"{v:.3f}", ha="center", fontsize=8)
plt.tight_layout()
# Renderiza la figura para mostrarla en la salida del notebook.
plt.show()
```

Visual de salida asociado a la celda:

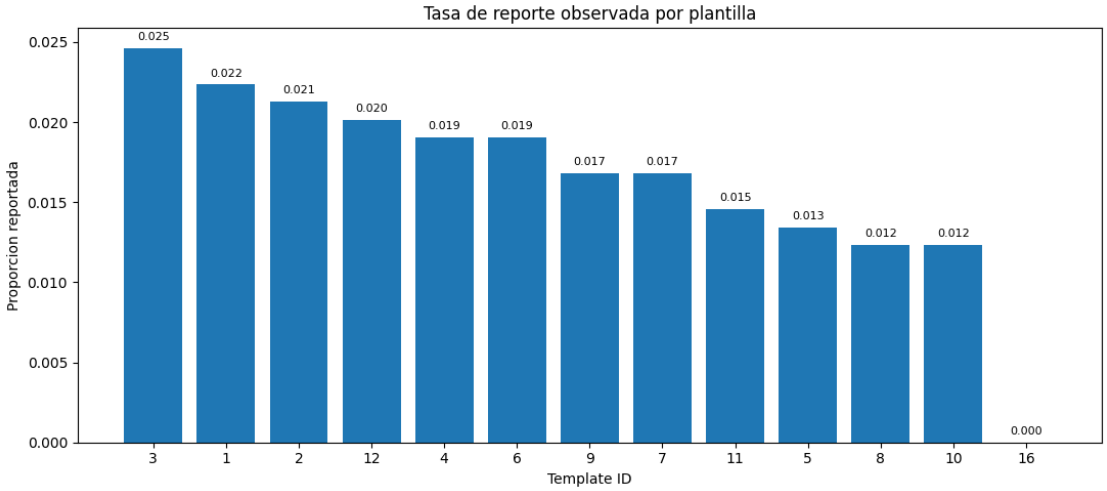

Celda 48. Grafica 10. Regresión logística binaria aplicada al reporte de correos

La gráfica conceptual de regresión logística binaria para reporte utiliza probabilidades reales estimadas del modelo lineal.

Conceptos y terminos clave

- log-odds: Escala logaritmica de razones de probabilidad usada internamente por la regresion logistica antes de convertirse en probabilidades.
- probabilidad estimada: Valor entre 0 y 1 que representa la confianza del modelo en que una observacion pertenezca a una clase.
- frontera lineal: Limite de decision trazado por un modelo lineal para separar clases en el espacio de variables.

Su aporte no es mostrar una línea recta, sino la estructura probabilística con la que el modelo separa reportado y no reportado.

Contexto declarado en el notebook: Grafica 10. Regresión logística binaria aplicada al reporte de correos Esta visualización usa las probabilidades reales estimadas por el modelo lineal de reporte para la clase positiva (`reported_target = 1`). El objetivo es mostrar cómo la regresión logística distribuyó su confianza sobre los correos evaluados y por qué la calibración del umbral fue una etapa necesaria dentro del análisis.

Codigo fuente analizado:

```
# ==============================================================================
# Regresión logística binaria para reporte - probabilidades reales estimadas
# ==============================================================================
# Este bloque toma las probabilidades reales generadas por el modelo de regresión
# logística para la clase positiva y las ordena para observar su comportamiento
# sobre el conjunto de prueba.
#
# Se usa información real del proyecto:
# - y_prob_report: probabilidad estimada de reporte
# - y_test: clase real observada en el conjunto de evaluación

# Convierte las estructuras a arreglos numéricos para asegurar consistencia.
y_prob_report_arr = np.asarray(y_prob_report, dtype=float)
y_test_arr = np.asarray(y_test, dtype=int)

# Ordena las probabilidades de menor a mayor para facilitar la lectura visual.
order_prob = np.argsort(y_prob_report_arr)
```

```
y_prob_sorted = y_prob_report_arr[order_prob]
y_test_sorted = y_test_arr[order_prob]

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(10, 5))
# Dibuja la curva de probabilidades ordenadas generadas por la regresión logística.
plt.plot(range(len(y_prob_sorted)), y_prob_sorted)
# Señala el umbral de decisión clásico de 0.5 usado en clasificación binaria.
plt.axhline(0.5)
# Superpone los casos reales reportados para mostrar dónde cae la clase positiva.
positive_idx = np.where(y_test_sorted == 1)[0]
plt.scatter(positive_idx, y_prob_sorted[positive_idx])

# Coloca título y etiquetas descriptivas.
plt.title("Regresión logística binaria - Probabilidades reales de reporte")
plt.xlabel("Observaciones ordenadas por probabilidad")
plt.ylabel("Probabilidad estimada de reporte")
plt.tight_layout()
plt.show()
```

Visual de salida asociado a la celda:

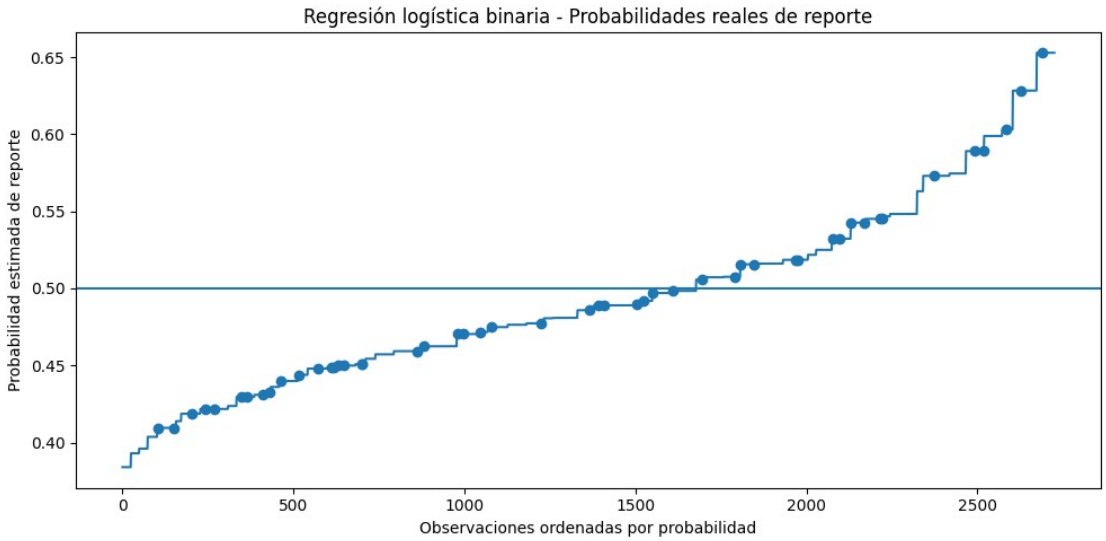

Celda 50. Grafica 11. OneVsRest + regresión logística para patrones de ingeniería social

La gráfica de OneVsRest + regresión logística presenta el rendimiento real por patrón de ingeniería social.

Conceptos y terminos clave

- One-vs-Rest: Enfoque que resuelve un problema de multiples clases entrenando un clasificador independiente para cada clase frente al resto.
- multietiqueta: Problema en el que una misma observacion puede pertenecer a varias etiquetas simultaneamente.
- métrica por etiqueta: Evaluacion calculada individualmente para cada etiqueta o clase en problemas multietiqueta o multiclase.

Es una vista granular del detector; muestra que algunos patrones son considerablemente más reconocibles que otros.

Contexto declarado en el notebook: Grafica 11. OneVsRest + regresión logística para patrones de ingeniería social Esta figura resume el rendimiento por etiqueta del clasificador multietiqueta utilizado para detectar patrones de ingeniería social. Cada barra representa el desempeño obtenido con datos reales de validación Leave-One-Out, mostrando cuáles patrones ofrecieron una señal más estable para el modelo.

Codigo fuente analizado:

```
# ==============================================================================
# OneVsRest + regresión logística - desempeño real por patrón
# ==============================================================================
# Este bloque calcula métricas reales por etiqueta usando las salidas del modelo
# multietiqueta ya evaluado previamente:
# - y_true_patterns: valores reales por patrón
# - y_pred_patterns: valores predichos por patrón
#
# El propósito es mostrar, de manera conceptual pero basada en resultados reales,
# cómo respondió el enfoque OneVsRest + regresión logística en cada etiqueta.

pattern_f1_scores = []
pattern_accuracy_scores = []

# Recorre cada patrón para calcular métricas individuales.
for i, col in enumerate(pattern_cols):
    f1_val = f1_score(y_true_patterns[:, i], y_pred_patterns[:, i], average="macro", zero_division=0)
    acc_val = accuracy_score(y_true_patterns[:, i], y_pred_patterns[:, i])

    pattern_f1_scores.append(f1_val)
    pattern_accuracy_scores.append(acc_val)

# Construye un DataFrame resumen para documentar el rendimiento por etiqueta.
df_pattern_model_metrics = pd.DataFrame({
    "pattern": pattern_cols,
    "macro_f1": pattern_f1_scores,
    "accuracy": pattern_accuracy_scores
}).sort_values("macro_f1", ascending=False)

# Muestra la tabla resumen como evidencia adicional del cálculo.
print(df_pattern_model_metrics)

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(10, 5))
# Dibuja barras con el Macro F1 real por patrón.
plt.bar(df_pattern_model_metrics["pattern"], df_pattern_model_metrics["macro_f1"])

# Añade título y etiquetas.
plt.title("OneVsRest + Regresión logística - Macro F1 real por patrón")
plt.xlabel("Patrón de ingeniería social")
plt.ylabel("Macro F1")
plt.xticks(rotation=30, ha="right")
plt.tight_layout()
plt.show()
```

Salida textual relevante:

```
                     pattern  macro_f1  accuracy
0            pattern_urgency  0.763636  0.769231
7  pattern_corporate_context  0.763636  0.769231
5          pattern_incentive  0.480000  0.923077
1          pattern_authority  0.458333  0.846154
2        pattern_credentials  0.458333  0.846154
3             pattern_threat  0.434783  0.769231
4         pattern_validation  0.380952  0.615385
6          pattern_curiosity  0.380952  0.615385
```

Visual de salida asociado a la celda:

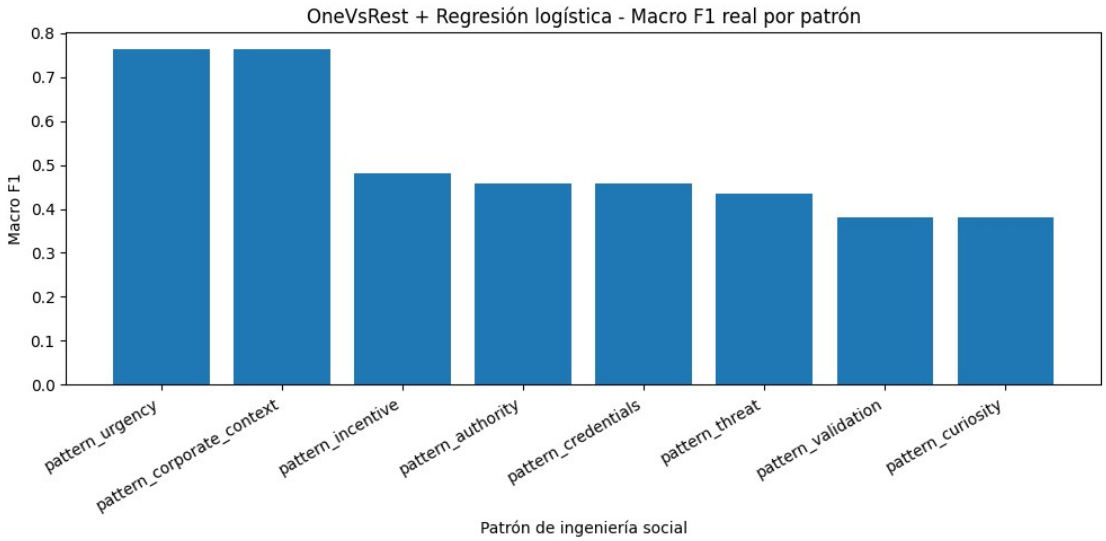

Celda 52. Grafica 12. Regresión logística multiclase aplicada al riesgo derivado

La visualización de regresión logística multiclase aplicada al riesgo muestra las variables estructuradas con mayor peso absoluto.

Conceptos y terminos clave

- coeficiente absoluto: Valor absoluto del coeficiente, empleado para ordenar variables por intensidad de influencia.
- influencia por clase: Impacto especifico que una variable tiene sobre la prediccion de una clase determinada.
- regresión logística multiclase: Extension de la regresion logistica para distinguir entre mas de dos clases posibles.

Aunque es una gráfica de barras, es correcta: el objetivo es exponer la magnitud del peso de cada variable, no representar una serie temporal ni una relación continua.

Contexto declarado en el notebook: Grafica 12. Regresión logística multiclase aplicada al riesgo derivado Esta visualización usa los coeficientes reales del modelo multiclase de riesgo para mostrar qué variables estructuradas tuvieron mayor peso absoluto dentro de la clasificación. La figura ayuda a interpretar qué señales del correo influyeron con mayor intensidad en la estimación de riesgo.

Codigo fuente analizado:

```
# ==============================================================================
# Regresión logística multiclase para riesgo - variables estructuradas más influyentes
# ==============================================================================
# Este bloque utiliza los coeficientes reales del modelo final de riesgo ya entrenado
# sobre todo el conjunto disponible.
#
# Se filtran solamente variables estructuradas:
# - numéricas (banderas y patrones)
# - categóricas codificadas
#
# El objetivo es ofrecer una vista conceptual del modelo, basada en información real
# de entrenamiento, resaltando qué variables tuvieron mayor peso absoluto.

# Reconstruye un DataFrame con coeficientes y nombres de características por clase.
df_risk_coef_all = []

for class_idx, class_label in class_map.items():
    temp = pd.DataFrame({
        "class": class_label,
```

```
        "feature": feature_names_risk,
        "coef": coef_matrix_risk[class_idx],
        "abs_coef": np.abs(coef_matrix_risk[class_idx])
    })
    df_risk_coef_all.append(temp)

df_risk_coef_all = pd.concat(df_risk_coef_all, ignore_index=True)

# Filtra únicamente variables estructuradas para evitar saturar la visualización con texto TF-IDF.
df_risk_structured = df_risk_coef_all[
    df_risk_coef_all["feature"].str.contains("num__|cat__", regex=True)
].copy()

# Selecciona las variables con mayor peso absoluto global.
df_risk_structured_top = (
    df_risk_structured
    .sort_values("abs_coef", ascending=False)
    .head(15)
)

# Muestra la tabla resultante como respaldo del cálculo.
print(df_risk_structured_top[["class", "feature", "coef", "abs_coef"]])

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(11, 6))
# Dibuja barras con las variables estructuradas más influyentes del modelo de riesgo.
plt.bar(df_risk_structured_top["feature"], df_risk_structured_top["abs_coef"])

# Añade título y etiquetas.
plt.title("Regresión logística multiclase - Variables estructuradas más influyentes")
plt.xlabel("Variable")
plt.ylabel("Magnitud absoluta del coeficiente")
plt.xticks(rotation=45, ha="right")
plt.tight_layout()
plt.show()
```

Salida textual relevante:

```
      class                          feature      coef  abs_coef
2542  Medio          num__pattern_curiosity  0.774465  0.774465
1258   Bajo        num__pattern_credentials -0.639996  0.639996
3823   Alto  num__pattern_corporate_context  0.600228  0.600228
1261   Bajo          num__pattern_incentive  0.498350  0.498350
3819   Alto             num__pattern_threat  0.487695  0.487695
3820   Alto         num__pattern_validation  0.419321  0.419321
3822   Alto          num__pattern_curiosity -0.406352  0.406352
1260   Bajo         num__pattern_validation -0.387447  0.387447
2539  Medio             num__pattern_threat -0.378256  0.378256
1262   Bajo          num__pattern_curiosity -0.368113  0.368113
2543  Medio  num__pattern_corporate_context -0.367790  0.367790
3818   Alto        num__pattern_credentials  0.326720  0.326720
2538  Medio        num__pattern_credentials  0.313275  0.313275
1256   Bajo            num__pattern_urgency -0.312280  0.312280
3821   Alto
num__pattern_incentive -0.252589  0.252589
```

Visual de salida asociado a la celda:

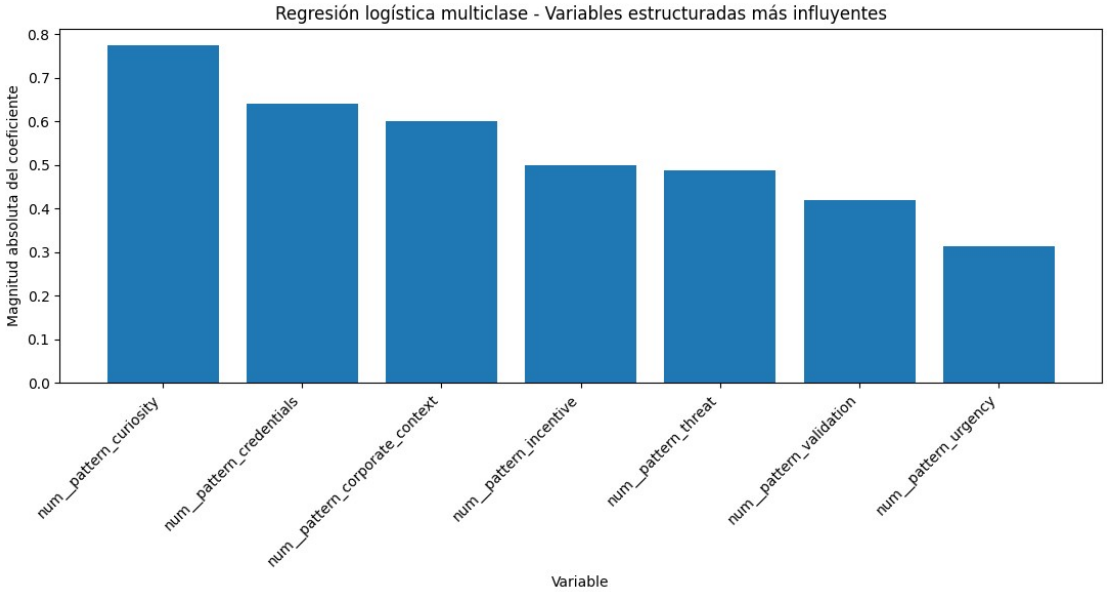

Celda 54. Grafica 13. Random Forest para la predicción de reporte

La gráfica de Random Forest muestra la importancia relativa de las variables más influyentes en la tarea de reporte.

Conceptos y terminos clave

- feature importance: Indicador general de relevancia predictiva de una variable dentro de un modelo.
- reducción de impureza: Criterio usado por arboles y bosques para medir cuanto mejora una particion al volver mas homogéneos los nodos hijos.
- ensamble de árboles: Conjunto de multiples arboles de decision combinados para producir una salida mas estable.

En un bosque aleatorio, esta visualización es más informativa que un diagrama de árboles individuales, porque resume qué atributos explican más reducción de incertidumbre.

Contexto declarado en el notebook: Grafica 13. Random Forest para la predicción de reporte Esta visualización mantiene la importancia de variables del modelo final de bosques aleatorios. A diferencia de una representación abstracta de votación entre árboles, aquí se usa directamente la importancia real calculada por el modelo entrenado con las variables estructuradas del proyecto.

Codigo fuente analizado:

```
# ==============================================================================
# Random Forest - importancia real de variables para la tarea de reporte
# ==============================================================================
# Este bloque extrae las importancias reales del modelo Random Forest final y grafica
# las variables con mayor peso relativo dentro de la predicción de reporte.
#
# La figura refleja información efectiva del modelo entrenado, por lo que resulta más
# útil que una representación puramente conceptual de árboles votando.

prep_rf = model_report_rf.named_steps["prep"]
clf_rf = model_report_rf.named_steps["clf"]

feature_names_rf = prep_rf.get_feature_names_out()
importances_rf = clf_rf.feature_importances_

# Construye un DataFrame de importancias ordenado de mayor a menor.
```

```python
df_rf_imp = pd.DataFrame({
    "feature": feature_names_rf,
    "importance": importances_rf
}).sort_values("importance", ascending=False).head(15)

# Muestra la tabla como evidencia adicional.
print(df_rf_imp)

# Crea una nueva figura de matplotlib para la visualización.
plt.figure(figsize=(10, 6))
# Dibuja la importancia relativa de las variables más influyentes.
plt.bar(df_rf_imp["feature"], df_rf_imp["importance"])

# Añade título y etiquetas.
plt.title("Random Forest - importancia real de variables")
plt.xlabel("Variable")
plt.ylabel("Importancia")
plt.xticks(rotation=45, ha="right")
plt.tight_layout()
plt.show()
```

Salida textual relevante:

```
                                   feature  importance
3                            num__risk_score    0.069465
27          cat__result_status_Submitted Data    0.062684
26            cat__result_status_Clicked Link    0.060152
20               cat__position_Jefe de Taller    0.059986
18         cat__position_Encargado de Compras    0.053955
15        cat__position_Asistente de Finanzas    0.052851
13             cat__position_Analista de RRHH    0.051774
24  cat__position_Supervisor de Mantenimiento    0.050544
25           cat__position_Tecnico de Soporte    0.045138
14             cat__position_Asesor Comercial    0.045003
23                cat__position_Recepcionista    0.044873
22         cat__position_Operador de Sistemas    0.043893
16            cat__position_Auxiliar Contable    0.043335
19           cat__position_Jefe de Produccion    0.043222
17        cat__position_Coordinador Logistico    0.042121
```

Visual de salida asociado a la celda:

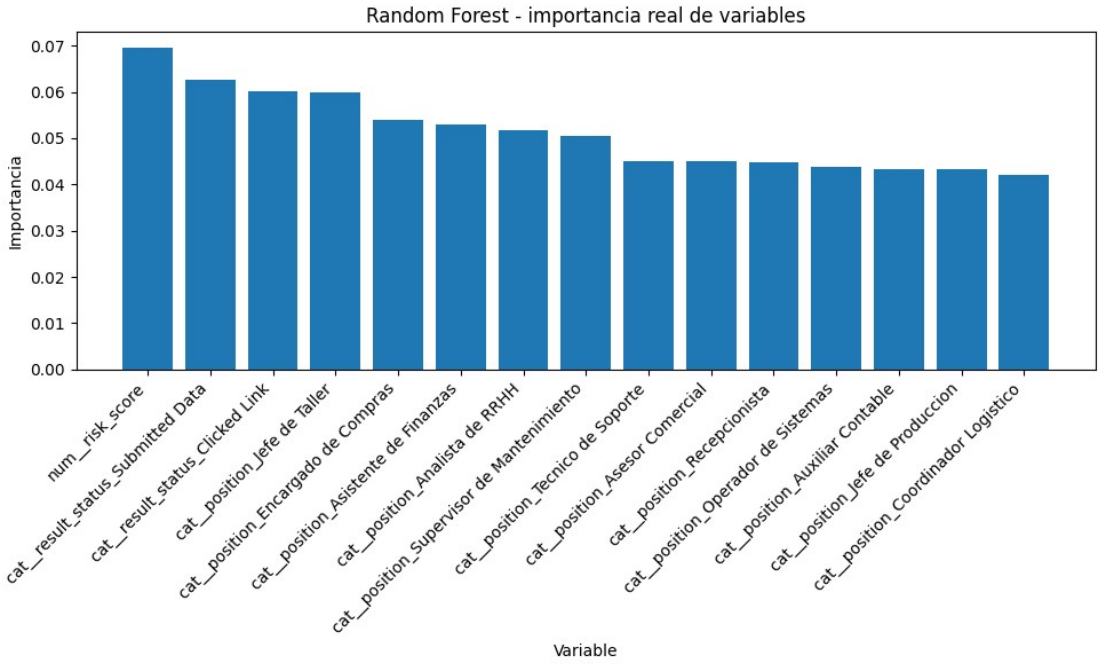

Celda 61. Exportación de datasets, métricas, tablas, gráficas y modelos

La celda final intenta exportar artefactos del proyecto: datasets, tablas, matrices, JSON y modelos serializados. Sin embargo, la ejecución falla por una referencia a `json` no disponible en el alcance efectivo de la celda.

Conceptos y terminos clave

- serialización: Proceso de guardar objetos de Python, como modelos entrenados, en archivos reutilizables.
- exportación reproducible: Generacion de artefactos finales de forma consistente para que puedan volver a producirse con el mismo flujo.
- NameError: Error de Python que ocurre cuando se intenta usar una variable o modulo que no ha sido definido o importado.
- artefactos analíticos: Productos generados por el proceso de analisis, como modelos, tablas, graficas, metricas o archivos exportados.

Este error no invalida los modelos previos, pero sí impide cerrar el pipeline de evidencia automática sin una corrección menor del código.

Contexto declarado en el notebook: Exportación de datasets, métricas, tablas, gráficas y modelos Este bloque crea una carpeta de salida y guarda los artefactos principales del proyecto: - datasets finales, - tablas de comparación, - matrices de confusión, - métricas agregadas, - modelos serializados, - y gráficas clave en formato PNG.

Codigo fuente analizado:

```
# ==============================================================================
# Exportación final de evidencias del proyecto
# ==============================================================================
# Este bloque guarda en disco los datasets finales, tablas de métricas, matrices de
# confusión, modelos serializados y gráficas principales. La idea es dejar una evidencia
# reproducible y reutilizable del análisis final.

# Define la carpeta donde se almacenarán los archivos de salida del proyecto.
output_dir = os.path.join(os.getcwd(), "exportables_finales_proyecto")
# Crea la carpeta de salida si todavía no existe.
```

```
os.makedirs(output_dir, exist_ok=True)

# -------------------------
# Exportación de datasets finales
# -------------------------
# Guarda el dataset final de plantillas y patrones de ingeniería social.
df_templates_final.to_csv(os.path.join(output_dir, "df_templates_final.csv"), index=False, encoding="utf-8-sig")
# Guarda el dataset final del riesgo derivado por plantilla.
df_risk_rules.to_csv(os.path.join(output_dir, "df_risk_rules.csv"), index=False, encoding="utf-8-sig")
# Guarda el dataset final de resultados para la tarea de reporte.
df_report_result.to_csv(os.path.join(output_dir, "df_report_result.csv"), index=False, encoding="utf-8-sig")

# -------------------------
# Exportación de tablas auxiliares
# -------------------------
# Guarda la tabla comparativa de métricas entre modelos.
df_model_metrics.to_csv(os.path.join(output_dir, "df_model_metrics.csv"), index=False, encoding="utf-8-sig")
# Guarda la tabla de thresholds del modelo lineal de reporte.
df_thresholds.to_csv(os.path.join(output_dir, "df_thresholds.csv"), index=False, encoding="utf-8-sig")
# Guarda la tabla de importancia de variables de Random Forest.
df_rf_imp.to_csv(os.path.join(output_dir, "df_rf_importance.csv"), index=False, encoding="utf-8-sig")

# Guarda la comparación real vs predicho por template en patrones, si existe.
if "df_compare_templates" in globals():
    df_compare_templates.to_csv(os.path.join(output_dir, "df_compare_templates.csv"), index=False, encoding="utf-8-
sig")

# -------------------------
# Exportación de matrices de confusión
# -------------------------
# Convierte y guarda la matriz de confusión del riesgo derivado.
df_cm_risk_export = pd.DataFrame(
    cm_risk,
    index=["Real_Bajo", "Real_Medio", "Real_Alto"],
    columns=["Pred_Bajo", "Pred_Medio", "Pred_Alto"]
)
df_cm_risk_export.to_csv(os.path.join(output_dir, "df_cm_risk.csv"), encoding="utf-8-sig")

# Convierte y guarda la matriz de confusión del reporte con Random Forest.
df_cm_report_rf_export = pd.DataFrame(
    cm_report_rf,
    index=["Real_NoReportado", "Real_Reportado"],
    columns=["Pred_NoReportado", "Pred_Reportado"]
)
df_cm_report_rf_export.to_csv(os.path.join(output_dir, "df_cm_report_rf.csv"), encoding="utf-8-sig")

# -------------------------
# Exportación de métricas resumidas en JSON
# -------------------------
# Arma un diccionario compacto con métricas finales para reutilización externa.
final_metrics = {
    "patterns_urgency": {
        "accuracy": float(pattern_accuracy),
        "macro_f1": float(pattern_macro_f1),
        "weighted_f1": float(pattern_weighted_f1)
    },
    "risk_rule": {
        "accuracy": float(risk_accuracy),
```

```
        "macro_f1": float(risk_macro_f1),
        "weighted_f1": float(risk_weighted_f1)
    },
    "report_random_forest": {
        "accuracy": float(report_rf_accuracy),
        "macro_f1": float(report_rf_macro_f1),
        "weighted_f1": float(report_rf_weighted_f1)
    }
}

# Guarda el resumen de métricas en formato JSON.
with open(os.path.join(output_dir, "final_metrics.json"), "w", encoding="utf-8") as f:
    json.dump(final_metrics, f, ensure_ascii=False, indent=4)

# -------------------------
# Serialización de modelos finales
# -------------------------
# Guarda el modelo multietiqueta de patrones.
if "model_patterns_final" in globals():
    joblib.dump(model_patterns_final, os.path.join(output_dir, "model_patterns_final.joblib"))

# Guarda el modelo final de riesgo interpretado.
if "model_risk_final" in globals():
    joblib.dump(model_risk_final, os.path.join(output_dir, "model_risk_final.joblib"))

# Guarda el modelo final de reporte con Random Forest.
if "model_report_rf" in globals():
    joblib.dump(model_report_rf, os.path.join(output_dir, "model_report_rf.joblib"))

# -------------------------
# Exportación de gráficas principales
# -------------------------
# Gráfica de accuracy entre modelos.
plt.figure(figsize=(10, 5))
plt.bar(df_model_metrics["modelo"], df_model_metrics["accuracy"])
plt.title("Comparacion de Accuracy entre modelos")
plt.xlabel("Modelo")
plt.ylabel("Accuracy")
plt.xticks(rotation=25, ha="right")
for i, v in enumerate(df_model_metrics["accuracy"]):
    plt.text(i, v + 0.01, f"{v:.2f}", ha="center")
plt.tight_layout()
plt.savefig(os.path.join(output_dir, "grafica_accuracy_modelos.png"), dpi=300, bbox_inches="tight")
plt.close()

# Gráfica de Macro F1 entre modelos.
plt.figure(figsize=(10, 5))
plt.bar(df_model_metrics["modelo"], df_model_metrics["macro_f1"])
plt.title("Comparacion de Macro F1 entre modelos")
plt.xlabel("Modelo")
plt.ylabel("Macro F1")
plt.xticks(rotation=25, ha="right")
for i, v in enumerate(df_model_metrics["macro_f1"]):
    plt.text(i, v + 0.01, f"{v:.2f}", ha="center")
plt.tight_layout()
plt.savefig(os.path.join(output_dir, "grafica_macro_f1_modelos.png"), dpi=300, bbox_inches="tight")
plt.close()
```

```
# Gráfica de Weighted F1 entre modelos.
plt.figure(figsize=(10, 5))
plt.bar(df_model_metrics["modelo"], df_model_metrics["weighted_f1"])
plt.title("Comparacion de Weighted F1 entre modelos")
plt.xlabel("Modelo")
plt.ylabel("Weighted F1")
plt.xticks(rotation=25, ha="right")
for i, v in enumerate(df_model_metrics["weighted_f1"]):
    plt.text(i, v + 0.01, f"{v:.2f}", ha="center")
plt.tight_layout()
plt.savefig(os.path.join(output_dir, "grafica_weighted_f1_modelos.png"), dpi=300, bbox_inches="tight")
plt.close()

# Matriz de confusión del riesgo.
plt.figure(figsize=(6, 5))
plt.imshow(cm_risk, interpolation="nearest")
plt.title("Matriz de confusion - Riesgo derivado")
plt.colorbar()
plt.xticks(np.arange(3), ["Bajo", "Medio", "Alto"])
plt.yticks(np.arange(3), ["Bajo", "Medio", "Alto"])
plt.xlabel("Prediccion")
plt.ylabel("Valor real")
for i in range(cm_risk.shape[0]):
    for j in range(cm_risk.shape[1]):
        plt.text(j, i, str(cm_risk[i, j]), ha="center", va="center")
plt.tight_layout()
plt.savefig(os.path.join(output_dir, "matriz_confusion_riesgo.png"), dpi=300, bbox_inches="tight")
plt.close()

# Matriz de confusión del reporte con Random Forest.
plt.figure(figsize=(6, 5))
plt.imshow(cm_report_rf, interpolation="nearest")
plt.title("Matriz de confusion - Reporte (Random Forest)")
plt.colorbar()
plt.xticks(np.arange(2), ["No reportado", "Reportado"])
plt.yticks(np.arange(2), ["No reportado", "Reportado"])
plt.xlabel("Prediccion")
plt.ylabel("Valor real")
for i in range(cm_report_rf.shape[0]):
    for j in range(cm_report_rf.shape[1]):
        plt.text(j, i, str(cm_report_rf[i, j]), ha="center", va="center")
plt.tight_layout()
plt.savefig(os.path.join(output_dir, "matriz_confusion_reporte_rf.png"), dpi=300, bbox_inches="tight")
plt.close()

# Imprime la ruta final para dejar evidencia de dónde se guardaron los archivos.
print("Archivos exportados en:", output_dir)
print(sorted(os.listdir(output_dir)))
```

Incidencia detectada: NameError: name 'json' is not defined

Interpretacion tecnica: la celda intenta serializar o exportar artefactos de salida, pero falla por una referencia no resuelta a `json`. La correccion inmediata consiste en asegurar que `import json` exista en el mismo contexto efectivo antes de ejecutar la exportacion o volver a ejecutar la celda de importaciones.

Celda 63. Resumen automático de cierre

El resumen automático de cierre sintetiza los mejores modelos y limitaciones principales del estudio.

Conceptos y terminos clave

- síntesis ejecutiva: Resumen final orientado a exponer hallazgos, implicaciones y decisiones de manera clara y directiva.
- benchmark interno: Comparacion entre modelos o configuraciones dentro del mismo proyecto y bajo condiciones controladas.
- limitaciones metodológicas: Restricciones del diseño analitico que condicionan el alcance, la validez o la interpretacion de los resultados.

Funciona como cierre operativo del notebook y condensa la lectura de negocio/técnica para defensa o presentación.

Contexto declarado en el notebook: Resumen automático de cierre Este bloque sintetiza los resultados oficiales del proyecto y deja una salida textual breve que puede reutilizarse como guía de cierre, control de calidad o apoyo para la defensa.

Codigo fuente analizado:

```python
# ==============================================================================
# Resumen automático final del proyecto
# ==============================================================================
# Este bloque imprime un resumen compacto de los modelos finales, sus métricas principales
# y las limitaciones más relevantes detectadas durante el análisis.

# Identifica el mejor modelo por accuracy dentro de la tabla comparativa.
best_accuracy_row = df_model_metrics.sort_values("accuracy", ascending=False).iloc[0]
# Identifica el mejor modelo por Macro F1 dentro de la tabla comparativa.
best_macro_f1_row = df_model_metrics.sort_values("macro_f1", ascending=False).iloc[0]

# Construye una lista de limitaciones finales del estudio.
final_limitations = [
    "Número reducido de plantillas únicas para el modelado textual.",
    "Desbalance severo de clases en la tarea de reporte.",
    "Parte del etiquetado de patrones y del riesgo fue semiautomático.",
    "El reporte depende de variables conductuales no completamente observadas."
]

# Imprime el resumen ejecutivo final del proyecto.
print("=" * 90)
print("RESUMEN FINAL DEL PROYECTO")
print("=" * 90)
print(f"Mejor modelo por accuracy: {best_accuracy_row['modelo']} ({best_accuracy_row['accuracy']:.4f})")
print(f"Mejor modelo por Macro F1: {best_macro_f1_row['modelo']} ({best_macro_f1_row['macro_f1']:.4f})")
print(f"Accuracy del modelo de patrones (urgencia): {pattern_accuracy:.4f}")
print(f"Accuracy del modelo de riesgo derivado: {risk_accuracy:.4f}")
print(f"Accuracy del modelo de reporte RF: {report_rf_accuracy:.4f}")
print("-" * 90)
print("Limitaciones principales:")
for limitation in final_limitations:
    print(f"- {limitation}")
print("-" * 90)
print("Ruta de exportación final:", output_dir)
```

Salida textual relevante:

```
==========================================================================================
RESUMEN FINAL DEL PROYECTO
==========================================================================================
Mejor modelo por accuracy: Reporte RF (0.8734)
Mejor modelo por Macro F1: Patrones - Urgencia (0.7636)
Accuracy del modelo de patrones (urgencia): 0.7692
Accuracy del modelo de riesgo derivado: 0.7692
```

```
Accuracy del modelo de reporte RF: 0.8734
--------------------------------------------------------------------------------------------
Limitaciones principales:
- Número reducido de plantillas únicas para el modelado textual.
- Desbalance severo de clases en la tarea de reporte.
- Parte del etiquetado de patrones y del riesgo fue semiautomático.
- El reporte depende de variables conductuales no completamente observadas.
--------------------------------------------------------------------------------------------
Ruta de exportación final: d:\Dev\Python\pre-
project\testing\exportables_finales_proyecto
```

4. Interpretacion ampliada de graficas y tablas

Grafica 1. Comparacion de accuracy entre modelos

La primera gráfica comparativa resume accuracy entre tres componentes del sistema: patrones, riesgo derivado y reporte RF. Funciona como vista ejecutiva de desempeño.

Aunque el Reporte RF lidera en accuracy, esto no implica automáticamente mejor equilibrio entre clases; por eso el notebook también presenta Macro F1 y Weighted F1.

Lectura profesional: el liderazgo del modelo de Reporte RF en accuracy no debe interpretarse de forma aislada, porque la clase no reportada domina casi todo el universo de observaciones. El indicador dice que el modelo acierta con frecuencia global, pero no garantiza buena sensibilidad sobre la clase reportada.

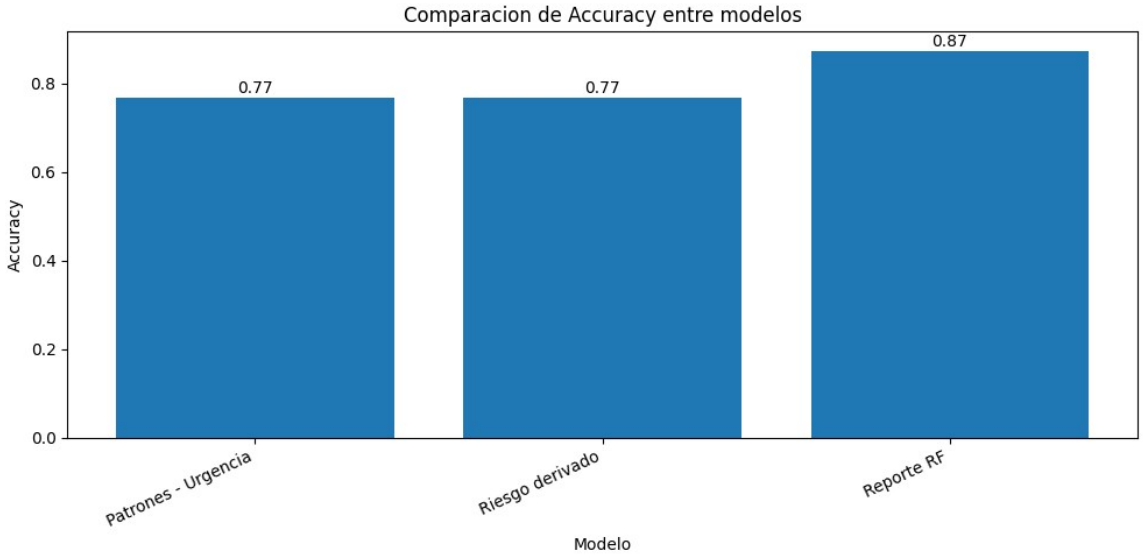

Grafica 2. Comparacion de Macro F1 entre modelos

La gráfica de Macro F1 compara la calidad promedio por clase sin favorecer a la clase mayoritaria.

Es la métrica más honesta cuando existe desbalance, pues penaliza modelos que solo aprenden la clase dominante.

Lectura profesional: esta grafica es esencial para desmontar lecturas excesivamente optimistas del accuracy. Un modelo puede parecer fuerte por volumen de aciertos en la clase mayoritaria y aun asi tener valor limitado para casos raros; Macro F1 corrige justamente ese sesgo.

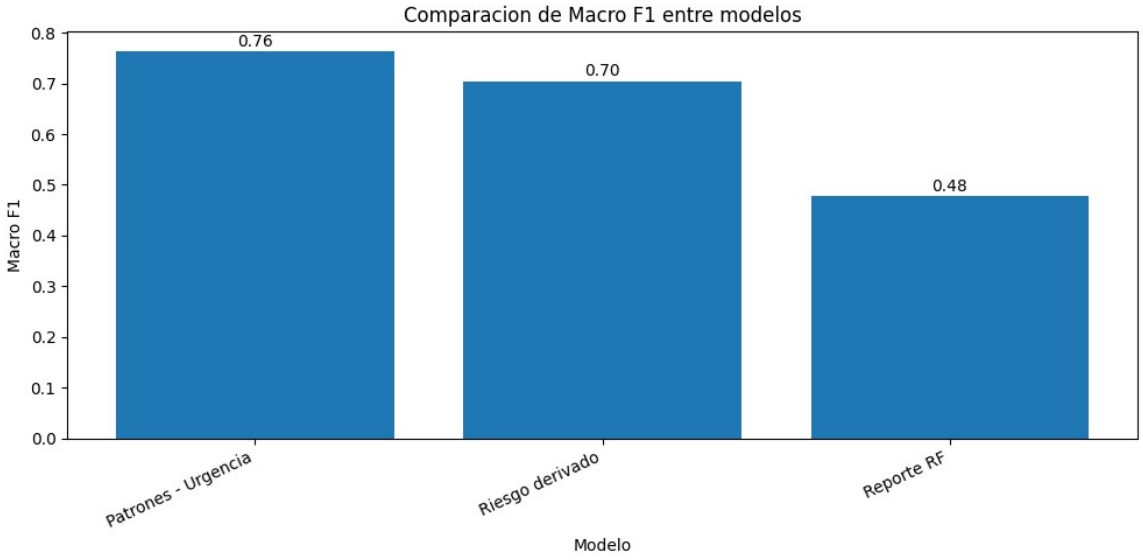

Grafica 3. Comparacion de Weighted F1 entre modelos

La gráfica de Weighted F1 incorpora el soporte de cada clase y ayuda a contextualizar el peso de la clase mayoritaria.

Complementa Macro F1: un valor alto aquí puede coexistir con un desempeño pobre en la clase minoritaria.

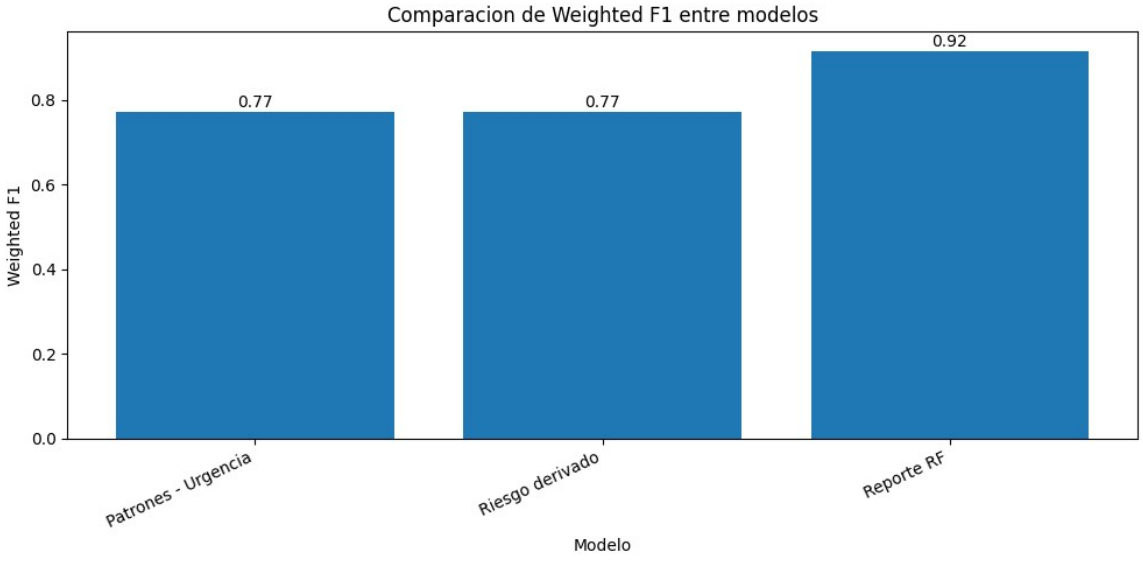

Grafica 4. Distribucion final de patrones de ingenieria social

La distribución de patrones por plantilla muestra cuántas plantillas activan cada patrón de ingeniería social.

Sirve para entender qué tipos de manipulación son más comunes en el corpus y cuáles están subrepresentados.

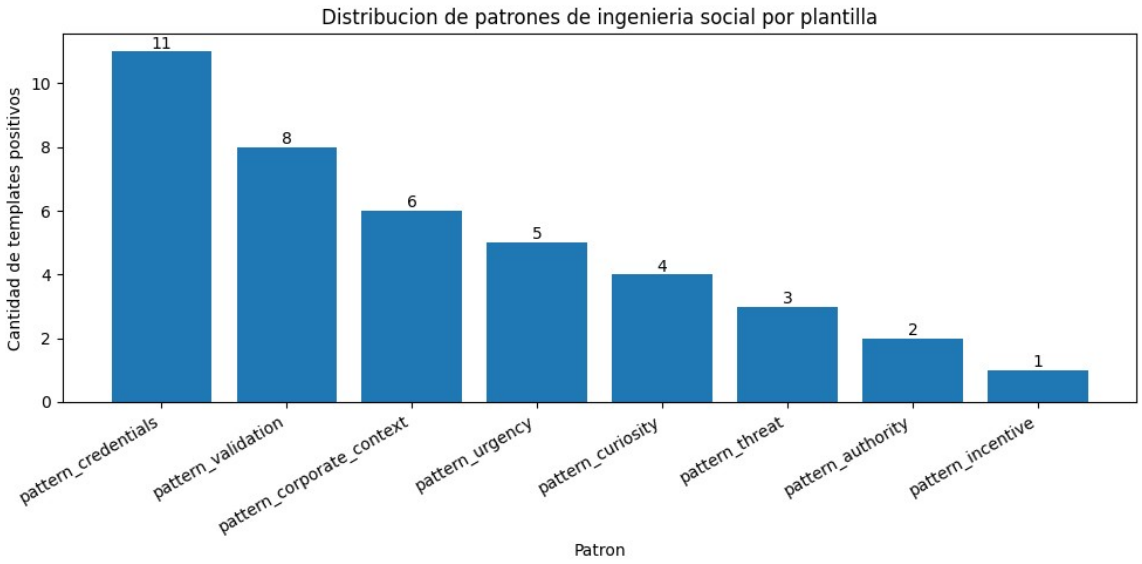

Grafica 5. Matriz de confusion del modelo de riesgo derivado

La matriz de confusión del riesgo derivado muestra aciertos y errores por clase Bajo, Medio y Alto.

Permite ver no solo cuánto acierta el modelo, sino dónde falla: por ejemplo, si confunde riesgo medio con alto, o si colapsa hacia la clase dominante.

Lectura profesional: cuando una matriz de confusion muestra concentracion en la diagonal, el modelo conserva discriminacion. Cuando aparecen errores fuera de diagonal entre clases adyacentes, ello sugiere que el problema no es completamente aleatorio, sino parcialmente ambiguo en fronteras semanticas.

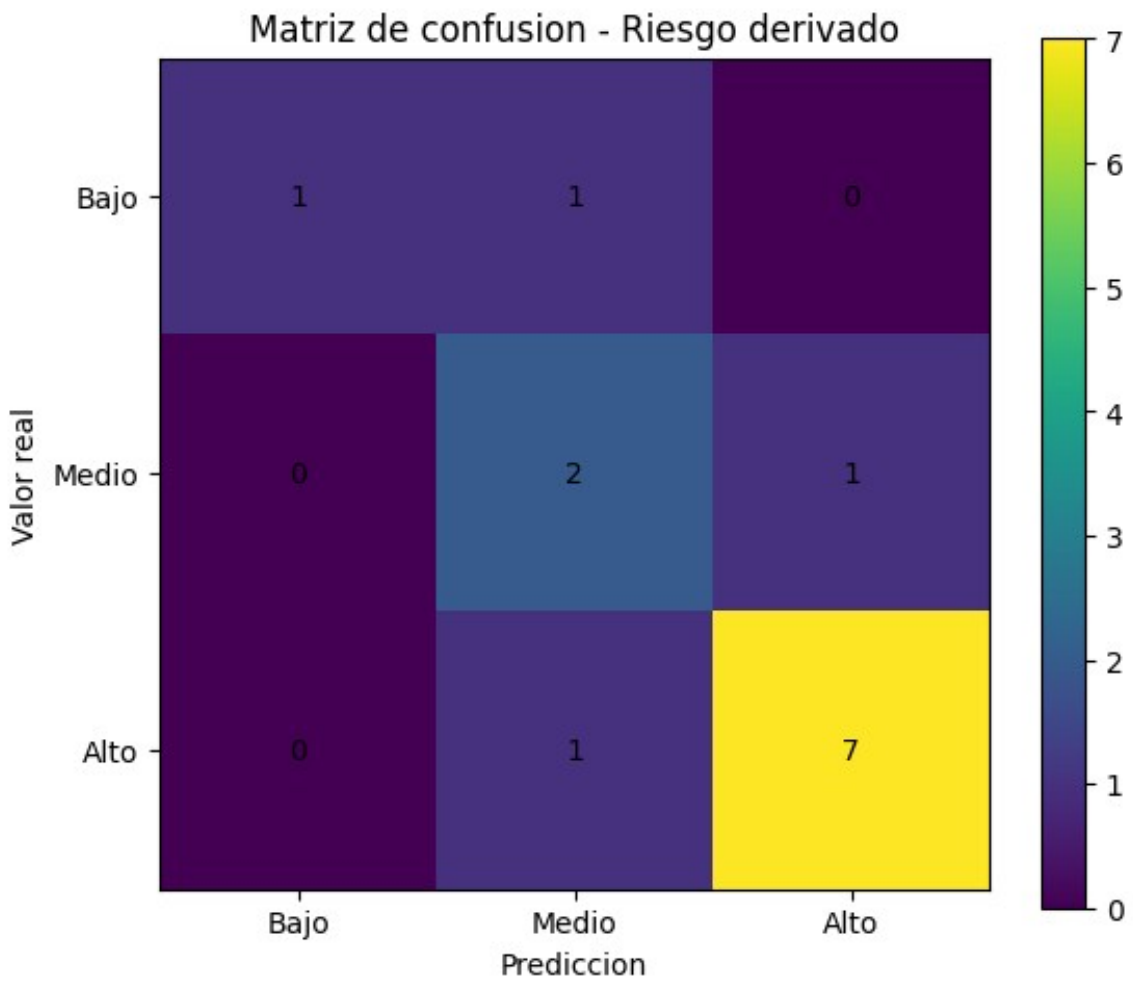

Grafica 6. Matriz de confusion del modelo de reporte con Random Forest

La matriz de confusión del reporte con Random Forest ilustra la capacidad real del modelo final para distinguir resultados reportados y no reportados.

La gran masa de no reportados domina la matriz; por eso debe leerse junto con precision, recall y F1 de la clase positiva.

Lectura profesional: aqui conviene fijarse especialmente en los falsos negativos de la clase reportada. En un escenario operativo de ciberseguridad, esos casos son mas costosos que muchos falsos positivos, porque representan eventos relevantes que el sistema deja escapar.

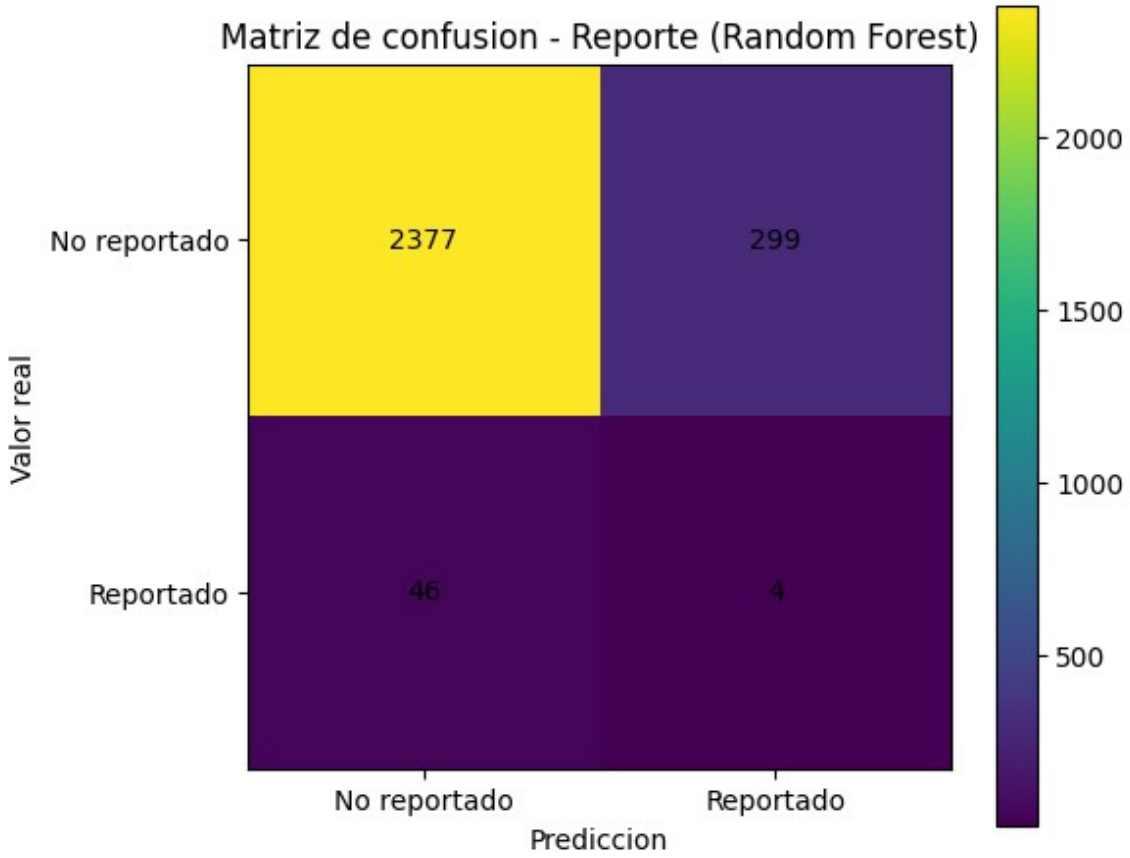

Grafica 7. Analisis de thresholds en el modelo lineal de reporte

La curva de thresholds grafica cómo cambian accuracy, precision, recall y F1 al mover el umbral.

Es una herramienta de diseño operacional: ayuda a decidir en qué punto conviene desplegar el modelo según el costo de errores.

Lectura profesional: esta figura no busca una curva "bonita", sino una politica de decision. Permite escoger un umbral distinto segun el contexto: investigacion academica, simulacion de concienciacion o despliegue practico con revision humana.

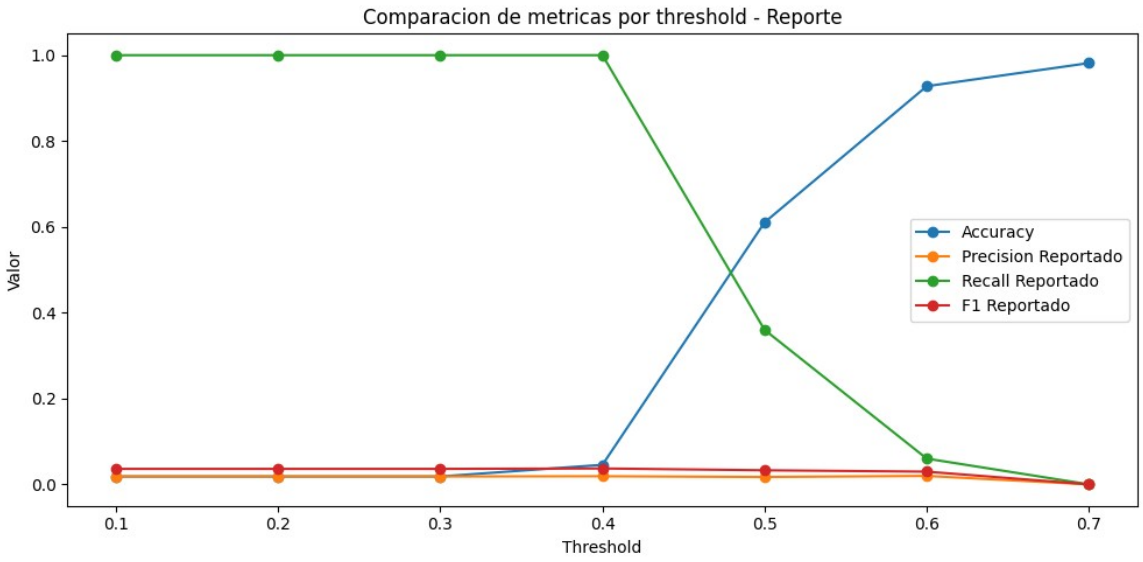

Grafica 8. Distribucion del riesgo derivado por plantilla

La distribución del riesgo derivado por plantilla resume la salida de las reglas de scoring.

Valida visualmente que el riesgo derivado sí tiene variabilidad útil para modelado.

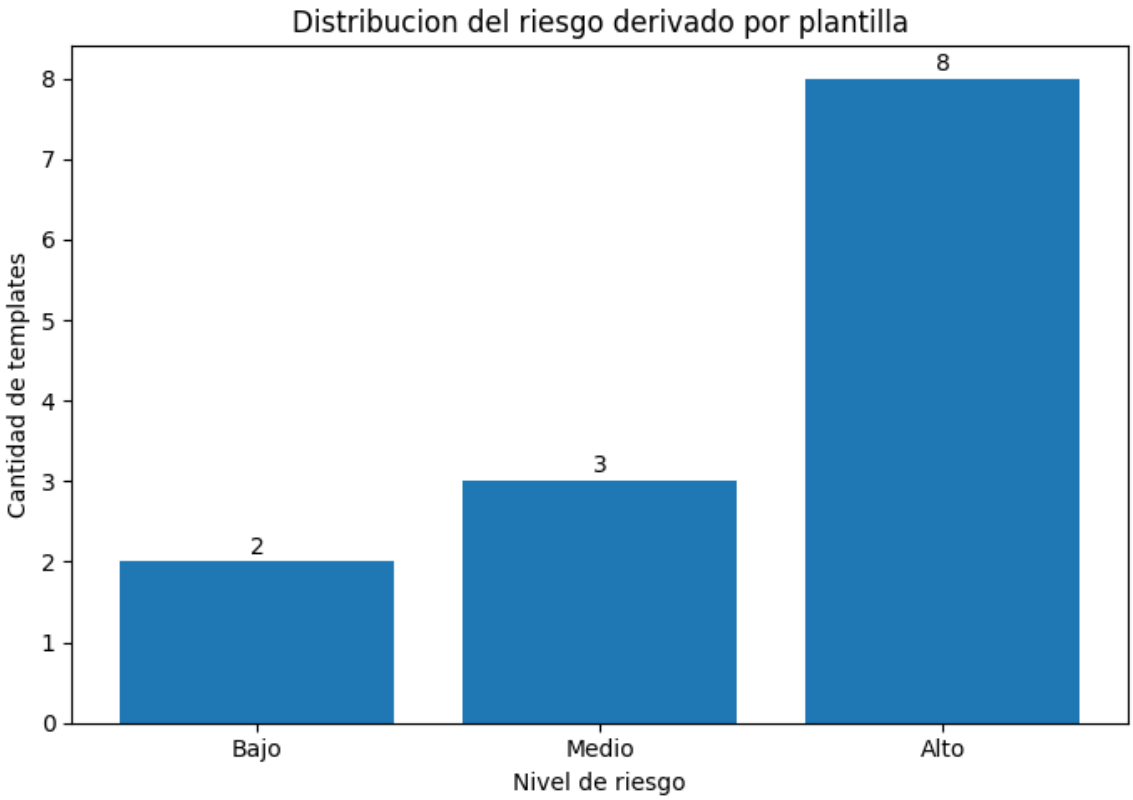

Grafica 9. Tasa de reporte observada por plantilla

La tasa de reporte observada por plantilla permite contrastar la reacción empírica de usuarios entre campañas o plantillas.

Esta lectura es importante porque el reporte no depende solo del texto, sino del contexto y de variables humanas no totalmente observadas.

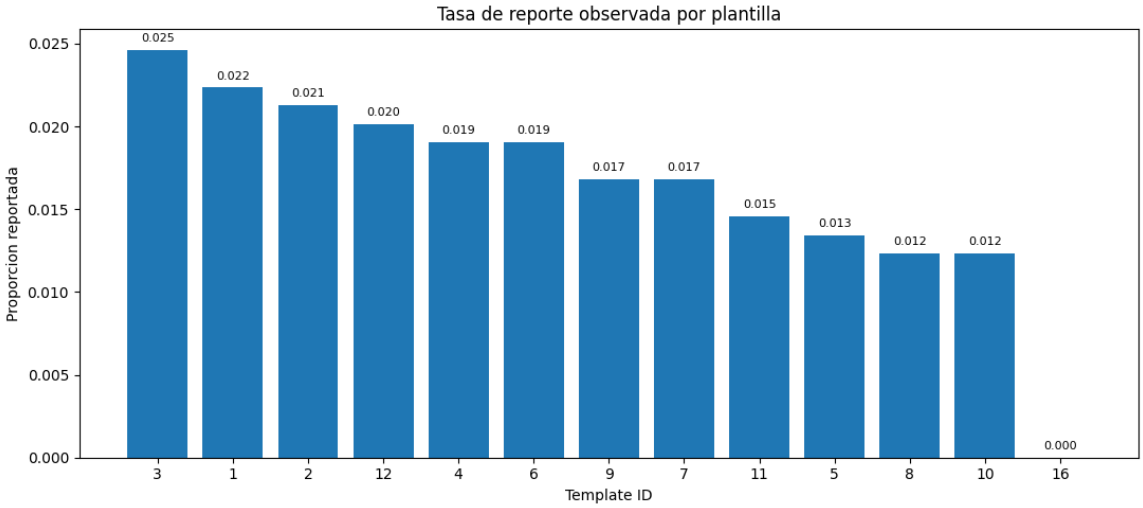

Grafica 10. Regresión logística binaria aplicada al reporte de correos

La gráfica conceptual de regresión logística binaria para reporte utiliza probabilidades reales estimadas del modelo lineal.

Su aporte no es mostrar una línea recta, sino la estructura probabilística con la que el modelo separa reportado y no reportado.

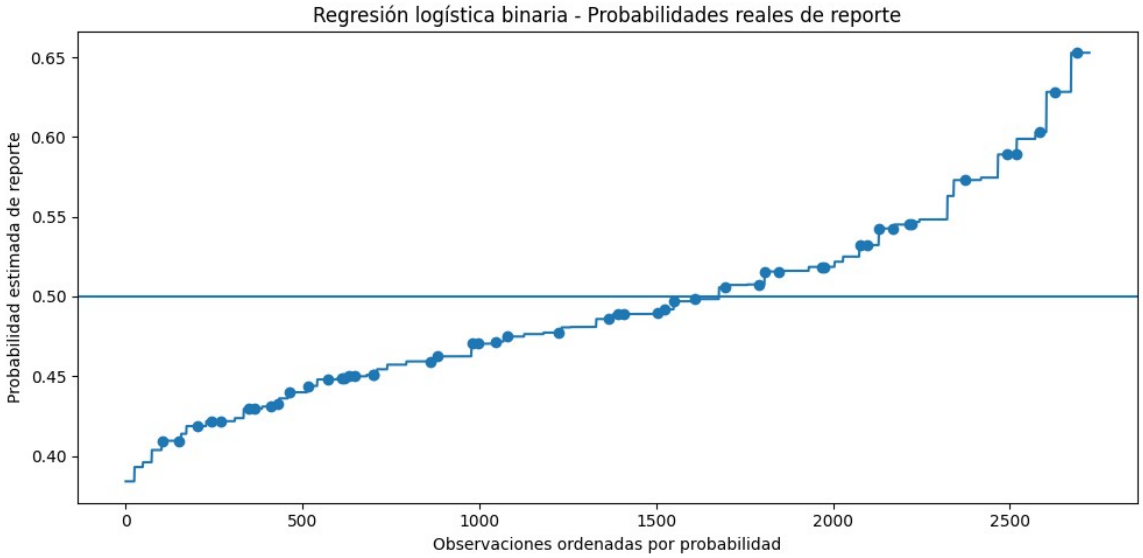

Grafica 11. OneVsRest + regresión logística para patrones de ingeniería social

La gráfica de OneVsRest + regresión logística presenta el rendimiento real por patrón de ingeniería social.

Es una vista granular del detector; muestra que algunos patrones son considerablemente más reconocibles que otros.

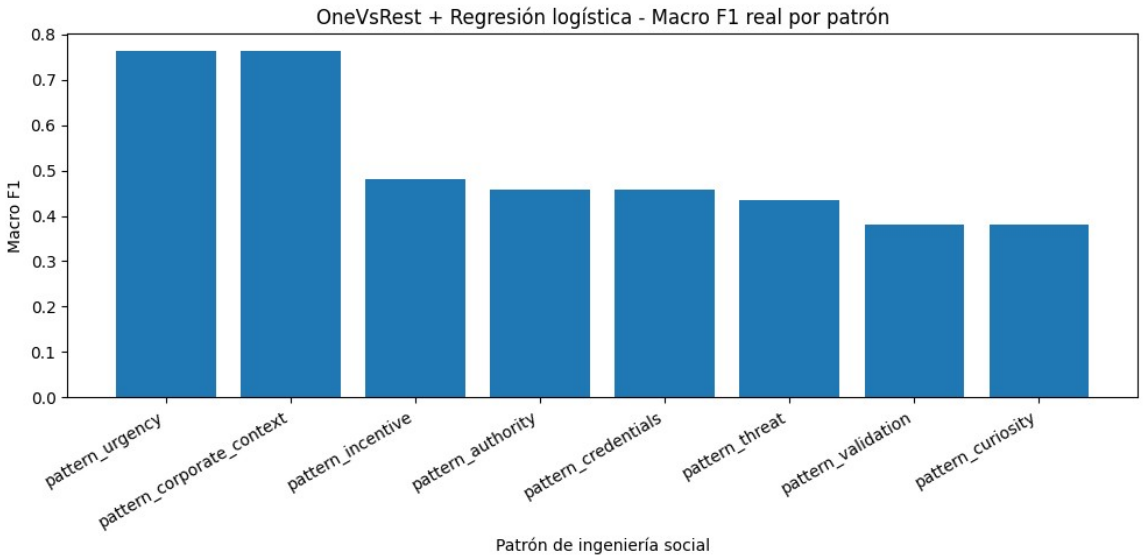

Grafica 12. Regresión logística multiclase aplicada al riesgo derivado

La visualización de regresión logística multiclase aplicada al riesgo muestra las variables estructuradas con mayor peso absoluto.

Aunque es una gráfica de barras, es correcta: el objetivo es exponer la magnitud del peso de cada variable, no representar una serie temporal ni una relación continua.

Lectura profesional: aunque la grafica se refiere a regresion logistica multiclase, una grafica de barras es totalmente adecuada porque el objetivo no es representar continuidad ni temporalidad, sino comparar magnitudes absolutas de coeficientes entre variables estructuradas.

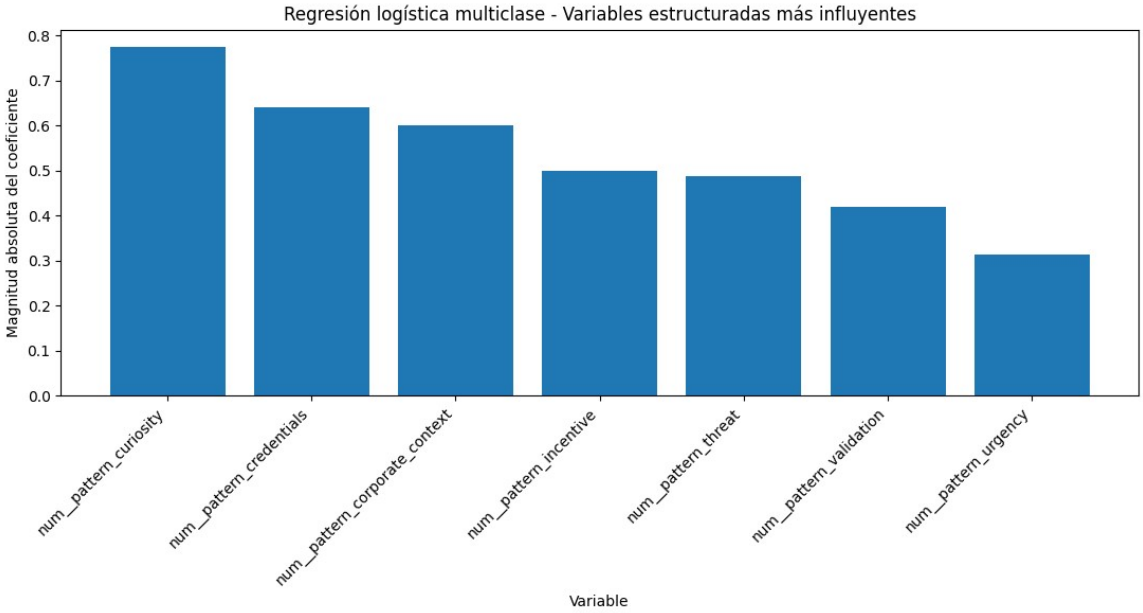

Grafica 13. Random Forest para la prediccion de reporte

La gráfica de Random Forest muestra la importancia relativa de las variables más influyentes en la tarea de reporte.

En un bosque aleatorio, esta visualización es más informativa que un diagrama de árboles individuales, porque resume qué atributos explican más reducción de incertidumbre.

Lectura profesional: Random Forest no es una sola decision arborescente, sino un ensamble de muchos arboles entrenados sobre muestras y subconjuntos de variables. Por eso la grafica de importancia agrega conocimiento del bosque completo y resulta mas util que dibujar un arbol individual.

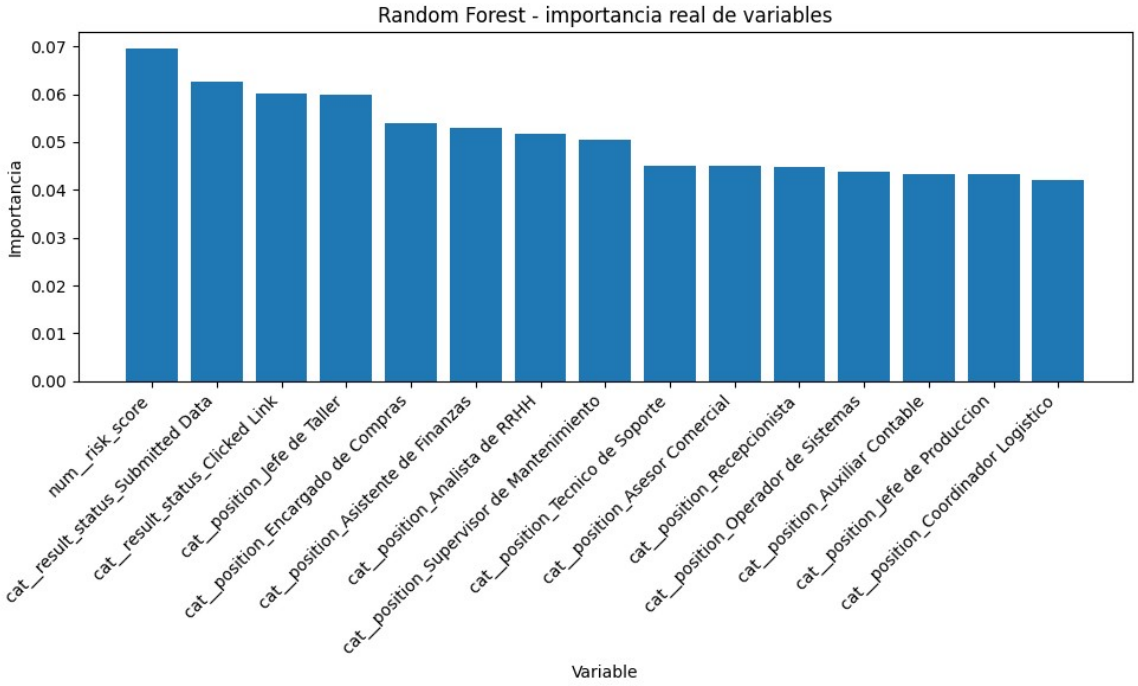

5. Glosario tecnico ampliado

TF-IDF: Tecnica de vectorizacion textual que pondera un termino segun su frecuencia en un documento y su rareza en el corpus. Permite transformar texto libre en variables numericas para modelos lineales.

Pipeline: Estructura encadenada de scikit-learn que asegura que preprocesamiento y modelo se ejecuten de forma coherente tanto en entrenamiento como en prediccion.

ColumnTransformer: Componente que aplica transformaciones distintas a subconjuntos de columnas, por ejemplo TF-IDF al texto y one-hot encoding a variables categoricas.

OneHotEncoder: Tecnica para convertir categorias nominales en variables binarias interpretable por algoritmos numericos.

One-vs-Rest: Estrategia que descompone un problema multietiqueta o multiclase en varios clasificadores binarios independientes.

Leave-One-Out: Validacion cruzada extrema donde cada observacion actua una vez como prueba y el resto como entrenamiento. Muy util en muestras pequenas.

Macro F1: Promedio simple del F1 por clase. Trata todas las clases con el mismo peso, aunque una sea muy rara.

Weighted F1: Promedio ponderado del F1 por soporte. Refleja mejor el rendimiento global, pero puede ocultar mal desempeño en clases minoritarias.

Random Forest: Ensamble de arboles de decision que reduce varianza y captura relaciones no lineales. Muy util en datos tabulares heterogeneos.

Desbalance de clases: Situacion en la que una clase tiene muchisimos mas ejemplos que otra. Complica el aprendizaje de la clase minoritaria y distorsiona metricas simples.

Matriz de confusion: Tabla que compara clases reales y predichas para identificar el tipo de error cometido por el modelo.

Feature engineering: Proceso de construir variables utiles a partir de datos crudos o conocimiento del dominio.

6. Valoracion tecnica final

El notebook presenta una estructura madura para un proyecto aplicado de seguridad y aprendizaje automatico. Sus fortalezas principales son: separacion entre nivel de plantilla y nivel de resultado, construccion explicita de reglas de negocio, uso de metrica mas alla del accuracy, e inclusion de interpretabilidad. Todo esto lo acerca mas a un cuaderno de investigacion defendible que a una simple prueba de concepto improvisada.

Sus limitaciones tambien son claras y correctamente reconocidas por el propio flujo: pocas plantillas unicas, desbalance severo en la variable de reporte, y dependencia parcial de etiquetado semiautomatico. Estas limitaciones no anulan el estudio; mas bien definen su frontera de validez. El resultado debe presentarse como una propuesta analitica robusta sobre datos disponibles, no como un detector universal ya listo para despliegue productivo.

Finalmente, la incidencia de exportacion observada en la celda 61 constituye un problema de cierre del pipeline, no un defecto conceptual del enfoque analitico. Con una correccion menor del contexto de importaciones, el notebook puede dejar completamente automatizada la generacion de evidencias, modelos y tablas finales.